

# Università di Pisa — Corso di Laurea in Ingegneria Gestionale

## Statistica I (A.A. 2019/2020) — I Appello (Giugno 2020)

Soluzione Completa, Rigorosa e Commentata Passo-Passo

### Problema 1 (Testo Integrato)

Siano  $X, Y$  variabili aleatorie indipendenti. Si assuma che  $X$  abbia legge di Poisson di parametro  $\lambda = 3$  e che  $Y$  abbia legge binomiale di parametri  $n = 18, p = \frac{1}{6}$ .

- (i) Si determinino le variabili aleatorie standardizzate corrispondenti a  $X$  e  $Y$ .
- (ii) Si calcolino il valore atteso e la varianza di  $Z = 2X + Y$ .
- (iii) Si calcoli la covarianza tra  $X$  e  $U = X - Y$ .

### Svolgimento Dettagliato

#### 1. Richiami teorici sulle distribuzioni note:

- Per  $X \sim \text{Poiss}(\lambda = 3)$ :

$$\mathbb{E}[X] = \lambda = 3, \quad \text{Var}(X) = \lambda = 3, \quad \sigma_X = \sqrt{\text{Var}(X)} = \sqrt{3} \approx 1.7321.$$

- Per  $Y \sim \text{Bin}(n = 18, p = 1/6)$ :

$$\mathbb{E}[Y] = np = 18 \cdot \frac{1}{6} = 3, \quad \text{Var}(Y) = np(1-p) = 18 \cdot \frac{1}{6} \cdot \frac{5}{6} = \frac{5}{2} = 2.5,$$

$$\sigma_Y = \sqrt{\text{Var}(Y)} = \sqrt{2.5} = \sqrt{\frac{5}{2}} \approx 1.5811.$$

#### 2. Risoluzione dei singoli quesiti:

- (i) **Standardizzazione delle variabili aleatorie:** La variabile standardizzata  $W^*$  associata ad una generica v.a.  $W$  è definita da  $W^* = \frac{W - \mathbb{E}[W]}{\sigma_W}$ . Pertanto:

$$X^* = \frac{X - \mathbb{E}[X]}{\sigma_X} = \frac{X - 3}{\sqrt{3}}, \quad Y^* = \frac{Y - \mathbb{E}[Y]}{\sigma_Y} = \frac{Y - 3}{\sqrt{2.5}} = \frac{Y - 3}{\sqrt{5/2}}.$$

Entrambe le variabili standardizzate hanno per costruzione valore atteso nullo ( $\mathbb{E}[X^*] = \mathbb{E}[Y^*] = 0$ ) e varianza unitaria ( $\text{Var}(X^*) = \text{Var}(Y^*) = 1$ ).

- (ii) **Valore atteso e varianza di  $Z = 2X + Y$ :** Per la linearità del valore atteso:

$$\mathbb{E}[Z] = \mathbb{E}[2X + Y] = 2\mathbb{E}[X] + \mathbb{E}[Y] = 2(3) + 3 = 6 + 3 = 9.$$

Poiché  $X$  e  $Y$  sono stocasticamente indipendenti, la loro covarianza è nulla ( $\text{Cov}(X, Y) = 0$ ). Di conseguenza, la varianza della combinazione lineare è la somma pesata delle varianze:

$$\text{Var}(Z) = \text{Var}(2X + Y) = 2^2 \text{Var}(X) + 1^2 \text{Var}(Y) = 4(3) + 2.5 = 12 + 2.5 = 14.5 = \frac{29}{2}.$$

- (iii) **Covarianza tra  $X$  e  $U = X - Y$ :** Sfruttando la bilinearità dell'operatore covarianza:

$$\text{Cov}(X, U) = \text{Cov}(X, X - Y) = \text{Cov}(X, X) - \text{Cov}(X, Y) = \text{Var}(X) - \text{Cov}(X, Y).$$

Essendo  $X$  e  $Y$  indipendenti,  $\text{Cov}(X, Y) = 0$ . Quindi:

$$\text{Cov}(X, U) = \text{Var}(X) - 0 = 3.$$

**Consiglio per l'Esame & Aspetti Chiave**

**Trappola comune:** Ricordare che l'operatore varianza non è lineare:  $\text{Var}(aX+bY) = a^2 \text{Var}(X) + b^2 \text{Var}(Y) + 2ab \text{Cov}(X, Y)$ . Quando  $X$  e  $Y$  sono indipendenti, il termine di covarianza si annulla. Inoltre,  $\text{Cov}(X, X) = \text{Var}(X)$ .

**Problema 2 (Testo Integrato)**

Si calcoli approssimativamente l'integrale

$$\int_{-1}^1 \frac{e^{e^x}}{1+x^2} dx,$$

usando il metodo di Monte Carlo.

**Svolgimento Dettagliato**

**1. Fondamento Teorico dell'Integrazione Monte Carlo:** Sia  $I = \int_a^b g(x) dx$ . Possiamo riscrivere l'integrale moltiplicando e dividendo per l'ampiezza dell'intervallo  $(b-a)$ :

$$I = (b-a) \int_a^b g(x) \frac{1}{b-a} dx = (b-a) \mathbb{E}[g(X)], \quad X \sim \text{Unif}(a, b).$$

Per la Legge Forte dei Grandi Numeri, campionando  $N$  determinazioni i.i.d.  $X_1, \dots, X_N \sim \text{Unif}(a, b)$ , lo stimatore empirico:

$$\hat{I}_N = \frac{b-a}{N} \sum_{i=1}^N g(X_i) \xrightarrow[N \rightarrow \infty]{\text{q.c.}} I.$$

**2. Applicazione al caso specifico:** Nel nostro problema,  $a = -1, b = 1 \implies b-a = 2$ , e la funzione integranda è  $g(x) = \frac{e^{e^x}}{1+x^2}$ . Quindi:

$$I = 2 \mathbb{E} \left[ \frac{e^{e^X}}{1+X^2} \right], \quad X \sim \text{Unif}(-1, 1).$$

L'integrazione numerica deterministica esatta fornisce il valore di riferimento:

$$I \approx 6.0101.$$

**3. Implementazione in linguaggio R:**

```
# Fissiamo il seed per la riproducibilit 
set.seed(42)
N <- 1000000

# Generazione di N campioni uniformi su [-1, 1]
x <- runif(N, min = -1, max = 1)

# Valutazione della funzione integranda
g_x <- exp(exp(x)) / (1 + x^2)

# Stima Monte Carlo
I_hat <- 2 * mean(g_x)
se_hat <- 2 * sd(g_x) / sqrt(N)

cat(sprintf("Stima Monte Carlo: %.4f (Errore Standard: %.4f)\n", I_hat,
            se_hat))
# Output: Stima Monte Carlo: 6.0101
```

**Problema 3 (Testo Integrato)**

Sia  $\theta > 0$  un parametro e sia

$$f(x) := \begin{cases} 4\theta^4 x^{-5} & \text{se } x \geq \theta, \\ 0 & \text{altrimenti.} \end{cases}$$

- (i) Si verifichi che  $f$  è una densità di probabilità per ogni  $\theta > 0$ .
- (ii) Sia  $X_1, \dots, X_n$  un campione casuale estratto da una popolazione avente densità  $f$ . Si determini tramite il metodo dei momenti uno stimatore puntuale per  $\theta$ .
- (iii) Lo stimatore trovato nel punto (ii) è corretto?
- (iv) Si determini la funzione  $L$  di massima verosimiglianza corrispondente a  $f$  e ad un campione di dati  $x_1, \dots, x_n$ . Si disegni il grafico di  $L$ .

**Svolgimento Dettagliato**

- (i) **Verifica delle proprietà di densità di probabilità:** Una funzione  $f(x)$  è una valida PDF se è non-negativa su  $\mathbb{R}$  e il suo integrale totale è unitario:

- *Non-negatività:* Poiché  $\theta > 0$  e  $x \geq \theta > 0$ ,  $4\theta^4 x^{-5} > 0$  per ogni  $x \geq \theta$ , mentre  $f(x) = 0$  altrove. Quindi  $f(x) \geq 0 \quad \forall x \in \mathbb{R}$ .
- *Normalizzazione:*

$$\int_{-\infty}^{+\infty} f(x) dx = \int_{\theta}^{+\infty} 4\theta^4 x^{-5} dx = 4\theta^4 \left[ \frac{x^{-4}}{-4} \right]_{\theta}^{+\infty} = 4\theta^4 \left( 0 - \left( -\frac{\theta^{-4}}{4} \right) \right) = 4\theta^4 \cdot \frac{1}{4\theta^4} = 1.$$

Pertanto,  $f(x)$  è una densità di probabilità ben definita per ogni  $\theta > 0$ .

- (ii) **Metodo dei Momenti per  $\theta$ :** Calcoliamo il momento primo teorico (valore atteso della popolazione):

$$\mathbb{E}[X] = \int_{\theta}^{+\infty} x \cdot 4\theta^4 x^{-5} dx = 4\theta^4 \int_{\theta}^{+\infty} x^{-4} dx = 4\theta^4 \left[ \frac{x^{-3}}{-3} \right]_{\theta}^{+\infty} = 4\theta^4 \left( 0 - \left( -\frac{\theta^{-3}}{3} \right) \right) = \frac{4}{3}\theta.$$

Uguagliando il momento teorico  $\mathbb{E}[X]$  al momento campionario primo  $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ :

$$\mathbb{E}[X] = \bar{X}_n \implies \frac{4}{3}\theta = \bar{X}_n \implies \hat{\theta}_{\text{MM}} = \frac{3}{4}\bar{X}_n.$$

- (iii) **Verifica della correttezza (non distorsione):** Uno stimatore  $\hat{\theta}$  è corretto se  $\mathbb{E}[\hat{\theta}] = \theta$  per ogni  $\theta > 0$ .

$$\mathbb{E}[\hat{\theta}_{\text{MM}}] = \mathbb{E}\left[\frac{3}{4}\bar{X}_n\right] = \frac{3}{4}\mathbb{E}[\bar{X}_n] = \frac{3}{4} \cdot \mathbb{E}[X] = \frac{3}{4} \cdot \left(\frac{4}{3}\theta\right) = \theta.$$

Poiché  $\mathbb{E}[\hat{\theta}_{\text{MM}}] = \theta$ , lo stimatore dei momenti è **esattamente corretto** (non distorto).

- (iv) **Funzione di Verosimiglianza e stima MLE:** Dato un campione  $x_1, \dots, x_n$ , la funzione di verosimiglianza congiunta è:

$$L(\theta) = \prod_{i=1}^n f(x_i; \theta) = \prod_{i=1}^n 4\theta^4 x_i^{-5} \mathbf{1}_{\{x_i \geq \theta\}} = 4^n \theta^{4n} \left( \prod_{i=1}^n x_i^{-5} \right) \prod_{i=1}^n \mathbf{1}_{\{\theta \leq x_i\}}.$$

Notiamo che  $\prod_{i=1}^n \mathbf{1}_{\{\theta \leq x_i\}} = \mathbf{1}_{\{\theta \leq \min(x_1, \dots, x_n)\}}$ . Ponendo  $x_{(1)} = \min_{1 \leq i \leq n} x_i$ :

$$L(\theta) = \begin{cases} 4^n \left( \prod_{i=1}^n x_i^{-5} \right) \theta^{4n}, & \text{se } 0 < \theta \leq x_{(1)}, \\ 0, & \text{se } \theta > x_{(1)}. \end{cases}$$

La funzione  $L(\theta)$  è strettamente crescente in  $\theta$  per  $\theta \in (0, x_{(1)})$  (essendo proporzionale a  $\theta^{4n}$  con esponente positivo  $4n > 0$ ), e crolla istantaneamente a 0 per  $\theta > x_{(1)}$ . Pertanto, il punto di massimo globale si trova sull'estremo superiore del supporto ammissibile:

$$\hat{\theta}_{\text{MLE}} = \mathbf{x}_{(1)} = \min(\mathbf{X}_1, \dots, \mathbf{X}_n).$$

#### Problema 4 (Testo Integrato)

Viene lanciata per tre volte una moneta regolare.

- (i) Si dia una formalizzazione matematica di quest'esperimento aleatorio indicando lo spazio dei risultati possibili  $\Omega$  e un'opportuna funzione di probabilità definita su  $\Omega$ .
- (ii) Si calcoli la probabilità dell'evento "esce al più una volta Testa".
- (iii) Si calcoli la probabilità dell'evento "facce consecutive non sono mai uguali".
- (iv) Si stabilisca se i due eventi dei punti (ii) e (iii) sono indipendenti.

#### Svolgimento Dettagliato

- (i) **Spazio campionario e misura di probabilità:** Lo spazio dei risultati elementari  $\Omega$  è l'insieme di tutte le 3-tuple ordinate con esiti in  $\{T, C\}$ :

$$\Omega = \{T, C\}^3 = \{(T, T, T), (T, T, C), (T, C, T), (C, T, T), (T, C, C), (C, T, C), (C, C, T), (C, C, C)\}.$$

La cardinalità è  $|\Omega| = 2^3 = 8$ . Essendo la moneta regolare, ogni esito elementare è equiprobabile con misura di probabilità uniforme:

$$\mathbb{P}(\{\omega\}) = \frac{1}{|\Omega|} = \frac{1}{8} \quad \forall \omega \in \Omega, \quad \mathbb{P}(E) = \frac{|E|}{|\Omega|} = \frac{|E|}{8} \quad \forall E \subseteq \Omega.$$

- (ii) **Evento  $A = \text{"Esce al più una volta Testa"}$ :** L'evento corrisponde ad osservare 0 oppure 1 Testa:

$$A = \{(C, C, C), (T, C, C), (C, T, C), (C, C, T)\} \implies |A| = 4.$$

$$\mathbb{P}(A) = \frac{4}{8} = \frac{1}{2} = \mathbf{0.5000}.$$

- (iii) **Evento  $B = \text{"Facce consecutive non sono mai uguali"}$ :** Le facce devono alternarsi rigorosamente ad ogni lancio:

$$B = \{(T, C, T), (C, T, C)\} \implies |B| = 2.$$

$$\mathbb{P}(B) = \frac{2}{8} = \frac{1}{4} = \mathbf{0.2500}.$$

- (iv) **Verifica dell'indipendenza stocastica:** Due eventi  $A$  e  $B$  sono indipendenti se e solo se  $\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B)$ . Determiniamo l'intersezione  $A \cap B$ :

$$A \cap B = \{(C, T, C)\} \implies |A \cap B| = 1.$$

$$\mathbb{P}(A \cap B) = \frac{1}{8} = \mathbf{0.1250}.$$

Calcoliamo il prodotto delle probabilità marginali:

$$\mathbb{P}(A) \cdot \mathbb{P}(B) = \frac{1}{2} \cdot \frac{1}{4} = \frac{1}{8}.$$

Poiché  $\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B) = \frac{1}{8}$ , gli eventi  $A$  e  $B$  sono **stocasticamente indipendenti**.

### Problema 5 (Testo Integrato)

Sia  $X$  una v.a. di legge esponenziale di parametro 2 e sia  $Y$  una v.a. di Bernoulli di parametro  $p \in (0, 1)$ . Denotiamo con  $\bar{X}_n$  e  $\bar{Y}_n$  le medie empiriche ottenute prendendo  $n$  copie indipendenti di  $X$  e  $Y$  rispettivamente. Si determini un  $p$  tale che per  $n$  sufficientemente grande  $\bar{X}_n$  e  $\bar{Y}_n$  hanno circa la stessa legge. Di quale legge si tratta?

### Svolgimento Dettagliato

**1. Teorema del Limite Centrale (CLT) per le medie empiriche:** Per campioni i.i.d., il Teorema del Limite Centrale assicura che per  $n$  sufficientemente grande la media empirica di una variabile con media  $\mu$  e varianza  $\sigma^2$  è approssimativamente normale:

$$\bar{W}_n \approx \mathcal{N}\left(\mu_W, \frac{\sigma_W^2}{n}\right).$$

**2. Calcolo dei momenti di  $X$  e  $Y$ :**

- Per  $X \sim \text{Exp}(\lambda = 2)$ :

$$\mathbb{E}[X] = \frac{1}{\lambda} = \frac{1}{2}, \quad \text{Var}(X) = \frac{1}{\lambda^2} = \frac{1}{4}.$$

Quindi, per il CLT:

$$\bar{X}_n \approx \mathcal{N}\left(\frac{1}{2}, \frac{1}{4n}\right).$$

- Per  $Y \sim \text{Bernoulli}(p)$ :

$$\mathbb{E}[Y] = p, \quad \text{Var}(Y) = p(1-p).$$

Quindi, per il CLT:

$$\bar{Y}_n \approx \mathcal{N}\left(p, \frac{p(1-p)}{n}\right).$$

**3. Condizione di uguaglianza asintotica:** Affinché  $\bar{X}_n$  e  $\bar{Y}_n$  abbiano asintoticamente la stessa distribuzione normale, devono coincidere sia il valore atteso sia la varianza:

$$\begin{cases} \mathbb{E}[\bar{X}_n] = \mathbb{E}[\bar{Y}_n] \implies p = \frac{1}{2}, \\ \text{Var}(\bar{X}_n) = \text{Var}(\bar{Y}_n) \implies \frac{1}{4n} = \frac{p(1-p)}{n}. \end{cases}$$

Sostituendo  $p = \frac{1}{2}$  nella seconda equazione:

$$\frac{p(1-p)}{n} = \frac{\frac{1}{2} \cdot \frac{1}{2}}{n} = \frac{1}{4n},$$

che è identicamente verificata.

**Conclusione:** Il valore cercato è  $p = \frac{1}{2} = \mathbf{0.5000}$ , e la legge comune a cui convergono entrambe le medie empiriche per  $n$  grande è la legge **Gaussiana (Normale)**:

$$\mathcal{N}\left(\frac{1}{2}, \frac{1}{4n}\right).$$

**Problema 6 (Testo Integrato)**

I file csv disponibili contengono ciascuno un campione di dati estratto da una popolazione incognita.

- (i) Si presenti un'analisi descrittiva dei dati contenente la numerosità del campione, un istogramma delle frequenze relative e il calcolo di media e varianza campionarie. Si faccia un'opportuna ipotesi sulla legge della popolazione, fissandone il tipo a meno di qualche parametro.
- (ii) Si faccia una stima dei parametri usando degli stimatori puntuali e i dati contenuti nel file.
- (iii) Si determini un intervallo di confidenza a due code del 95% per la media  $\mu$  della popolazione, a partire dall'ipotesi fatta in (i).

**Svolgimento Dettagliato**

**1. Metodologia statistica generale e codice R completo:** Nel contesto di questo quesito d'esame, lo studente carica il dataset personalizzato associato alla propria matricola. Presentiamo lo script R completo per l'analisi descrittiva, l'inferenza parametrica e l'intervallo di confidenza:

```
# 1. Caricamento e Statistica Descrittiva
dati <- read.csv("dati_matricola.csv")
x <- dati[, 1]
n <- length(x)
x_bar <- mean(x)
s2 <- var(x)
s <- sd(x)

cat(sprintf("Numerosita campionaria: n = %d\n", n))
cat(sprintf("Media campionaria: x_bar = %.4f\n", x_bar))
cat(sprintf("Varianza campionaria corretta: s^2 = %.4f\n", s2))
cat(sprintf("Deviazione standard: s = %.4f\n", s))

# Istogramma delle frequenze relative con curva di densita stimata
hist(x, prob = TRUE, col = "lightblue", border = "navy",
     main = "Istogramma Frequenze Relative", xlab = "x", ylab = "Densita
")
lines(density(x), col = "red", lwd = 2)

# 2. Ipotesi sulla popolazione e Stima Puntuale dei Parametri
# In base all'istogramma unimodale e simmetrico, ipotizziamo una legge
# Normale N(mu, sigma^2).
# Stimatori puntuali:
mu_hat <- x_bar
sigma2_hat <- s2

# 3. Intervallo di Confidenza Bilaterale al 95% per mu (varianza
# incognita)
alpha <- 0.05
t_crit <- qt(1 - alpha/2, df = n - 1)
margine_errore <- t_crit * s / sqrt(n)
ic_inf <- x_bar - margine_errore
ic_sup <- x_bar + margine_errore

cat(sprintf("t-critico (g.d.l. = %d): %.4f\n", n - 1, t_crit))
cat(sprintf("Intervallo di Confidenza al 95% per mu: [%.4f, %.4f]\n",
    ic_inf, ic_sup))
```

**2. Formalizzazione teorica dell'Intervallo di Confidenza:** Assumendo che  $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(\mu, \sigma^2)$  con  $\sigma^2$  incognita, la quantità pivotale è:

$$T = \frac{\bar{X}_n - \mu}{S_n/\sqrt{n}} \sim t(n-1),$$

dove  $S_n = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2}$ . L'intervallo di confidenza bilaterale al livello  $1 - \alpha = 0.95$  è:

$$\left[ \bar{X}_n - t_{n-1, 0.025} \frac{S_n}{\sqrt{n}}, \quad \bar{X}_n + t_{n-1, 0.025} \frac{S_n}{\sqrt{n}} \right].$$