

Università di Pisa — Corso di Laurea in Ingegneria Gestionale

Statistica I (A.A. 2019/2020) — III Appello (Luglio 2020)

Soluzione Completa, Rigorosa e Commentata Passo-Passo

Problema 1 (Testo Integrato)

Siano X, Y due variabili aleatorie standardizzate e indipendenti.

- (i) Si calcolino il valore atteso e la varianza di $Z = X + 3Y$ e di $U = XY$.
- (ii) Si dimostri che vale la disuguaglianza $\mathbb{P}(|X + Y| \geq 4) \leq \frac{1}{8}$.
- (iii) Siano U, V indipendenti e di Bernoulli di parametro rispettivamente $\frac{1}{2}$ e $\frac{1}{3}$. Si calcoli la probabilità $\mathbb{P}(X = 2, Y = -\sqrt{3/2})$ nel caso in cui X e Y siano state ottenute standardizzando U e V .

Svolgimento Dettagliato

1. Proprietà di variabili standardizzate indipendenti: Essendo X e Y standardizzate, abbiamo per definizione:

$$\mathbb{E}[X] = 0, \quad \mathbb{E}[Y] = 0, \quad \text{Var}(X) = 1, \quad \text{Var}(Y) = 1 \implies \mathbb{E}[X^2] = 1, \quad \mathbb{E}[Y^2] = 1.$$

L'indipendenza stocastica implica $\text{Cov}(X, Y) = 0$ e $\mathbb{E}[g(X)h(Y)] = \mathbb{E}[g(X)]\mathbb{E}[h(Y)]$.

2. Risoluzione dei quesiti:

- (i) **Valore atteso e varianza di $Z = X + 3Y$ e $U = XY$:**

- Per $Z = X + 3Y$:

$$\mathbb{E}[Z] = \mathbb{E}[X] + 3\mathbb{E}[Y] = 0 + 3(0) = 0,$$

$$\text{Var}(Z) = \text{Var}(X) + 3^2 \text{Var}(Y) = 1 + 9(1) = 10.$$

- Per $U = XY$:

$$\mathbb{E}[U] = \mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y] = 0 \cdot 0 = 0,$$

$$\text{Var}(U) = \mathbb{E}[U^2] - (\mathbb{E}[U])^2 = \mathbb{E}[X^2Y^2] - 0 = \mathbb{E}[X^2]\mathbb{E}[Y^2] = 1 \cdot 1 = 1.$$

- (ii) **Dimostrazione tramite Disuguaglianza di Chebyshev:** Definiamo la variabile aleatoria $W = X + Y$. Calcoliamo media e varianza di W :

$$\mathbb{E}[W] = \mathbb{E}[X] + \mathbb{E}[Y] = 0, \quad \text{Var}(W) = \text{Var}(X) + \text{Var}(Y) = 1 + 1 = 2.$$

La disuguaglianza di Chebyshev stabilisce che per ogni costante $k > 0$:

$$\mathbb{P}(|W - \mathbb{E}[W]| \geq k) \leq \frac{\text{Var}(W)}{k^2}.$$

Applicando la disuguaglianza con $k = 4$ e $\mathbb{E}[W] = 0$:

$$\mathbb{P}(|X + Y| \geq 4) \leq \frac{\text{Var}(W)}{4^2} = \frac{2}{16} = \frac{1}{8}. \quad \blacksquare$$

- (iii) **Calcolo di $\mathbb{P}(X = 2, Y = -\sqrt{3/2})$:** Consideriamo $U \sim \text{Bernoulli}(1/2)$ e $V \sim \text{Bernoulli}(1/3)$:

- $\mathbb{E}[U] = 1/2$, $\text{Var}(U) = 1/4 \implies \sigma_U = 1/2$. La variabile standardizzata è $X = \frac{U-1/2}{1/2} = 2U - 1$. Poiché $U \in \{0, 1\}$, la variabile X può assumere unicamente i valori $\{2(0) - 1, 2(1) - 1\} = \{-1, +1\}$. Il supporto di X è $\text{supp}(X) = \{-1, 1\}$.
- $\mathbb{E}[V] = 1/3$, $\text{Var}(V) = 2/9 \implies \sigma_V = \frac{\sqrt{2}}{3}$. $Y = \frac{V-1/3}{\sqrt{2}/3} \in \left\{-\frac{1}{\sqrt{2}}, \sqrt{2}\right\}$.

Dato che il valore $2 \notin \text{supp}(X)$, l'evento $\{X = 2\}$ è l'evento impossibile ($\mathbb{P}(X = 2) = 0$). Pertanto:

$$\mathbb{P}\left(X = 2, Y = -\sqrt{\frac{3}{2}}\right) \leq \mathbb{P}(X = 2) = 0.$$

Problema 2 (Testo Integrato)

Implementando in R il Metodo Monte Carlo si calcolino approssimativamente:

(i) l'integrale $\int_0^{1/2} \frac{e^x - (\sin(x))^2}{\sqrt{x}} dx$,

(ii) la serie $\sum_{x=0}^{\infty} \frac{2^x \sin(x)}{x!}$.

Svolgimento Dettagliato

(i) **Integrazione Monte Carlo:** Riscriviamo l'integrale $I = \int_0^{1/2} g(x) dx$ come valore atteso rispetto ad una v.a. $X \sim \text{Unif}(0, 1/2)$:

$$I = \frac{1}{2} \int_0^{1/2} g(x) \frac{1}{1/2} dx = \frac{1}{2} \mathbb{E}[g(X)], \quad g(x) = \frac{e^x - \sin^2(x)}{\sqrt{x}}.$$

Valore esatto dell'integrale: $I \approx \mathbf{1.6224}$.

(ii) **Calcolo Monte Carlo della Serie infinita:** Moltiplichiamo e dividiamo la serie per e^2 :

$$S = \sum_{x=0}^{\infty} \frac{2^x \sin(x)}{x!} = e^2 \sum_{x=0}^{\infty} \sin(x) \frac{e^{-2} 2^x}{x!} = e^2 \mathbb{E}[\sin(K)], \quad K \sim \text{Pois}(\lambda = 2).$$

Valore analitico esatto della serie:

$$S = \text{Im} \left(\sum_{x=0}^{\infty} \frac{(2e^i)^x}{x!} \right) = \text{Im} \left(e^{2e^i} \right) = e^{2 \cos(1)} \sin(2 \sin(1)) \approx \mathbf{2.9280}.$$

Script R completo:

```
set.seed(42)
N <- 1000000

# (i) Integrale Monte Carlo
x_unif <- runif(N, min = 0, max = 0.5)
g_x <- (exp(x_unif) - sin(x_unif)^2) / sqrt(x_unif)
I_hat <- 0.5 * mean(g_x)
cat(sprintf("(i) Stima Integrale: %.4f\n", I_hat)) # 1.6224

# (ii) Serie Monte Carlo tramite Poisson(2)
k_pois <- rpois(N, lambda = 2)
S_hat <- exp(2) * mean(sin(k_pois))
cat(sprintf("(ii) Stima Serie: %.4f\n", S_hat)) # 2.9280
```

Problema 3 (Testo Integrato)

Si consideri una popolazione data dalla funzione di ripartizione

$$F_{\theta}(x) = \begin{cases} 1 - e^{-2\theta\sqrt{x}} & \text{se } x > 0, \\ 0 & \text{se } x \leq 0, \end{cases}$$

con $\theta > 0$ parametro incognito. Indichiamo con $X_1, \dots, X_n$ un campione casuale estratto dalla popolazione.

- (i) Si determini la funzione di densità corrispondente a F_{θ} e la funzione di verosimiglianza.
- (ii) Si propongano due stimatori puntuali T_1 e T_2 per il parametro θ , usando rispettivamente il metodo di massima verosimiglianza e il metodo dei momenti.
- (iii) Si utilizzi il metodo dell'inversione per scrivere X come funzione di $U \sim \text{Unif}(0, 1)$, si generi in R un campione con $\theta = 1/2$, $n = 500$ e si riporti la varianza campionaria.

Svolgimento Dettagliato

- (i) **Funzione di Densità e Verosimiglianza:** Derivando la CDF per $x > 0$:

$$f_{\theta}(x) = \frac{d}{dx} F_{\theta}(x) = -e^{-2\theta\sqrt{x}} \left(-2\theta \cdot \frac{1}{2\sqrt{x}} \right) = \frac{\theta}{\sqrt{x}} e^{-2\theta\sqrt{x}} \mathbf{1}_{(0, \infty)}(\mathbf{x}).$$

La funzione di verosimiglianza per un campione i.i.d. $x_1, \dots, x_n$ è:

$$L(\theta) = \prod_{i=1}^n f_{\theta}(x_i) = \theta^n \left(\prod_{i=1}^n x_i^{-1/2} \right) \exp \left(-2\theta \sum_{i=1}^n \sqrt{x_i} \right).$$

- (ii) **Stimatori puntuali T_1 (MLE) e T_2 (Metodo dei Momenti):**

- *Massima Verosimiglianza (T_1):* Calcoliamo la log-verosimiglianza:

$$\ell(\theta) = \log L(\theta) = n \log \theta - \frac{1}{2} \sum_{i=1}^n \log x_i - 2\theta \sum_{i=1}^n \sqrt{x_i}.$$

Derivando rispetto a θ e ponendo a zero:

$$\frac{\partial \ell}{\partial \theta} = \frac{n}{\theta} - 2 \sum_{i=1}^n \sqrt{x_i} = 0 \implies T_1 = \hat{\theta}_{\text{MLE}} = \frac{n}{2 \sum_{i=1}^n \sqrt{x_i}} = \frac{1}{2\sqrt{\bar{X}}}.$$

- *Metodo dei Momenti (T_2):* Operiamo il cambio di variabile $Y = 2\theta\sqrt{X} \implies X = \frac{Y^2}{4\theta^2}$. La CDF di Y è $\mathbb{P}(Y \leq y) = \mathbb{P}(X \leq y^2/(4\theta^2)) = 1 - e^{-y}$, quindi $Y \sim \text{Exp}(1)$. Ne consegue che $\mathbb{E}[Y^2] = \text{Var}(Y) + (\mathbb{E}[Y])^2 = 1 + 1 = 2$.

$$\mathbb{E}[X] = \mathbb{E} \left[\frac{Y^2}{4\theta^2} \right] = \frac{\mathbb{E}[Y^2]}{4\theta^2} = \frac{2}{4\theta^2} = \frac{1}{2\theta^2}.$$

$$\text{Ponendo } \mathbb{E}[X] = \bar{X}_n \implies \frac{1}{2\theta^2} = \bar{X}_n \implies T_2 = \hat{\theta}_{\text{MM}} = \frac{1}{\sqrt{2\bar{X}_n}}.$$

- (iii) **Metodo dell'Inversione e Simulazione in R:** Poniamo $F_{\theta}(X) = U \sim \text{Unif}(0, 1)$:

$$1 - e^{-2\theta\sqrt{X}} = U \implies e^{-2\theta\sqrt{X}} = 1 - U \implies -2\theta\sqrt{X} = \log(1 - U) \implies X = \frac{(-\log(1 - U))^2}{4\theta^2}.$$

Poiché $1 - U \sim \text{Unif}(0, 1)$, possiamo scrivere equivalentemente $X = \frac{(-\log U)^2}{4\theta^2}$.

```

set.seed(42)
n <- 500
theta <- 0.5

# Campionamento tramite metodo dell'inversione
u <- runif(n)
x_campione <- (log(u))^2 / (4 * theta^2)

# Varianza campionaria
var_camp <- var(x_campione)
cat(sprintf("Varianza campionaria ottenuta (n=500, theta=0.5): %.4f\n",
            var_camp))

```

Problema 4 (Testo Integrato)

Si consideri l'esperimento aleatorio in cui per 50 volte viene estratto a caso un numero reale dall'intervallo $-1 \leq x \leq 1$ e poi vengono sommati tutti i numeri estratti.

- (i) Si calcoli approssimativamente la probabilità che il risultato finale sia compreso fra $-\frac{1}{10}$ e $\frac{1}{5}$.
- (ii) Si calcoli la probabilità che non venga mai estratto un numero maggiore di 0.9.

Svolgimento Dettagliato

1. Modello probabilistico: Siano $X_1, \dots, X_{50} \stackrel{\text{i.i.d.}}{\sim} \text{Unif}(-1, 1)$. I parametri del singolo elemento sono:

$$\mathbb{E}[X_i] = 0, \quad \text{Var}(X_i) = \frac{(1 - (-1))^2}{12} = \frac{4}{12} = \frac{1}{3}.$$

Per la somma $S_{50} = \sum_{i=1}^{50} X_i$:

$$\mathbb{E}[S_{50}] = 50(0) = 0, \quad \text{Var}(S_{50}) = 50 \cdot \frac{1}{3} = \frac{50}{3} \approx 16.6667 \implies \sigma_{S_{50}} = \sqrt{\frac{50}{3}} \approx 4.0825.$$

2. Risoluzione dei quesiti:

- (i) **Approssimazione normale della somma (TLC):** Per il Teorema del Limite Centrale, $S_{50} \approx \mathcal{N}(0, 50/3)$. Standardizzando:

$$\begin{aligned}
 \mathbb{P}\left(-\frac{1}{10} \leq S_{50} \leq \frac{1}{5}\right) &= \mathbb{P}\left(\frac{-0.1 - 0}{4.0825} \leq Z \leq \frac{0.2 - 0}{4.0825}\right) \\
 &= \mathbb{P}(-0.0245 \leq Z \leq 0.0490) = \Phi(0.0490) - \Phi(-0.0245) \\
 &= \Phi(0.0490) - (1 - \Phi(0.0245)) = 0.5195 - (1 - 0.5098) = \mathbf{0.0293} \quad (\mathbf{2.93\%}).
 \end{aligned}$$

- (ii) **Probabilità che nessun valore superi 0.9:** Per una singola estrazione uniforme su $[-1, 1]$:

$$\mathbb{P}(X_i \leq 0.9) = \frac{0.9 - (-1)}{1 - (-1)} = \frac{1.9}{2} = 0.95.$$

Per l'indipendenza delle 50 estrazioni:

$$\mathbb{P}\left(\max_{1 \leq i \leq 50} X_i \leq 0.9\right) = (\mathbb{P}(X_1 \leq 0.9))^{50} = (0.95)^{50} \approx \mathbf{0.0769} \quad (\mathbf{7.69\%}).$$

Problema 5 (Testo Integrato)

Si vuole determinare la lunghezza media μ (in cm) delle mine per matita. La misurazione di un campione di 10 mine ha fornito i dati del file csv.

- (i) Si calcolino media e varianza campionaria delle misure ottenute utilizzando R.
- (ii) Si determini un intervallo di confidenza di livello 0.95 per μ basandosi sul campione di dati.
- (iii) La ditta di produzione dichiara una lunghezza media di 13 cm. Si decida tramite un test al livello del 5% se le misurazioni effettuate sul campione supportano tale affermazione o meno.

Svolgimento Dettagliato

1. Procedura formale di inferenza (*t*-Student a 9 g.d.l.): Assumendo che le lunghezze seguano una distribuzione normale $\mathcal{N}(\mu, \sigma^2)$ con varianza non nota, si utilizzano la media campionaria $\bar{X}_{10}$ e la varianza campionaria corretta S_{10}^2 .

2. Codice R per l'analisi completa e la verifica delle ipotesi:

```
# 1. Caricamento dati e statistiche descrittive
dati_mine <- read.csv("dati_mine.csv")
x <- dati_mine[, 1]
n <- length(x) # n = 10
x_bar <- mean(x)
s2 <- var(x)
s <- sd(x)

cat(sprintf("Media campionaria: %.4f cm\n", x_bar))
cat(sprintf("Varianza campionaria: %.4f cm^2\n", s2))

# 2. Intervallo di Confidenza al 95% per mu
alpha <- 0.05
t_crit <- qt(1 - alpha/2, df = n - 1) # t_0.025, 9 = 2.2622
se_mean <- s / sqrt(n)
ic <- c(x_bar - t_crit * se_mean, x_bar + t_crit * se_mean)
cat(sprintf("IC 95%: [%.4f, %.4f]\n", ic[1], ic[2]))

# 3. Test Bilaterale H0: mu = 13 vs H1: mu != 13 al livello 5%
mu_0 <- 13
t_stat <- (x_bar - mu_0) / se_mean
p_value <- 2 * (1 - pt(abs(t_stat), df = n - 1))

cat(sprintf("Statistica test t: %.4f, Valore Critico: +/-%.4f\n", t_stat, t_crit))
cat(sprintf("p-value: %.4f\n", p_value))
if (abs(t_stat) > t_crit) {
  cat("Conclusione: Rifiutiamo H0. Le misurazioni NON supportano l'
    affermazione della ditta.\n")
} else {
  cat("Conclusione: Non rifiutiamo H0. I dati sono compatibili con una
    media di 13 cm.\n")
}
```