

Università di Pisa — Corso di Laurea in Ingegneria Gestionale

Statistica I (A.A. 2020/2021) — Appello del 15/09/2021

Soluzione Completa, Rigorosa e Commentata Passo-Passo

Problema 1 (Testo Integrato)

Si considerino due variabili aleatorie X, Y , entrambe a valori in $\{0, 1\}$ e tali che

$$\mathbb{P}(X = 0) = \frac{1}{2}, \quad \mathbb{P}(Y = 0 \mid X = 0) = \frac{1}{3}, \quad \mathbb{P}(Y = 1 \mid X = 1) = \frac{1}{4}.$$

1. Scrivere la funzione di massa congiunta di (X, Y) . Dire se Y è Bernoulli e calcolare $\mathbb{P}(Y = 1)$.
2. Calcolare le deviazioni standard σ_X, σ_Y e il coefficiente di correlazione $\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}$.
3. Dire se le variabili X ed U sono correlate, dove si definisce $U = Y - \rho_{XY} \frac{\sigma_Y}{\sigma_X} X$.

Svolgimento Dettagliato

1. Costruzione della PMF congiunta di (X, Y) : Poiché $\mathbb{P}(X = 0) = 1/2$, abbiamo $\mathbb{P}(X = 1) = 1 - 1/2 = 1/2$. Dalle probabilità condizionate:

$$\mathbb{P}(X = 0, Y = 0) = \mathbb{P}(Y = 0 \mid X = 0)\mathbb{P}(X = 0) = \frac{1}{3} \cdot \frac{1}{2} = \frac{1}{6},$$

$$\mathbb{P}(X = 0, Y = 1) = \mathbb{P}(Y = 1 \mid X = 0)\mathbb{P}(X = 0) = \left(1 - \frac{1}{3}\right) \frac{1}{2} = \frac{2}{3} \cdot \frac{1}{2} = \frac{1}{3} = \frac{2}{6},$$

$$\mathbb{P}(X = 1, Y = 1) = \mathbb{P}(Y = 1 \mid X = 1)\mathbb{P}(X = 1) = \frac{1}{4} \cdot \frac{1}{2} = \frac{1}{8},$$

$$\mathbb{P}(X = 1, Y = 0) = \mathbb{P}(Y = 0 \mid X = 1)\mathbb{P}(X = 1) = \left(1 - \frac{1}{4}\right) \frac{1}{2} = \frac{3}{4} \cdot \frac{1}{2} = \frac{3}{8}.$$

Tabella della funzione di massa congiunta:

$p_{X,Y}(x, y)$	$y = 0$	$y = 1$	$p_X(x)$
$x = 0$	1/6	1/3	1/2
$x = 1$	3/8	1/8	1/2
$p_Y(y)$	13/24	11/24	1

La variabile Y assume solo i valori $\{0, 1\}$, quindi è una variabile di **Bernoulli** con parametro:

$$p_Y = \mathbb{P}(Y = 1) = \frac{1}{3} + \frac{1}{8} = \frac{11}{24} \approx 0.4583.$$

2. Deviazioni standard e Coefficiente di Correlazione:

- Per $X \sim \text{Bernoulli}(1/2)$:

$$\mathbb{E}[X] = \frac{1}{2}, \quad \text{Var}(X) = \frac{1}{2} \left(1 - \frac{1}{2}\right) = \frac{1}{4} \implies \sigma_X = \frac{1}{2} = 0.5000.$$

- Per $Y \sim \text{Bernoulli}(11/24)$:

$$\mathbb{E}[Y] = \frac{11}{24}, \quad \text{Var}(Y) = \frac{11}{24} \cdot \frac{13}{24} = \frac{143}{576} \implies \sigma_Y = \frac{\sqrt{143}}{24} \approx 0.4983.$$

- Valore atteso congiunto e Covarianza:

$$\mathbb{E}[XY] = 1 \cdot 1 \cdot \mathbb{P}(X = 1, Y = 1) = \frac{1}{8}.$$

$$\text{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] = \frac{1}{8} - \left(\frac{1}{2}\right)\left(\frac{11}{24}\right) = \frac{1}{8} - \frac{11}{48} = \frac{6-11}{48} = -\frac{5}{48} \approx -0.1042.$$

- Coefficiente di correlazione lineare ρ_{XY} :

$$\rho_{XY} = \frac{\text{Cov}(\mathbf{X}, \mathbf{Y})}{\sigma_X \sigma_Y} = \frac{-\frac{5}{48}}{\left(\frac{1}{2}\right)\left(\frac{\sqrt{143}}{24}\right)} = \frac{-\frac{5}{48}}{\frac{\sqrt{143}}{48}} = -\frac{5}{\sqrt{143}} \approx -0.4181.$$

3. Correlazione tra X e U : Poniamo $\beta = \rho_{XY} \frac{\sigma_Y}{\sigma_X} = \frac{\text{Cov}(X, Y)}{\text{Var}(X)}$. Calcoliamo la covarianza tra X e $U = Y - \beta X$:

$$\text{Cov}(X, U) = \text{Cov}(X, Y - \beta X) = \text{Cov}(X, Y) - \beta \text{Var}(X) = \text{Cov}(X, Y) - \frac{\text{Cov}(X, Y)}{\text{Var}(X)} \text{Var}(X) = 0.$$

Poiché la covarianza è esattamente nulla, le variabili X ed U sono **completamente scorrelate** ($\rho_{XU} = 0$).

Problema 2 (Testo Integrato)

Siano $X_1, X_2, \dots, X_{42}$ variabili aleatorie indipendenti, ciascuna con legge uniforme $\text{Unif}(0, 1)$, e si ponga $Y_i = -\log(X_i)$, per $i = 1, \dots, 42$.

1. Determinare la funzione di ripartizione, la densità, media e varianza di Y_1 .
2. Scrivere dei comandi R per simulare 420 realizzazioni indipendenti di variabili con la stessa legge di Y_1 e calcolare la media empirica dei dati generati (riportare il risultato).
3. Posta $U = (X_1 \cdot X_2 \cdots X_{42})^{1/42}$, cosa possiamo dire della funzione di ripartizione di U , ad esempio di $\mathbb{P}(U \leq 0.3)$?

Svolgimento Dettagliato

1. **Legge di $Y_1 = -\log(X_1)$:** Poiché $X_1 \sim \text{Unif}(0, 1)$, per ogni $y > 0$:

$$F_{Y_1}(y) = \mathbb{P}(-\log(X_1) \leq y) = \mathbb{P}(\log(X_1) \geq -y) = \mathbb{P}(X_1 \geq e^{-y}) = 1 - e^{-y}.$$

Per $y \leq 0$, $F_{Y_1}(y) = 0$. Derivando:

$$f_{Y_1}(y) = e^{-y} \mathbf{1}_{(0, \infty)}(y) \implies \mathbf{Y}_1 \sim \text{Exp}(\lambda = 1).$$

I momenti teorici sono:

$$\mathbb{E}[\mathbf{Y}_1] = 1, \quad \text{Var}(\mathbf{Y}_1) = 1.$$

2. **Simulazione in R:**

```
set.seed(42)
# Generazione di 420 realizzazioni iid da Exp(1)
y_samples <- -log(runif(420))
media_empirica <- mean(y_samples)
cat(sprintf("Media empirica (420 campioni): %.4f\n", media_empirica)) #
~ 1.0063
```

3. Distribuzione di U e calcolo di $\mathbb{P}(U \leq 0.3)$ tramite TLC: Prendendo il logaritmo naturale di U :

$$-\log(U) = -\log\left(\prod_{i=1}^{42} X_i^{1/42}\right) = \frac{1}{42} \sum_{i=1}^{42} (-\log X_i) = \frac{1}{42} \sum_{i=1}^{42} Y_i = \bar{Y}_{42}.$$

La media empirica $\bar{Y}_{42}$ di 42 esponenziali standard ha media $\mathbb{E}[\bar{Y}_{42}] = 1$ e varianza $\text{Var}(\bar{Y}_{42}) = 1/42$. Per il Teorema del Limite Centrale, $\bar{Y}_{42} \approx \mathcal{N}\left(1, \frac{1}{42}\right)$. L'evento $\{U \leq 0.3\}$ equivale a:

$$-\log(U) \geq -\log(0.3) \approx 1.2040.$$

Standardizzando:

$$\mathbb{P}(U \leq 0.3) = \mathbb{P}(\bar{Y}_{42} \geq 1.2040) \approx 1 - \Phi\left(\frac{1.2040 - 1}{\sqrt{1/42}}\right) = 1 - \Phi(1.2040 \cdot \sqrt{42} - \sqrt{42}) = 1 - \Phi(1.3219).$$

Dalle tavole della normale standard:

$$1 - \Phi(1.3219) \approx 1 - 0.9069 = \mathbf{0.0931} \quad (\mathbf{9.31\%}).$$

Problema 3 (Testo Integrato)

Un montacarichi ha una portata di 2000 kg. Sapendo che il peso medio di una persona adulta è 76.2 kg, con deviazione standard 11.4 kg, stimare con quale probabilità il peso combinato di 25 persone può superare la portata del montacarichi. Si indichi con P il peso totale delle 25 persone. Indicare i comandi R per generare 1000 realizzazioni di P e attraverso di esse valutare numericamente la probabilità richiesta.

Svolgimento Dettagliato

1. Calcolo analitico tramite Teorema del Limite Centrale: Siano $W_1, \dots, W_{25}$ i pesi delle 25 persone, con $\mathbb{E}[W_i] = \mu = 76.2$ kg e $\sigma = 11.4$ kg. Il peso complessivo è $P = \sum_{i=1}^{25} W_i$.

$$\mathbb{E}[P] = 25 \cdot 76.2 = \mathbf{1905} \text{ kg},$$

$$\text{Var}(P) = 25 \cdot (11.4)^2 = 25 \cdot 129.96 = 3249 \implies \sigma_P = \sqrt{3249} = 5 \cdot 11.4 = \mathbf{57} \text{ kg}.$$

Applicando il TLC, $P \approx \mathcal{N}(1905, 57^2)$. La probabilità di sovraccarico è:

$$\mathbb{P}(P > 2000) = \mathbb{P}\left(\frac{P - 1905}{57} > \frac{2000 - 1905}{57}\right) = \mathbb{P}(Z > 1.6667) = 1 - \Phi(1.6667).$$

Dalle tavole della normale standard $\Phi(1.6667) \approx 0.9522$:

$$\mathbb{P}(P > 2000) \approx 1 - 0.9522 = \mathbf{0.0478} \quad (\mathbf{4.78\%}).$$

2. Implementazione della simulazione Monte Carlo in R:

```
set.seed(42)
N_sim <- 1000

# Simulazione di 1000 carichi da 25 persone
# Assumendo pesi gaussiani N(76.2, 11.4^2)
pesi_totali <- replicate(N_sim, sum(rnorm(25, mean = 76.2, sd = 11.4)))

# Stima della probabilità di superamento portata
p_sovraccarico <- mean(pesi_totali > 2000)
cat(sprintf("Probabilità stimata di sovraccarico: %.4f\n", p_
sovraccarico)) # ~ 0.0480
```

Problema 4 (Testo Integrale)

Si considerino le variabili aleatorie indipendenti $X_1, \dots, X_n$ con densità

$$f(x) = \begin{cases} \frac{a-|x|}{2a-1}, & -1 < x < 1, \\ 0, & \text{altrimenti,} \end{cases}$$

dove $a \geq 1$ è un parametro.

1. Determinare la funzione di ripartizione di X_1 .
2. Determinare uno stimatore di a realizzato con il metodo dei momenti.
3. Si valuti lo stimatore trovato con i dati disponibili nel file **Problema4.csv**.

Svolgimento Dettagliato

1. **Funzione di ripartizione $F(x)$:** Per $x \in (-1, 0]$:

$$F(x) = \int_{-1}^x \frac{a - (-t)}{2a - 1} dt = \frac{1}{2a - 1} \left[at + \frac{t^2}{2} \right]_{-1}^x = \frac{ax + \frac{x^2}{2} + a - \frac{1}{2}}{2a - 1}.$$

Per $x \in [0, 1)$:

$$F(x) = F(0) + \int_0^x \frac{a - t}{2a - 1} dt = \frac{a - 1/2}{2a - 1} + \frac{ax - x^2/2}{2a - 1} = \frac{1}{2} + \frac{ax - \frac{x^2}{2}}{2a - 1}.$$

Chiaramente $F(x) = 0$ per $x \leq -1$ e $F(x) = 1$ per $x \geq 1$.

2. **Metodo dei Momenti per a :** Essendo $f(x)$ pari, il momento primo è identicamente nullo ($\mathbb{E}[X] = 0$) e non dipende da a . Ricorriamo al momento secondo $\mathbb{E}[X^2]$:

$$\mathbb{E}[X^2] = 2 \int_0^1 x^2 \frac{a - x}{2a - 1} dx = \frac{2}{2a - 1} \left[\frac{ax^3}{3} - \frac{x^4}{4} \right]_0^1 = \frac{2}{2a - 1} \left(\frac{a}{3} - \frac{1}{4} \right) = \frac{4a - 3}{6(2a - 1)}.$$

Ponendo $\mathbb{E}[X^2] = m_2 := \frac{1}{n} \sum_{i=1}^n X_i^2$:

$$\frac{4a - 3}{12a - 6} = m_2 \implies 4a - 3 = 12m_2 a - 6m_2 \implies a(4 - 12m_2) = 3 - 6m_2 \implies \hat{a}_{MM} = \frac{3 - 6m_2}{4 - 12m_2}.$$

3. **Valutazione empirica con R:**

```
dati <- read.csv("Problema4.csv")
x <- dati[, 1]
m2 <- mean(x^2)
a_hat <- (3 - 6 * m2) / (4 - 12 * m2)
cat(sprintf("Momento secondo campionario m2: %.4f\n", m2))
cat(sprintf("Stima del parametro a: %.4f\n", a_hat))
```

Problema 5 (Testo Integrale)

Duecento autovetture dello stesso modello circolano su uno stesso percorso cittadino per valutare la percorrenza chilometrica per litro di carburante. Al termine dell'esperimento si trova il valore $\bar{x} = 8.82$ km per la media empirica della percorrenza con un litro di carburante, e il valore $s = 0.921$ km per la deviazione standard campionaria. Si consideri il modello di 200 variabili

aleatorie gaussiane $\mathcal{N}(\mu, \sigma^2)$.

1. Determinare un intervallo di confidenza al 95% per la percorrenza chilometrica media μ .
2. La casa produttrice ha dichiarato che l'autovettura percorre 9 km/l. Valutare la correttezza di questa affermazione al livello dell'1%.

Svolgimento Dettagliato

1. Intervallo di Confidenza al 95% per μ ($n = 200$): Data la grande numerosità campionaria ($n = 200 > 30$), per il TLC la quantità pivotale $Z = \frac{\bar{X}_n - \mu}{S_n/\sqrt{n}}$ segue una distribuzione normale standard $\mathcal{N}(0, 1)$. L'errore standard della media è:

$$SE(\bar{X}_n) = \frac{s}{\sqrt{n}} = \frac{0.921}{\sqrt{200}} = \frac{0.921}{14.1421} \approx \mathbf{0.06512} \text{ km/l.}$$

Il quantile critico per $\alpha = 0.05$ (bilaterale) è $z_{0.025} = 1.960$. Il margine d'errore è:

$$ME = 1.960 \cdot 0.06512 \approx 0.1276 \text{ km/l.}$$

L'intervallo di confidenza al 95% è:

$$IC_{95\%}(\mu) = [8.82 - 0.1276, 8.82 + 0.1276] = [\mathbf{8.6924}, \mathbf{8.9476}] \text{ km/l.}$$

2. Verifica dell'ipotesi al livello $\alpha = 0.01$: Formuliamo il test d'ipotesi bilaterale:

$$H_0 : \mu = 9.00 \quad \text{vs} \quad H_1 : \mu \neq 9.00.$$

Calcoliamo la statistica test Z :

$$Z_{\text{oss}} = \frac{\bar{x} - \mu_0}{SE(\bar{X}_n)} = \frac{8.82 - 9.00}{0.06512} = \frac{-0.18}{0.06512} = \mathbf{-2.7641}.$$

Per un livello di significatività $\alpha = 0.01$, i quantili critici della normale standard sono $\pm z_{0.005} = \pm 2.5758$. La regione di rifiuto è $W = (-\infty, -2.5758] \cup [2.5758, +\infty)$. Poiché $|Z_{\text{oss}}| = 2.7641 > 2.5758$, la statistica test cade all'interno della regione critica. Il p -value associato è:

$$p\text{-value} = 2 \cdot (1 - \Phi(2.7641)) \approx 2 \cdot (1 - 0.99715) = \mathbf{0.0057} \quad (\mathbf{0.57\%} < 1\%).$$

Conclusione del test: Al livello di significatività dell'1%, **rifiutiamo l'ipotesi nulla H_0** . I dati empirici smentiscono l'affermazione del produttore: la percorrenza media reale è significativamente inferiore a 9 km/l.