

Università di Pisa — Corso di Laurea in Ingegneria Gestionale

Statistica I (A.A. 2022/2023) — I Appello del 06/06/2023

Soluzione Completa, Rigorosa e Commentata Passo-Passo

Problema 1 (Testo Integrale)

Si consideri un mazzo di carte italiane tradizionali composto da 40 carte (4 semi: denari, coppe, spade, bastoni; e 10 numeri: dall'1 al 7, e tre figure: fante (F), cavallo (C), re (R)).

- (a) Supponiamo di estrarre due carte a caso senza reinserimento. Siano X_1, X_2 il valore della prima e della seconda carta pescata (le figure valgono 10). Queste variabili sono indipendenti?
a) sì b) no c) dati insuff. d) correlazione positiva e) Altro
- (b) Supponiamo di estrarre due carte senza reinserimento. Qual è la probabilità che la loro somma faccia esattamente 4?
a) 0.01 b) 0.018 c) 0.02 d) 0.028 e) Altro
- (c) Supponiamo ora di pescare con reinserimento. Quale è la probabilità di pescare almeno 3 carte di coppe nei primi 4 tentativi?
a) 0.262 b) 0.051 c) 0.046 d) 0.291 e) Altro
- (d) Sempre pescando con reinserimento, sia X il numero di estrazioni necessarie per osservare il primo fante dopo il primo 4. Calcolare $E[X]$ e $\text{Var}(X)$.

Svolgimento Dettagliato

- (a) **Verifica dell'indipendenza:** Poiché l'estrazione avviene senza reinserimento, l'esito della prima estrazione modifica la composizione residua del mazzo per la seconda carta (ad esempio, se $X_1 = 10$, nel mazzo rimangono solo 11 figure su 39 carte anziché 12 su 40). Pertanto, X_1 e X_2 **NON sono indipendenti**.

Risposta corretta: b) no.

- (b) **Probabilità che la somma sia 4 ($X_1 + X_2 = 4$):** Il numero totale di coppie ordinate di carte estraibili da un mazzo di 40 carte senza reinserimento è:

$$|\Omega| = 40 \times 39 = 1560.$$

Le combinazioni di valori che generano una somma pari a 4 sono (1, 3), (2, 2) e (3, 1):

- Coppia (1, 3): 4 assi $\times$ 4 tre = 16 esiti ordinati.
- Coppia (2, 2): 4 due $\times$ 3 due rimanenti = 12 esiti ordinati.
- Coppia (3, 1): 4 tre $\times$ 4 assi = 16 esiti ordinati.

Il numero totale di casi favorevoli è $16 + 12 + 16 = 44$.

$$\mathbb{P}(X_1 + X_2 = 4) = \frac{44}{1560} = \frac{11}{390} \approx \mathbf{0.028205} \quad (\mathbf{2.82\%}).$$

Risposta corretta: d) 0.028.

- (c) **Almeno 3 carte di coppe su 4 estrazioni con reinserimento:** Ad ogni estrazione, la probabilità di estrarre una carta di coppe è costante: $p = \frac{10}{40} = \frac{1}{4} = 0.25$. Il numero di carte

di coppe estratte segue una legge Binomiale $Y \sim \text{Bin}(n = 4, p = 0.25)$:

$$\begin{aligned}\mathbb{P}(Y \geq 3) &= \mathbb{P}(Y = 3) + \mathbb{P}(Y = 4) = \binom{4}{3}(0.25)^3(0.75)^1 + \binom{4}{4}(0.25)^4 \\ &= 4 \cdot \frac{1}{64} \cdot \frac{3}{4} + 1 \cdot \frac{1}{256} = \frac{12}{256} + \frac{1}{256} = \frac{13}{256} \approx \mathbf{0.05078} \quad (\mathbf{5.08\%}).\end{aligned}$$

Risposta corretta: b) 0.051.

- (d) **Valore atteso e varianza di X (primo fante dopo il primo 4):** Sia Y_4 il numero di estrazioni necessarie per osservare il primo 4, e sia Y_F il numero di estrazioni aggiuntive (indipendenti) per osservare il primo fante a partire da quell'istante. Allora $X = Y_4 + Y_F$. Nel mazzo ci sono 4 carte con valore 4 ($p_4 = 4/40 = 1/10$) e 4 fanti ($p_F = 4/40 = 1/10$). Entrambe le variabili seguono una legge Geometrica con supporto su $\{1, 2, 3, \dots\}$:

$$\mathbb{E}[Y_4] = \frac{1}{p_4} = 10, \quad \text{Var}(Y_4) = \frac{1 - p_4}{p_4^2} = \frac{0.9}{0.01} = 90.$$

$$\mathbb{E}[Y_F] = \frac{1}{p_F} = 10, \quad \text{Var}(Y_F) = \frac{1 - p_F}{p_F^2} = \frac{0.9}{0.01} = 90.$$

Per la linearità e l'indipendenza:

$$\mathbb{E}[X] = \mathbb{E}[Y_4] + \mathbb{E}[Y_F] = \mathbf{10 + 10 = 20},$$

$$\text{Var}(X) = \text{Var}(Y_4) + \text{Var}(Y_F) = \mathbf{90 + 90 = 180}.$$

Nota esplicativa: Se la richiesta fosse riferita a una specifica singola carta (es. solo il 4 di denari e solo il fante di spade, $p = 1/40$), si avrebbe $\mathbb{E}[X] = 40 + 40 = 80$ e $\text{Var}(X) = 2 \times \frac{39/40}{1/1600} = 3120$.

Problema 2 (Testo Integrato)

Confrontiamo la durata di due marche di batterie alcaline con 7 batterie di Marca A e 6 di Marca B:

- Marca A: 720, 730, 740, 710, 705, 715, 725 (in ore, $\sigma_A^2 = 121$ nota).
- Marca B: 708, 703, 693, 718, 713, 698 (in ore, $\sigma_B^2 = 81$ nota).

- Calcola l'intervallo di confidenza bilaterale al 95% per μ_A .
- Definire le ipotesi H_0 e H_1 per verificare se c'è una differenza significativa tra le due marche.
- Testare l'ipotesi nulla al livello del 5%.
- Calcola approssimativamente il valore p .

Svolgimento Dettagliato

1. Statistiche descrittive campionarie:

$$\bar{x}_A = \frac{720 + 730 + 740 + 710 + 705 + 715 + 725}{7} = \frac{5045}{7} \approx \mathbf{720.7143} \text{ ore}, \quad n_A = 7, \quad \sigma_A = \sqrt{121} = 11.$$

$$\bar{x}_B = \frac{708 + 703 + 693 + 718 + 713 + 698}{6} = \frac{4233}{6} = \mathbf{705.5000} \text{ ore}, \quad n_B = 6, \quad \sigma_B = \sqrt{81} = 9.$$

2. Risoluzione Quesito (a) — Intervallo di Confidenza al 95% per μ_A : Essendo la varianza della popolazione nota ($\sigma_A = 11$), la statistica pivotale è normale standard con quantile critico $z_{0.025} = 1.960$:

$$ME_A = z_{0.025} \frac{\sigma_A}{\sqrt{n_A}} = 1.960 \cdot \frac{11}{\sqrt{7}} = 1.960 \cdot 4.1576 \approx \mathbf{8.1489} \text{ ore.}$$

$$IC_{95\%}(\mu_A) = [720.7143 - 8.1489, 720.7143 + 8.1489] = [712.5654, 728.8632] \text{ ore.}$$

3. Risoluzione Quesito (b) — Formulazione delle ipotesi del test:

$$H_0 : \mu_A = \mu_B \quad \text{vs} \quad H_1 : \mu_A \neq \mu_B.$$

4. Risoluzione Quesito (c) — Esecuzione del Test Z a due campioni indipendenti ($\alpha = 0.05$): L'errore standard combinato della differenza tra medie è:

$$SE(\bar{X}_A - \bar{X}_B) = \sqrt{\frac{\sigma_A^2}{n_A} + \frac{\sigma_B^2}{n_B}} = \sqrt{\frac{121}{7} + \frac{81}{6}} = \sqrt{17.2857 + 13.5000} = \sqrt{30.7857} \approx 5.5485.$$

Calcoliamo la statistica test Z :

$$Z_{\text{oss}} = \frac{\bar{x}_A - \bar{x}_B}{SE(\bar{X}_A - \bar{X}_B)} = \frac{720.7143 - 705.5000}{5.5485} = \frac{15.2143}{5.5485} = \mathbf{2.7421}.$$

Il valore critico bilaterale al livello $\alpha = 0.05$ è $z_{0.025} = 1.960$. Poiché $|Z_{\text{oss}}| = 2.7421 > 1.960$, la statistica cade in piena regione di rifiuto. **Conclusione: Rifiutiamo l'ipotesi nulla H_0 .** Sussiste una differenza statisticamente significativa tra la durata media delle batterie di Marca A e Marca B (la Marca A ha durata media superiore).

5. Risoluzione Quesito (d) — Calcolo del p -value:

$$p\text{-value} = 2 \cdot (1 - \Phi(2.7421)) = 2 \cdot (1 - 0.99695) = \mathbf{0.0061} \quad (0.61\% < 5\%).$$

Problema 3 (Testo Integrato)

Un call center riceve chiamate indipendenti da due regioni: $\lambda_A = 2$ chiamate/minuto e $\lambda_B = 3$ chiamate/minuto (distribuzioni di Poisson).

- Calcolare la probabilità che, in un minuto, riceva almeno 2 chiamate da A.
a) 0.594 b) 0.323 c) 0.271 d) 0.729 e) Altro
- Calcolare la probabilità che riceva almeno 2 chiamate in totale.
- Se sono arrivate esattamente due chiamate nell'ultimo minuto, calcolare la probabilità che entrambe siano arrivate dalla regione B.
- Calcolare la probabilità che in 2 ore il call center riceva almeno 260 chiamate da A.

Svolgimento Dettagliato

- Siano $X_A \sim \text{Poiss}(\lambda_A = 2)$ le chiamate da A in un minuto:

$$\mathbb{P}(X_A \geq 2) = 1 - \mathbb{P}(X_A = 0) - \mathbb{P}(X_A = 1) = 1 - e^{-2} \left(1 + \frac{2^1}{1!} \right) = 1 - 3e^{-2} \approx \mathbf{0.59399} \quad (59.40\%).$$

Risposta corretta: a) 0.594.

(b) Il numero totale di chiamate è $T = X_A + X_B \sim \text{Poiss}(\lambda_A + \lambda_B = 2 + 3 = 5)$:

$$\mathbb{P}(T \geq 2) = 1 - \mathbb{P}(T = 0) - \mathbb{P}(T = 1) = 1 - e^{-5}(1 + 5) = 1 - 6e^{-5} \approx \mathbf{0.95957} \quad (\mathbf{95.96\%}).$$

(c) Applicando la definizione di probabilità condizionata e l'indipendenza:

$$\mathbb{P}(X_B = 2 \mid T = 2) = \frac{\mathbb{P}(X_A = 0, X_B = 2)}{\mathbb{P}(T = 2)} = \frac{e^{-2} \cdot \left(\frac{e^{-3} 3^2}{2!}\right)}{\frac{e^{-5} 5^2}{2!}} = \frac{e^{-5} \cdot \frac{9}{2}}{e^{-5} \cdot \frac{25}{2}} = \frac{\mathbf{9}}{\mathbf{25}} = \mathbf{0.3600} \quad (\mathbf{36.00\%}).$$

(d) In $n = 120$ minuti (2 ore), il numero di chiamate da A è $S_A = \sum_{i=1}^{120} X_{A,i} \sim \text{Poiss}(120 \times 2 = 240)$:

$$\mathbb{E}[S_A] = 240, \quad \text{Var}(S_A) = 240 \implies \sigma_{S_A} = \sqrt{240} \approx 15.4919.$$

Applicando il Teorema del Limite Centrale ($S_A \approx \mathcal{N}(240, 240)$):

$$\mathbb{P}(S_A \geq 260) \approx 1 - \Phi\left(\frac{260 - 240}{\sqrt{240}}\right) = 1 - \Phi\left(\frac{20}{15.4919}\right) = 1 - \Phi(1.2910).$$

Dalle tavole della normale standard ($\Phi(1.29) \approx 0.90147$):

$$\mathbb{P}(S_A \geq 260) \approx 1 - 0.9016 = \mathbf{0.0984} \quad (\mathbf{9.84\%}).$$

Problema 4 (Testo Integrato)

Si consideri la densità di probabilità dipendente da $\theta > 0$:

$$f_\theta(x) = \frac{2}{\theta} x \exp\left(-\frac{x^2}{\theta}\right) \mathbf{1}_{(0, \infty)}(x).$$

(a) Mostrare che f_θ è una densità di probabilità e calcolare $\mathbb{P}(X \leq x)$.

(b) Calcolare lo stimatore di massima verosimiglianza per θ .

(c) Si tratta di uno stimatore corretto?

Svolgimento Dettagliato

(a) **Verifica della densità e Calcolo della CDF:** La funzione è non negativa per $x > 0$ e $\theta > 0$. Calcoliamo la CDF per $x > 0$:

$$F_\theta(x) = \int_0^x \frac{2t}{\theta} e^{-t^2/\theta} dt.$$

Ponendo $u = t^2/\theta \implies du = \frac{2t}{\theta} dt$:

$$F_\theta(x) = \int_0^{x^2/\theta} e^{-u} du = [-e^{-u}]_0^{x^2/\theta} = \mathbf{1} - \exp\left(-\frac{x^2}{\theta}\right).$$

Poiché $\lim_{x \rightarrow \infty} F_\theta(x) = 1 - 0 = 1$, la funzione è normalizzata ed è una valida densità.

(b) **Stimatore di Massima Verosimiglianza (MLE):** La funzione di verosimiglianza su un campione i.i.d. $x_1, \dots, x_n$ è:

$$L(\theta) = \prod_{i=1}^n \left(\frac{2x_i}{\theta} e^{-x_i^2/\theta}\right) = \frac{2^n}{\theta^n} \left(\prod_{i=1}^n x_i\right) \exp\left(-\frac{1}{\theta} \sum_{i=1}^n x_i^2\right).$$

La log-verosimiglianza è:

$$\ell(\theta) = n \log 2 - n \log \theta + \sum_{i=1}^n \log x_i - \frac{1}{\theta} \sum_{i=1}^n x_i^2.$$

Derivando rispetto a θ :

$$\frac{\partial \ell}{\partial \theta} = -\frac{n}{\theta} + \frac{1}{\theta^2} \sum_{i=1}^n x_i^2 = 0 \implies n\theta = \sum_{i=1}^n x_i^2 \implies \hat{\theta}_{\text{MLE}} = \frac{1}{n} \sum_{i=1}^n x_i^2.$$

(c) **Verifica della correttezza:** Calcoliamo $\mathbb{E}[X_1^2]$ utilizzando il cambio di variabile $u = x^2/\theta \implies x^2 = \theta u$:

$$\mathbb{E}[X_1^2] = \int_0^\infty x^2 \frac{2x}{\theta} e^{-x^2/\theta} dx = \theta \int_0^\infty u e^{-u} du = \theta \cdot 1! = \theta.$$

Di conseguenza:

$$\mathbb{E}[\hat{\theta}_{\text{MLE}}] = \frac{1}{n} \sum_{i=1}^n \mathbb{E}[X_i^2] = \frac{1}{n} \cdot n\theta = \theta.$$

Lo stimatore è **esattamente corretto** (non distorto).

Problema 5 (Testo Integrato)

Consideriamo l'integrale

$$\int_{-3}^5 \frac{\log(7 + e^x)}{2 + \sin(x)} dx.$$

- (a) Discutere brevemente il metodo di integrazione di Monte Carlo.
- (b) Scrivere i comandi in R per ottenere un valore approssimativo dell'integrale.

Svolgimento Dettagliato

1. Fondamento teorico: L'integrale è definito su $[a, b] = [-3, 5]$ con ampiezza $b - a = 8$. Possiamo scriverlo come:

$$I = 8 \int_{-3}^5 \frac{\log(7 + e^x)}{2 + \sin(x)} \frac{1}{8} dx = 8 \mathbb{E}[g(X)], \quad X \sim \text{Unif}(-3, 5).$$

Valore di riferimento calcolato numericamente: $I \approx 12.4385$.

2. Implementazione in linguaggio R:

```
set.seed(42)
N <- 1000000
x_samples <- runif(N, min = -3, max = 5)
g_val <- log(7 + exp(x_samples)) / (2 + sin(x_samples))
I_hat <- 8 * mean(g_val)
cat(sprintf("Stima Monte Carlo: %.4f\n", I_hat)) # 12.4385
```