

STATISTICA E CALCOLO DELLE PROBABILITÀ

CORSO DI LAUREA IN INGEGNERIA GESTIONALE

Nicola Beccaceci

29 agosto 2026

Indice

Guida alla Consultazione	v
Programma del Corso e Mappa Concettuale	vii
1 Statistica Descrittiva	1
1.1 Database Empirico, Rilevazione dei Dati e Distribuzioni di Frequenza	1
1.2 Indici di Posizione e Tendenza Centrale	2
1.2.1 Media Campionaria: Il Baricentro Fisico dei Dati	3
1.2.2 Mediana Campionaria: Robustezza e Minimizzazione L_1	4
1.2.3 Moda Campionaria e Asimmetria Geometrica	5
1.2.4 Quantili e Percentili Campionari	5
1.3 Indici di Dispersione e Variabilità	6
1.3.1 Varianza Campionaria Corretta e Correzione di Bessel	6
1.3.2 Scarto Interquartile (IQR) e Anatomia del Boxplot	7
1.4 Statistica Descrittiva Bivariata: Covarianza e Correlazione	8
1.4.1 Covarianza Campionaria e Concordanza Geometrica	8
1.4.2 Coefficiente di Correlazione Lineare di Pearson	9
1.5 La Retta di Regressione Lineare dei Minimi Quadrati (OLS)	11
1.6 Proprietà di Invarianza e Trasformazioni Lineari	12
1.7 Consigli per l'Esame, Trappole Frequenti e Schemi Risolutivi	12
2 Elementi di Teoria della Probabilità e Calcolo Combinatorio	15
2.1 Genesi Storica e Paradigmi Interpretativi della Probabilità	15
2.2 L'Impianto Assiomatico di Kolmogorov	16
2.3 Teoremi Fondamentali e Proprietà Derivate	17
2.4 Calcolo Combinatorio e Tecniche di Conteggio	19
2.5 Problemi Classici ed Esempi Notabili: Il Paradosso del Compleanno	20
3 Probabilità Condizionata, Formula di Bayes e Indipendenza	23
3.1 Il Concetto di Informazione e la Probabilità Condizionata	23
3.1.1 Regola del Prodotto e Formula a Catena	24
3.2 Il Teorema delle Probabilità Totali	24
3.3 Il Teorema di Bayes e l'Inversione delle Cause	26
3.3.1 Applicazione Fondamentale: Il Paradosso dei Falsi Positivi	27
3.4 Indipendenza Stocastica	27
3.4.1 Indipendenza a Due a Due vs Mutua Indipendenza Globale	28
3.5 Consigli per l'Esame e Trappole Ricorrenti	29
4 Variabili Aleatorie Discrete, Continue e Vettori Aleatori	31
4.1 Il Concetto di Variabile Aleatoria e la Funzione di Ripartizione (CDF)	31
4.2 Variabili Aleatorie Discrete e Funzione di Massa (PMF)	33
4.3 Variabili Aleatorie Continue e Funzione di Densità (PDF)	33

4.4	Vettori Aleatori Bivariati, Distribuzioni Congiunte e Marginali	34
4.4.1	Densità Marginali e Densità Condizionate	34
4.4.2	Indipendenza tra Variabili Aleatorie	35
4.5	Trasformazioni di Variabili Aleatorie e Metodo dello Jacobiano	35
5	Valore Atteso, Varianza, Covarianza e Disuguaglianze	37
5.1	Valore Atteso (Speranza Matematica) e Principio del Baricentro	37
5.1.1	La Formula del Trasferimento (LOTUS)	38
5.1.2	Linearità Universale del Valore Atteso	38
5.2	Varianza Teorica e Deviazione Standard	39
5.3	Covarianza, Correlazione e Varianza della Somma	39
5.4	Disuguaglianze Fondamentali di Concentrazione: Markov e Chebyshev	40
6	Somma di Variabili Aleatorie, Convoluzione e Teoremi Limite	43
6.1	Distribuzione della Somma e Integrale di Convoluzione	43
6.1.1	Famiglie di Distribuzioni Riproduttive (Chiusura per Convoluzione)	44
6.2	La Legge dei Grandi Numeri (LLN)	45
6.3	Il Teorema del Limite Centrale (CLT)	45
6.3.1	Teorema di De Moivre-Laplace e Correzione di Continuità di Yates	46
7	Classi di Leggi di Probabilità Discrete	47
7.1	Distribuzione di Bernoulli e Distribuzione Binomiale	47
7.2	Distribuzione Geometrica e la Proprietà di Assenza di Memoria	48
7.3	Distribuzione di Poisson e la Legge degli Eventi Rari	49
7.4	Distribuzione Ipergeometrica e Binomiale Negativa	50
7.5	Tabella Sinottica delle Classi di Leggi Discrete	51
8	Classi di Leggi di Probabilità Continue	53
8.1	Distribuzione Uniforme Continua e Probabilità Geometrica	53
8.2	Distribuzione Esponenziale e Affidabilità nel Continuo	54
8.3	Distribuzione Normale Gaussiana	55
8.4	Distribuzioni Campionarie Pivotali: χ^2 , t di Student e F	56
9	Campione Statistico, Teoria della Stima Puntuale e Massima Verosimiglianza	59
9.1	Il Paradigma dell'Inferenza: Campione Casuale e Stimatori	59
9.2	Criteri di Ottimalità: Correttezza, MSE e Consistenza	60
9.2.1	Correttezza (Non Distorsione / Unbiasedness)	60
9.2.2	Errore Quadratico Medio e Scomposizione Bias-Varianza	60
9.2.3	Consistenza Asintotica	61
9.3	Informazione di Fisher e Limite di Cramér-Rao (CRLB)	61
9.4	Il Metodo della Massima Verosimiglianza (MLE)	62
9.5	Il Metodo Monte Carlo per la Stima e l'Integrazione Numerica	63
10	Intervalli di Confidenza e Inferenza Intervallare	65
10.1	Il Concetto di Intervallo e l'Interpretazione Frequentista	65
10.2	Il Metodo Generale della Quantità Pivotala	67
10.3	Tassonomia Completa degli Intervalli di Confidenza	68
10.3.1	1. Media di Popolazione con Varianza σ^2 Nota (Intervallo Z)	68
10.3.2	2. Media di Popolazione con Varianza σ^2 Incognita (Intervallo t di Student)	68
10.3.3	3. Proporzione Bernoulliana (Intervallo Asintotico di Wald)	68
10.3.4	4. Differenza tra Due Medie Indipendenti $\mu_1 - \mu_2$	68
10.3.5	5. Varianza di Popolazione Gaussiana σ^2	69

11 Verifica delle Ipotesi Statistiche (Test di Significatività)	71
11.1 La Struttura Logica del Test d'Ipotesi e la Metafora Giuridica	71
11.2 Matrice degli Errori Decisionali e Potenza del Test	72
11.3 Regioni di Accettazione, Regioni Critiche di Rifiuto e Algoritmo Operativo . .	74
11.4 Il Concetto di p -value (Livello di Significatività Osservato)	74
11.5 Teorema di Dualità tra Test Bilaterali e Intervalli di Confidenza	75
12 Raccolta Temi d'Esame Risolti con Guida Metodologica	77
12.1 Tema d'Esame 1: Probabilità Condizionata e Formula di Bayes	77
12.2 Tema d'Esame 2: Vettore Aleatorio Continuo Bivariato	78
12.3 Tema d'Esame 3: Teorema del Limite Centrale e Dimensionamento	79
12.4 Tema d'Esame 4: Stima di Massima Verosimiglianza e Informazione di Fisher .	80
13 Archivio Ufficiale Temi d'Esame Svolti (2024–2022 ed Eserciziari)	83
13.1 Sessione d'Esame 2024: Testi e Soluzioni Svolte Passo-Passo	83
13.1.1 Appello del 04 Giugno 2024	83
13.1.2 Appello del 25 Giugno 2024	86
13.2 Sessione d'Esame 2023: Testi e Soluzioni Svolte	89
13.2.1 Appello del 06 Giugno 2023	89
13.3 Sessione d'Esame 2022: Testi e Soluzioni Svolte	90
13.3.1 Appello 1 (2022)	90
13.4 Eserciziario Tematico Selezionato dalle Prove Scritte	90

Guida alla Consultazione

Questo volume raccoglie la trascrizione rigorosa, la ricostruzione formale e l'approfondimento teorico-applicativo degli appunti del corso di **Statistica e Calcolo delle Probabilità** per il Corso di Laurea in Ingegneria Gestionale.

Il testo è strutturato in modo altamente modulare per facilitare sia l'apprendimento concettuale sia la rapida consultazione durante la preparazione delle prove d'esame. Ogni capitolo integra:

- Fondamenti teorici e definizioni formali con quantificatori espliciti.
- Teoremi enunciati con ipotesi minime e dimostrazioni complete step-by-step.
- Grafici vettoriali TikZ/pgfplots per la rappresentazione di densità, istogrammi, funzioni di ripartizione, alberi decisionali e regioni critiche.
- Schemi procedurali ed algoritmi di calcolo per l'inferenza statistica.
- Box dedicati ai tranelli tipici dei temi d'esame e ai controesempi classici.

Codice Visivo dei Box Tematici

Per massimizzare l'efficacia dello studio, i concetti sono racchiusi in appositi blocchi grafici:

- **Definizioni:** Formalizzazione assiomatica, spazi campionari, variabili aleatorie, stimatori e parametri.
- **Teoremi, Proposizioni e Corollari:** Risultati matematici cardine, proprietà di chiusura, leggi limite e dimostrazioni rigorose (■).
- **Proprietà:** Proprietà algebriche, operative e statistiche di valori attesi, varianze, stimatori e densità.
- **Esempi ed Esercizi Guidati:** Problemi classici d'esame svolti passo dopo passo con calcoli numerici espliciti.
- **Consigli per l'Esame e Trappole Comuni:** Segnalazione degli errori di interpretazione più frequenti e condizioni di applicabilità dei teoremi.
- **Metodi Risolutivi Standard:** Algoritmi sequenziali per la stima puntuale, il calcolo di intervalli di confidenza e la conduzione di test d'ipotesi.
- **Osservazioni:** Note interpretative, collegamenti tra distribuzioni e approfondimenti asintotici.

Programma del Corso e Mappa Concettuale

Il percorso didattico si articola nelle seguenti macro-aree sequenziali:

1. **Statistica Descrittiva:** scale di misura, frequenze assolute, relative e cumulate; indici di posizione (media aritmetica, mediana, moda, quantili) e indici di dispersione (varianza, deviazione standard, scarto interquartile, coefficiente di variazione); tabelle a doppia entrata, covarianza, correlazione lineare e retta di regressione dei minimi quadrati.
2. **Elementi di Probabilità:** spazio campionario Ω , σ -algebra degli eventi $\mathcal{F}$, assiomi di Kolmogorov, probabilità classica, frequentista e soggettiva; calcolo combinatorio (disposizioni, permutazioni, combinazioni).
3. **Indipendenza e Probabilità Condizionata:** definizione di probabilità condizionata, formula delle probabilità totali, Teorema di Bayes (inferenza bayesiana elementare), indipendenza stocastica di eventi a due a due e globale.
4. **Variabili Aleatorie Discrete e Continue:** definizione di variabile aleatoria, funzione di ripartizione (CDF) e sue proprietà; variabili discrete e funzione di probabilità di massa (PMF); variabili continue e funzione di densità di probabilità (PDF); quantili e percentili.
5. **Valore Atteso e Varianza:** definizione assiomatica di speranza matematica $\mathbb{E}[X]$, Teorema del Trasferimento (LOTUS), momenti semplici e centrati, varianza $\text{Var}(X)$, disuguaglianze notevoli (Markov, Chebyshev, Cauchy-Schwarz, Jensen).
6. **Vettori Aleatori e Somma di Variabili Indipendenti:** distribuzioni congiunte, marginali e condizionate; covarianza e correlazione tra v.a.; indipendenza di variabili aleatorie; convoluzione e legge della somma di v.a. indipendenti; Funzione Generatrice dei Momenti (MGF/FGM) e Funzione Caratteristica; Legge Debole e Forte dei Grandi Numeri (LLN); Teorema del Limite Centrale (TLC / CLT).
7. **Classi di Leggi Discrete Notevoli:** Bernoulli, Binomiale, Poissoniana (legge degli eventi rari e approssimazione binomiale), Geometrica (proprietà di assenza di memoria), Ipergeometrica, Binomiale Negativa.
8. **Classi di Leggi Continue Notevoli:** Gaussiana/Normale standard e generale (proprietà di stabilità per combinazioni lineari), Esponenziale (assenza di memoria), Gamma, Chi-quadro (χ^2), t di Student, Fisher-Snedecor (F).
9. **Campione Statistico e Stima Puntuale:** modello statistico parametrico, campione casuale i.i.d., statistica campionaria; media campionaria e varianza campionaria (corretta e non corretta); proprietà degli stimatori (non distorsione/correttezza, consistenza, efficienza, Errore Quadratico Medio MSE); Metodo dei Momenti e Metodo della Massima Verosimiglianza (MLE); Informazione di Fisher e disuguaglianza di Cramér-Rao.
10. **Intervalli di Confidenza:** quantità pivotali, intervalli di confidenza per la media di popolazioni gaussiane (varianza nota e incognita), intervalli per la varianza, intervalli asintotici per grandi campioni e per proporzioni bernoulliane; ampiezza e numerosità campionaria ottimale.

11. **Test delle Ipotesi Statistiche:** ipotesi nulla H_0 e alternativa H_1 , errori di I tipo (α) e II tipo (β), livello di significatività e potenza del test ($1 - \beta$); regione critica W , statistica test e calcolo del p -value; Lemma di Neyman-Pearson; test parametrici a una e due code (Z-test, t-test, test χ^2 sulla varianza, test di confronto tra due medie/proporzioni/varianze).

CAPITOLO 1

Statistica Descrittiva

Sintesi del Capitolo. *Il presente capitolo espone in modo rigoroso, organico e approfondito i fondamenti dell'analisi statistica descrittiva univariata e bivariata su dati empirici. Partendo dalla rilevazione del dato grezzo e dalla strutturazione delle distribuzioni di frequenza, si approfondiscono i concetti di sintesi di posizione (media aritmetica, mediana, moda e quantili) e di dispersione (varianza campionaria corretta, deviazione standard, scarto interquartile). Vengono dimostrate analiticamente le proprietà algebriche e variazionali fondamentali (tra cui il principio del baricentro, la minimizzazione L_1 ed L_2 e la correzione di Bessel per la non distorsione della varianza). Nella seconda parte, l'indagine si estende alla statistica bivariata attraverso la geometria della covarianza nei quattro quadranti baricentrici, il coefficiente di correlazione lineare di Pearson (con dimostrazione della limitatezza $[-1, 1]$ mediante la disuguaglianza di Cauchy-Schwarz), la stima della retta di regressione dei minimi quadrati (OLS) e l'analisi critica delle trappole metodologiche d'esame.*

1.1 Database Empirico, Rilevazione dei Dati e Distribuzioni di Frequenza

Nel contesto dell'ingegneria e delle scienze applicate, qualsiasi indagine quantitativa trae origine dall'osservazione sistematica di un fenomeno reale. Che si tratti di misurare la resistenza a rottura di una partita di provini d'acciaio, il tempo di risposta di un server distribuito o il numero di pezzi difettosi per lotto di produzione, il primo contatto con la realtà empirica si concretizza in un insieme finito di numeri reali, disordinati e grezzi.

L'obiettivo primario della **statistica descrittiva** non è ancora quello di formulare leggi generali probabilistiche (compito demandato all'inferenza statistica), bensì di organizzare, condensare, visualizzare e sintetizzare la massa dei dati osservati, preservando il massimo contenuto informativo senza alterare la struttura del fenomeno sottostante.

Definizione 1.1: Database Empirico (Campione Univariato)

Sia $\mathcal{U}$ un collettivo statistico (o popolazione di riferimento) composto da n unità statistiche elementari. Si definisce **database empirico** o **campione univariato di dimensione n** la n -upla ordinata delle osservazioni numeriche:

$$D = \{x_1, x_2, \dots, x_n\} \subset \mathbb{R}^n, \quad n \in \mathbb{N}_{\geq 1} \quad (1.1)$$

dove l'indice $i \in \{1, \dots, n\}$ contrassegna la specifica unità statistica esaminata, e $x_i \in \mathbb{R}$ indica il valore assunto dal carattere quantitativo X su tale unità.

Quando la numerosità campionaria n cresce, l'elenco sequenziale dei valori grezzi $x_1, \dots, x_n$ diventa di difficile lettura visiva e computazionale. Spesso molte unità presentano la medesima modalità numerica (valori duplicati o coincidenti). Risulta quindi indispensabile operare una prima compressione dei dati mediante il passaggio alle **distribuzioni di frequenza**.

Sia $\{u_1, u_2, \dots, u_k\}$ l'insieme delle $k \leq n$ distinte modalità numeriche assunte dal carattere nel campione D , ordinate in senso strettamente crescente:

$$u_1 < u_2 < \dots < u_{k-1} < u_k \quad (1.2)$$

Definizione 1.2: Frequenze Assolute, Relative e Cumulate

Dato un campione D con k modalità distinte $\{u_1, \dots, u_k\}$, si definiscono per ogni modalità u_j ($j = 1, \dots, k$):

1. **Frequenza assoluta** n_j : il numero esatto di osservazioni campionarie che hanno manifestato la modalità u_j :

$$n_j = \sum_{i=1}^n \mathbf{1}_{\{x_i=u_j\}}, \quad \text{con il vincolo di conservazione della massa campionaria: } \sum_{j=1}^k n_j = n \quad (1.3)$$

dove $\mathbf{1}_{\{\cdot\}}$ è la funzione indicatrice (pari a 1 se la condizione interna è verificata, 0 altrimenti).

2. **Frequenza relativa** f_j : la proporzione o quota di osservazioni associate alla modalità u_j sul totale del campione:

$$f_j = \frac{n_j}{n}, \quad \text{con i vincoli di non negatività e normalizzazione: } f_j \in [0, 1] \quad \text{e} \quad \sum_{j=1}^k f_j = 1 \quad (1.4)$$

3. **Frequenza assoluta cumulata** N_j e **frequenza relativa cumulata** F_j : rappresentano rispettivamente il numero e la quota di osservazioni campionarie con valore non superiore a u_j :

$$N_j = \sum_{m=1}^j n_m, \quad F_j = \sum_{m=1}^j f_m = \frac{N_j}{n} \quad (j = 1, \dots, k) \quad (1.5)$$

con le condizioni di bordo evidenti $N_1 = n_1, N_k = n$ e $F_1 = f_1, F_k = 1$.

Interpretazione Concettuale ed Empirica. La frequenza relativa f_j rappresenta la controparte empirica della nozione teorica di probabilità $\mathbb{P}(X = u_j)$ che verrà formalizzata nel Capitolo ???. All'aumentare indefinito della numerosità campionaria ($n \rightarrow \infty$), per la Legge dei Grandi Numeri le frequenze relative f_j tenderanno a stabilizzarsi attorno alle probabilità teoriche del fenomeno generatore.

La funzione di frequenza cumulata F_j costituisce a sua volta l'analogo empirico della Funzione di Ripartizione (CDF) $F_X(x)$, fornendo per ogni soglia la frazione di popolazione che si colloca al di sotto di essa.

1.2 Indici di Posizione e Tendenza Centrale

Una distribuzione di frequenza racchiude l'intera informazione del dataset, ma per confrontare rapidamente popolazioni differenti o monitorare processi industriali è indispensabile riassumere

l'ordine di grandezza del fenomeno mediante indici sintetici di posizione o **misure di tendenza centrale**. Ciascun indice risponde a un preciso criterio geometrico o variazionale.

1.2.1 Media Campionaria: Il Baricentro Fisico dei Dati

La media aritmetica campionaria rappresenta l'indice di posizione più diffuso e naturale nell'ingegneria.

Definizione 1.3: Media Campionaria (Media Aritmetica)

Dato il campione $D = \{x_1, \dots, x_n\}$, la **media campionaria** $\bar{x}$ è definita come la media aritmetica semplice di tutte le osservazioni:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad (1.6)$$

Qualora i dati siano organizzati nella tabella delle frequenze con modalità $\{u_1, \dots, u_k\}$ e frequenze assolute $\{n_1, \dots, n_k\}$ (o relative $\{f_1, \dots, f_k\}$), la media campionaria si esprime come media ponderata:

$$\bar{x} = \frac{1}{n} \sum_{j=1}^k u_j n_j = \sum_{j=1}^k u_j f_j \quad (1.7)$$

Significato Meccanico e Variazionale della Media. La media campionaria possiede due proprietà matematiche che ne spiegano la centralità:

1. **Interpretazione del Baricentro Fisico:** Se immaginiamo una barra rigida priva di massa su cui posizioniamo pesi unitari in corrispondenza delle ascisse $x_1, \dots, x_n$, il punto $\bar{x}$ coincide esattamente con il centro di massa (fulcro di equilibrio) del sistema. Posizionando il fulcro in $\bar{x}$, i momenti delle forze generate dagli scarti positivi e negativi si bilanciano perfettamente, annullando la risultante rotazionale.
2. **Minimizzazione dell'Errore Quadratico (L_2 Loss):** In ambito di stima e approssimazione, se vogliamo sostituire l'intero dataset D con un unico valore costante c , la scelta ottimale che minimizza l'energia totale dell'errore (la somma dei quadrati delle deviazioni) è proprio $c = \bar{x}$.

Teorema 1.4: Proprietà Fondamentali della Media Campionaria

La media campionaria $\bar{x}$ soddisfa rigorosamente le seguenti due proprietà:

1. **Annullamento della somma degli scarti (Principio di Equilibrio):**

$$\sum_{i=1}^n (x_i - \bar{x}) = 0 \quad (1.8)$$

2. **Teorema di König-Huygens sul Minimo degli Scarti Quadratici:** La funzione di costo quadratico $g(c) = \sum_{i=1}^n (x_i - c)^2$, definita per ogni $c \in \mathbb{R}$, ammette un unico punto di minimo globale in $c = \bar{x}$.

Dimostrazione dell'annullamento della somma degli scarti. Sfruttando la linearità dell'operatore di sommatoria:

$$\sum_{i=1}^n (x_i - \bar{x}) = \sum_{i=1}^n x_i - \sum_{i=1}^n \bar{x} = \sum_{i=1}^n x_i - n\bar{x} \quad (1.9)$$

Poiché per definizione $n\bar{x} = \sum_{i=1}^n x_i$, sostituendo si ottiene immediatamente:

$$\sum_{i=1}^n (x_i - \bar{x}) = n\bar{x} - n\bar{x} = 0 \quad \blacksquare \quad (1.10)$$

Dimostrazione del Teorema di König-Huygens. Consideriamo la funzione $g(c) = \sum_{i=1}^n (x_i - c)^2$. Sviluppando il quadrato del binomio:

$$g(c) = \sum_{i=1}^n (x_i^2 - 2cx_i + c^2) = \sum_{i=1}^n x_i^2 - 2c \sum_{i=1}^n x_i + nc^2 \quad (1.11)$$

La funzione $g(c)$ è un polinomio di secondo grado in c , convesso poiché il coefficiente del termine quadratico è $n > 0$. La derivata seconda è $g''(c) = 2n > 0, \forall c$. Ponendo a zero la derivata prima rispetto a c :

$$g'(c) = -2 \sum_{i=1}^n x_i + 2nc = 0 \iff 2nc = 2 \sum_{i=1}^n x_i \iff c = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x} \quad (1.12)$$

Essendo la funzione strettamente convessa ovunque, $c = \bar{x}$ costituisce il minimo globale assoluto. $\blacksquare$

1.2.2 Mediana Campionaria: Robustezza e Minimizzazione L_1

Sebbene la media sia ottimale sotto penalizzazione quadratica, essa risente pesantemente dei valori estremi anomali (*outlier*). Per ovviare a tale vulnerabilità, si introduce la **mediana campionaria**.

Definizione 1.5: Statistiche d'Ordine e Mediana Campionaria

Sia $(x_{(1)}, x_{(2)}, \dots, x_{(n)})$ il vettore delle **statistiche d'ordine** del campione, ottenuto riordinando le osservazioni x_i in senso non decrescente:

$$x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n-1)} \leq x_{(n)} \quad (1.13)$$

La **mediana campionaria**, denotata con $\tilde{x}$ o $\text{med}(x)$, è l'elemento che divide il campione ordinato in due metà di eguale numerosità:

$$\tilde{x} = \begin{cases} x_{(\frac{n+1}{2})}, & \text{se } n \text{ è dispari,} \\ \frac{x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}}{2}, & \text{se } n \text{ è pari.} \end{cases} \quad (1.14)$$

Osservazione (Proprietà Variazionale L_1 della Mediana)

Mentre la media $\bar{x}$ minimizza la somma degli scarti quadratici (L_2), la mediana campionaria $\tilde{x}$ è il valore che minimizza la somma degli **scarti assoluti** (L_1 Loss):

$$\min_{c \in \mathbb{R}} \sum_{i=1}^n |x_i - c| = \sum_{i=1}^n |x_i - \tilde{x}| \quad (1.15)$$

Questa proprietà spiega matematicamente perché la mediana è un indicatore **robusto**: la funzione scarto assoluto penalizza linearmente gli scarti anziché quadraticamente, rendendo la stima insensibile a singoli errori grossolani di misura o a code pesanti.

1.2.3 Moda Campionaria e Asimmetria Geometrica

Definizione 1.6: Moda Campionaria

La **moda campionaria**, denotata con $\text{moda}(x)$ o Mo , è la modalità numerica u_j a cui è associata la massima frequenza assoluta n_j (o relativa f_j):

$$\text{moda}(x) = \arg \max_{u_j} n_j \quad (1.16)$$

Se la distribuzione ammette un unico massimo relativo si definisce **unimodale**; se presenta due o più picchi locali di frequenza viene detta **bimodale** o **multimodale** (spesso indice della compresenza di due sottopopolazioni eterogenee).




Figura 1.1: Confronto geometrico tra Moda, Mediana e Media in una distribuzione asimmetrica a destra (positiva). La Moda individua il picco massimo della densità; la Mediana divide l'area sottesa esattamente al 50%; la Media è trascinata verso destra dal braccio di leva degli outlier nella coda.

Come evidenziato in Figura 1.1:

- Nelle distribuzioni **simmetriche unimodali**, i tre indici coincidono: $\text{moda}(x) = \text{med}(x) = \bar{x}$.
- Nelle distribuzioni **asimmetriche a destra** (coda destra allungata, tipica dei tempi di attesa o dei redditi): $\text{moda}(x) < \text{med}(x) < \bar{x}$.
- Nelle distribuzioni **asimmetriche a sinistra** (coda sinistra allungata): $\bar{x} < \text{med}(x) < \text{moda}(x)$.

1.2.4 Quantili e Percentili Campionari

I quantili estendono il concetto di mediana a qualsiasi frazione di ripartizione campionaria.

Definizione 1.7: Quantile Campionario di Livello p e Percentili

Dato un livello di probabilità $p \in (0, 1)$, il **quantile campionario di ordine p** (denotato con q_p) è il valore al di sotto del quale ricade una frazione p delle osservazioni campionarie. Operativamente, ordinato il campione $x_{(1)} \leq \dots \leq x_{(n)}$:

1. Si calcola la posizione reale $k = n \cdot p$.
2. Se $k \notin \mathbb{N}$, si arrotonda per eccesso alla parte intera superiore $\lceil k \rceil$, e si pone $q_p = x_{(\lceil k \rceil)}$.
3. Se $k \in \mathbb{N}$, si calcola la media dei due elementi contigui: $q_p = \frac{x_{(k)} + x_{(k+1)}}{2}$.

I **percentili** corrispondono alla scala centesimale ($p = k/100$ per $k = 1, \dots, 99$). I **quartili** dividono il campione in quattro parti uguali:

- **Primo quartile** $Q_1 = q_{0.25}$ (25-esimo percentile);
- **Secondo quartile** $Q_2 = q_{0.50} = \tilde{x}$ (mediana);
- **Terzo quartile** $Q_3 = q_{0.75}$ (75-esimo percentile).

1.3 Indici di Dispersione e Variabilità

Gli indici di posizione descrivono dove i dati sono centrati, ma non offrono alcuna informazione sulla loro dispersione. Due processi produttivi possono avere la medesima media nominale $\bar{x} = 100$ mm, ma il primo potrebbe avere oscillazioni contenute entro ± 0.1 mm (alta qualità) e il secondo oscillazioni di ± 10 mm (prodotto non conforme). La misura quantitativa della dispersione è affidata agli indici di variabilità.

1.3.1 Varianza Campionaria Corretta e Correzione di Bessel

Definizione 1.8: Varianza Campionaria e Deviazione Standard

Dato un campione $D = \{x_1, \dots, x_n\}$ con $n \geq 2$:

1. La **varianza campionaria corretta** S^2 è definita come:

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \quad (1.17)$$

2. La **deviazione standard campionaria** (o scarto quadratico medio) S è la radice quadrata positiva della varianza:

$$S = \sqrt{S^2} = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2} \quad (1.18)$$

Perché dividiamo per $n-1$ anziché per n ? (La Correzione di Bessel). Uno dei dubbi più frequenti riguarda la presenza del denominatore $n-1$. L'intuizione fondamentale è legata ai **gradi di libertà** e alla natura della stima:

- Gli scarti $(x_i - \bar{x})$ sono calcolati rispetto alla media campionaria $\bar{x}$, e non rispetto alla vera media incognita della popolazione μ .
- Come dimostrato nel Teorema ??, la media campionaria $\bar{x}$ minimizza la somma dei quadrati $\sum (x_i - c)^2$. Di conseguenza, la somma calcolata attorno a $\bar{x}$ è sistematicamente

minore della somma che si otterrebbe attorno a μ :

$$\sum_{i=1}^n (x_i - \bar{x})^2 \leq \sum_{i=1}^n (x_i - \mu)^2 \quad (1.19)$$

- Se dividessimo per n , lo stimatore risulterebbe affetto da una distorsione sistematica verso il basso (sottostimerebbe la reale dispersione della popolazione).
- Poiché il vincolo lineare $\sum_{i=1}^n (x_i - \bar{x}) = 0$ consuma esattamente 1 grado di libertà (fissati i primi $n - 1$ scarti, l' n -esimo è univocamente determinato), la somma contiene solo $n - 1$ scarti liberi e indipendenti. Dividere per $n - 1$ compensa esattamente tale deficit informativo, garantendo che $\mathbb{E}[S^2] = \sigma^2$ (stimatore non distorto).

Teorema 1.9: Formula Computazionale Operativa per la Varianza

La devianza totale ammette la seguente fondamentale identità algebrica:

$$\sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - n\bar{x}^2 = \sum_{i=1}^n x_i^2 - \frac{1}{n} \left(\sum_{i=1}^n x_i \right)^2 \quad (1.20)$$

Pertanto, la varianza campionaria si calcola in un singolo passaggio computazionale come:

$$S^2 = \frac{1}{n-1} \left(\sum_{i=1}^n x_i^2 - n\bar{x}^2 \right) = \frac{1}{n-1} \left(\sum_{i=1}^n x_i^2 - \frac{1}{n} \left(\sum_{i=1}^n x_i \right)^2 \right) \quad (1.21)$$

Dimostrazione dell'Identità Computazionale di König-Huygens. Sviluppando il quadrato all'interno della sommatoria:

$$\sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n (x_i^2 - 2\bar{x}x_i + \bar{x}^2) \quad (1.22)$$

$$= \sum_{i=1}^n x_i^2 - 2\bar{x} \sum_{i=1}^n x_i + \sum_{i=1}^n \bar{x}^2 \quad (1.23)$$

$$= \sum_{i=1}^n x_i^2 - 2\bar{x}(n\bar{x}) + n\bar{x}^2 \quad (1.24)$$

$$= \sum_{i=1}^n x_i^2 - 2n\bar{x}^2 + n\bar{x}^2 = \sum_{i=1}^n x_i^2 - n\bar{x}^2 \quad \blacksquare \quad (1.25)$$

■

1.3.2 Scarto Interquartile (IQR) e Anatomia del Boxplot

Accanto alla deviazione standard S (sensibile agli outlier), si impiega lo **scarto interquartile** come misura di variabilità robusta.

Definizione 1.10: Scarto Interquartile (Interquartile Range - IQR)

Lo **scarto interquartile** è la differenza tra il terzo e il primo quartile del campione:

$$\text{IQR} = Q_3 - Q_1 \quad (1.26)$$

Rappresenta l'ampiezza dell'intervallo centrale che racchiude esattamente il 50% delle osservazioni campionarie.




Figura 1.2: Anatomia strutturata del Boxplot (diagramma a scatola e baffi di Tukey). La scatola delimita l'IQR tra Q_1 e Q_3 , con la linea interna sulla Mediana $\tilde{x}$. I baffi si estendono fino alle osservazioni estreme non outlier contenute nelle recinzioni interne $[Q_1 - 1.5 \text{ IQR}, Q_3 + 1.5 \text{ IQR}]$. I punti esterni sono segnalati individualmente come outlier.

Il Boxplot (Figura 1.2) implementa il criterio di Tukey per il rilevamento oggettivo degli outlier:

- **Recinzione inferiore interna:** $LF = Q_1 - 1.5 \cdot \text{IQR}$.
- **Recinzione superiore interna:** $UF = Q_3 + 1.5 \cdot \text{IQR}$.
- Qualsiasi osservazione $x_i < LF$ o $x_i > UF$ viene classificata come **outlier** ed evidenziata con un simbolo isolato.

1.4 Statistica Descrittiva Bivariata: Covarianza e Correlazione

Quando su ciascuna unità statistica vengono misurati simultaneamente due caratteri quantitativi X e Y , il dataset assume la forma bivariata:

$$D_{XY} = \{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\} \subset \mathbb{R}^2 \quad (1.27)$$

L'obiettivo fondamentale dell'analisi bivariata è determinare l'esistenza, il verso e l'intensità del legame associativo tra le due variabili.

1.4.1 Covarianza Campionaria e Concordanza Geometrica

Definizione 1.11: Covarianza Campionaria

Dato un campione bivariato di dimensione $n \geq 2$, con medie $\bar{x}$ e $\bar{y}$, si definisce **covarianza campionaria** (denotata con s_{xy} o q):

$$s_{xy} = q = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \quad (1.28)$$

Teorema 1.12: Formula Computazionale Operativa per la Covarianza

La codevianza ammette l'identità:

$$\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \sum_{i=1}^n x_i y_i - n \bar{x} \bar{y} = \sum_{i=1}^n x_i y_i - \frac{1}{n} \left(\sum_{i=1}^n x_i \right) \left(\sum_{i=1}^n y_i \right) \quad (1.29)$$

Pertanto:

$$s_{xy} = \frac{1}{n-1} \left(\sum_{i=1}^n x_i y_i - n \bar{x} \bar{y} \right) \quad (1.30)$$

Dimostrazione. Sviluppando il prodotto degli scarti:

$$\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \sum_{i=1}^n (x_i y_i - \bar{x} y_i - \bar{y} x_i + \bar{x} \bar{y}) \quad (1.31)$$

$$= \sum_{i=1}^n x_i y_i - \bar{x} \sum_{i=1}^n y_i - \bar{y} \sum_{i=1}^n x_i + n \bar{x} \bar{y} \quad (1.32)$$

$$= \sum_{i=1}^n x_i y_i - \bar{x}(n \bar{y}) - \bar{y}(n \bar{x}) + n \bar{x} \bar{y} \quad (1.33)$$

$$= \sum_{i=1}^n x_i y_i - 2n \bar{x} \bar{y} + n \bar{x} \bar{y} = \sum_{i=1}^n x_i y_i - n \bar{x} \bar{y} \quad \blacksquare \quad (1.34)$$




Figura 1.3: Interpretazione geometrica della covarianza e della concordanza. Il piano cartesiano viene traslato nel baricentro $(\bar{x}, \bar{y})$. Nei quadranti I e III il prodotto degli scarti $(x_i - \bar{x})(y_i - \bar{y})$ è strettamente positivo (concordanza, $r > 0$). Nei quadranti II e IV il prodotto è negativo (discordanza, $r < 0$).

1.4.2 Coefficiente di Correlazione Lineare di Pearson

La covarianza s_{xy} dipende dall'unità di misura delle due variabili (ad esempio, $\text{kg} \cdot \text{m}$). Per disporre di una misura adimensionale e standardizzata, si normalizza la covarianza per il prodotto delle deviazioni standard.

Definizione 1.13: Coefficiente di Correlazione Lineare di Pearson

Si definisce **coefficiente di correlazione lineare campionario** r (o r_{xy}):

$$r = \frac{s_{xy}}{s_x s_y} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} \quad (1.35)$$

Teorema 1.14: Proprietà di Limitatezza di Pearson (Dimostrazione via Cauchy-Schwarz)

Per qualsiasi campione bivariato con deviazioni standard $s_x > 0$ e $s_y > 0$:

$$-1 \leq r \leq 1 \quad (1.36)$$

Inoltre:

- $r = +1$ se e solo se esiste una perfetta relazione lineare crescente $y_i = ax_i + b$ con $a > 0$.
- $r = -1$ se e solo se esiste una perfetta relazione lineare decrescente $y_i = ax_i + b$ con $a < 0$.
- $r = 0$ indica assenza di correlazione lineare (incorrelazione).

Dimostrazione tramite la Disuguaglianza di Cauchy-Schwarz. Definiamo nello spazio euclideo $\mathbb{R}^n$ i due vettori degli scarti centrati:

$$\mathbf{u} = \begin{pmatrix} x_1 - \bar{x} \\ \vdots \\ x_n - \bar{x} \end{pmatrix}, \quad \mathbf{v} = \begin{pmatrix} y_1 - \bar{y} \\ \vdots \\ y_n - \bar{y} \end{pmatrix} \quad (1.37)$$

Il prodotto scalare standard in $\mathbb{R}^n$ è $\langle \mathbf{u}, \mathbf{v} \rangle = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = (n-1)s_{xy}$. Le norme euclidee sono:

$$\|\mathbf{u}\| = \sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} = \sqrt{n-1} s_x, \quad \|\mathbf{v}\| = \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2} = \sqrt{n-1} s_y \quad (1.38)$$

Per la fondamentale **disuguaglianza di Cauchy-Schwarz**, per ogni coppia di vettori in uno spazio prehilbertiano:

$$|\langle \mathbf{u}, \mathbf{v} \rangle| \leq \|\mathbf{u}\| \|\mathbf{v}\| \quad (1.39)$$

Sostituendo le espressioni dei nostri vettori centrati:

$$|(n-1)s_{xy}| \leq (\sqrt{n-1}s_x)(\sqrt{n-1}s_y) = (n-1)s_x s_y \quad (1.40)$$

Dividendo ambo i membri per la quantità strettamente positiva $(n-1)s_x s_y$:

$$\left| \frac{s_{xy}}{s_x s_y} \right| \leq 1 \iff |r| \leq 1 \iff -1 \leq r \leq 1 \quad (1.41)$$

L'uguaglianza $|\langle \mathbf{u}, \mathbf{v} \rangle| = \|\mathbf{u}\| \|\mathbf{v}\|$ sussiste se e solo se i vettori $\mathbf{u}$ e $\mathbf{v}$ sono linearmente dipendenti (paralleli), ossia $\mathbf{v} = a\mathbf{u}$ per qualche costante $a \neq 0$. Ciò equivale a $y_i - \bar{y} = a(x_i - \bar{x}) \implies y_i = ax_i + (\bar{y} - a\bar{x})$, che rappresenta una perfetta retta sul piano cartesiano. ■ ■

1.5 La Retta di Regressione Lineare dei Minimi Quadrati (OLS)

Quando tra le variabili X e Y sussiste un legame di correlazione significativo, si cerca di modellare la risposta quantitativa Y come funzione lineare della variabile antecedente X :

$$\hat{y}_i = ax_i + b \quad (1.42)$$

La determinazione della retta ottima si fonda sul criterio dei **Minimi Quadrati Ordinari** (*Ordinary Least Squares* - *OLS*), che consiste nel minimizzare la somma dei quadrati dei residui verticali $e_i = y_i - \hat{y}_i$.




Figura 1.4: Retta di regressione dei minimi quadrati OLS. I segmenti verticali tratteggiati evidenziano i residui $e_i = y_i - \hat{y}_i$. Il criterio OLS individua la retta che minimizza la somma delle aree dei quadrati dei residui, passando necessariamente per il baricentro $(\bar{x}, \bar{y})$.

Teorema 1.15: Coefficienti della Retta di Regressione OLS

La funzione di perdita $S(a, b) = \sum_{i=1}^n (y_i - (ax_i + b))^2$ ammette un unico punto di minimo globale dato da:

$$a = \frac{s_{xy}}{s_x^2} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = r \frac{s_y}{s_x} \quad (1.43)$$

$$b = \bar{y} - a\bar{x} \quad (1.44)$$

Pertanto, l'equazione della retta OLS in forma baricentrica è:

$$\hat{y} - \bar{y} = a(x - \bar{x}) \quad (1.45)$$

Dimostrazione. Calcoliamo le derivate parziali di $S(a, b)$ rispetto a b e ad a , ponendole a zero (sistema delle equazioni normali):

$$\frac{\partial S}{\partial b} = -2 \sum_{i=1}^n (y_i - ax_i - b) = 0 \implies \sum_{i=1}^n y_i - a \sum_{i=1}^n x_i - nb = 0 \implies b = \bar{y} - a\bar{x} \quad (1.46)$$

$$\frac{\partial S}{\partial a} = -2 \sum_{i=1}^n x_i (y_i - ax_i - b) = 0 \quad (1.47)$$

Sostituendo $b = \bar{y} - a\bar{x}$ nella seconda equazione:

$$\sum_{i=1}^n x_i (y_i - ax_i - (\bar{y} - a\bar{x})) = 0 \iff \sum_{i=1}^n x_i (y_i - \bar{y}) - a \sum_{i=1}^n x_i (x_i - \bar{x}) = 0 \quad (1.48)$$

Poiché $\sum x_i (y_i - \bar{y}) = \sum (x_i - \bar{x})(y_i - \bar{y})$ e $\sum x_i (x_i - \bar{x}) = \sum (x_i - \bar{x})^2$, ricaviamo immediatamente:

$$a = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{(n-1)s_{xy}}{(n-1)s_x^2} = \frac{s_{xy}}{s_x^2} \quad \blacksquare \quad (1.49)$$

■

1.6 Proprietà di Invarianza e Trasformazioni Lineari

Nell'elaborazione di dati sperimentali è frequente operare cambi di scala o di unità di misura (ad esempio conversione da gradi Celsius a Fahrenheit: $Y = 1.8X + 32$).

Teorema 1.16: Effetto delle Trasformazioni Affini sugli Indici Descrittivi

Sia $X = \{x_1, \dots, x_n\}$ un campione con media $\bar{x}$ e deviazione standard S_x . Sia $Y = \{y_1, \dots, y_n\}$ il campione trasformato per via affine: $y_i = ax_i + b$ con $a, b \in \mathbb{R}$. Allora:

1. **Media campionaria:** $\bar{y} = a\bar{x} + b$ (proprietà di preservazione lineare).
2. **Mediana e quantili:** $\tilde{y} = a\tilde{x} + b$ per $a > 0$.
3. **Varianza campionaria:** $S_y^2 = a^2 S_x^2$ (invariante rispetto alla costante additiva b).
4. **Deviazione standard:** $S_y = |a| S_x$.
5. **Covarianza campionaria:** per $U = aX + b$ e $V = cY + d$, si ha $s_{uv} = ac \cdot s_{xy}$.
6. **Correlazione lineare:** $r_{uv} = \text{sgn}(ac) \cdot r_{xy} = \frac{ac}{|ac|} r_{xy}$.

1.7 Consigli per l'Esame, Trappole Frequenti e Schemi Risolutivi

Trappola 1: Incorrelazione Lineare ($r = 0$) vs Indipendenza

Nelle prove d'esame è frequente l'errore concettuale di confondere l'assenza di correlazione lineare ($r = 0$) con l'indipendenza stocastica:

- Il coefficiente r quantifica **esclusivamente l'intensità del legame lineare**.
- Due variabili possono essere legate da una perfetta relazione deterministica non lineare (es. $Y = X^2$ con X distribuita simmetricamente rispetto all'origine) ed avere esattamente $s_{xy} = 0 \implies r = 0$.
- Vale sempre l'implicazione: **Indipendenza** $\implies r = 0$, mentre $r = 0 \not\Rightarrow$ **Indipendenza**.

Trappola 2: Correlazione Spuria vs Causalità (*Cum Hoc Ergo Propter Hoc*)

Un coefficiente di correlazione elevato ($r \approx 1$) dimostra che le due serie storiche o campionarie variano congiuntamente, ma **non dimostra in alcun modo un rapporto**

di causa-effetto. Spesso l'associazione è indotta da una terza variabile non osservata di confondimento Z (*confounding factor*) che influenza simultaneamente X e Y .

Calcolo Tabellare Veloce di Media, Varianza e Covarianza all'Esame

Per evitare errori di calcolo e risparmiare tempo durante la prova scritta, non calcolare gli scarti individuali $(x_i - \bar{x})$, bensì organizza i calcoli cumulando i seguenti 5 totalizzatori:

$$\Sigma_x = \sum_{i=1}^n x_i, \quad \Sigma_y = \sum_{i=1}^n y_i, \quad \Sigma_{x^2} = \sum_{i=1}^n x_i^2, \quad \Sigma_{y^2} = \sum_{i=1}^n y_i^2, \quad \Sigma_{xy} = \sum_{i=1}^n x_i y_i \quad (1.50)$$

Dopodiché applica direttamente le formule computazionali di König-Huygens:

$$\bar{x} = \frac{\Sigma_x}{n}, \quad \bar{y} = \frac{\Sigma_y}{n} \quad (1.51)$$

$$S_x^2 = \frac{1}{n-1} \left(\Sigma_{x^2} - \frac{\Sigma_x^2}{n} \right), \quad S_y^2 = \frac{1}{n-1} \left(\Sigma_{y^2} - \frac{\Sigma_y^2}{n} \right) \quad (1.52)$$

$$s_{xy} = \frac{1}{n-1} \left(\Sigma_{xy} - \frac{\Sigma_x \Sigma_y}{n} \right), \quad r = \frac{s_{xy}}{S_x S_y} \quad (1.53)$$

CAPITOLO 2

Elementi di Teoria della Probabilità e Calcolo Combinatorio

Sintesi del Capitolo. *Il presente capitolo introduce l'impianto formale e concettuale del calcolo delle probabilità moderno. Partendo dall'evoluzione epistemologica del concetto di probabilità (dalla definizione classica di Laplace, al paradigma frequentista di von Mises, fino all'approccio soggettivista di de Finetti), viene presentata l'assiomatizzazione di Kolmogorov su spazi di misura $(\Omega, \mathcal{F}, \mathbb{P})$. Vengono fornite le dimostrazioni analitiche rigorose di tutte le proprietà fondamentali (probabilità dell'evento complementare, monotonia, formule di inclusione-esclusione di Poincaré, disuguaglianze di Boole e Bonferroni). Nella seconda parte, si sviluppa organicamente l'algebra del campionamento e del calcolo combinatorio (permutazioni, disposizioni, combinazioni semplici e con ripetizione, coefficienti multinomiali), applicandola alla risoluzione analitica di problemi storici ed esami universitari classici come il paradosso del compleanno.*

2.1 Genesi Storica e Paradigmi Interpretativi della Probabilità

Il calcolo delle probabilità nasce storicamente a metà del Seicento dalla celebre corrispondenza tra Blaise Pascal e Pierre de Fermat in merito a problemi di scommesse e giochi d'azzardo (in particolare il *problème des partis* posto dal Cavaliere di Méré). Tuttavia, la quantificazione dell'incertezza trascende il contesto ludico e costituisce oggi l'ossatura logico-matematica di tutta la fisica quantistica, dell'ingegneria industriale, dell'affidabilità dei sistemi e dell'intelligenza artificiale.

Prima di approdare all'assiomatizzazione formale, è essenziale comprendere le tre grandi prospettive storiche attraverso cui è stato definito il valore $\mathbb{P}(E) \in [0, 1]$ di un evento incerto E :

1. **Paradigma Classico (Pierre-Simon de Laplace, 1812):** Se lo spazio dei possibili esiti elementari è finito e tutti gli esiti sono considerati, per ragioni di simmetria fisica, perfettamente *equiprobabili* (principio di ragion non sufficiente), la probabilità di E è il rapporto tra casi favorevoli e casi possibili:

$$\mathbb{P}(E) = \frac{\#(\text{casi favorevoli a } E)}{\#(\text{casi possibili totali})} = \frac{|E|}{|\Omega|} \quad (2.1)$$

Critica epistemologica: La definizione classica presuppone il concetto di eventi “equiprobabili” per definire la probabilità stessa, incorrendo in un'evidente circolarità logica. Inoltre, non è applicabile a spazi campionari continui o a esperimenti con esiti sbilanciati.

2. **Paradigma Frequentistico (Richard von Mises, 1928):** La probabilità non è una proprietà deducibile a priori, bensì una grandezza fisica oggettiva misurabile **a posteriori**. Se un esperimento ideale è ripetibile infinite volte in condizioni identiche e mutualmente indipendenti, la probabilità dell'evento E è il limite a cui tende la frequenza relativa empirica dei successi al divergere del numero di prove:

$$\mathbb{P}(E) = \lim_{n \rightarrow \infty} \frac{n_E}{n} \quad (2.2)$$

Critica epistemologica: Il concetto di limite matematico $n \rightarrow \infty$ è inattuabile sperimentalmente nel mondo reale (possiamo compiere solo un numero finito n di prove). Inoltre, il paradigma non può essere applicato a eventi unici e non ripetibili (ad esempio: la probabilità di pioggia domani a Pisa o la probabilità di fallimento di una specifica missione spaziale).

3. **Paradigma Soggettivistico (Bruno de Finetti, Frank Ramsey, 1931):** La probabilità è intesa come il **grado di fiducia o credenza razionale** che un individuo coerente ripone nell'avverarsi di un evento, in base all'insieme di informazioni a sua disposizione. Operativamente, è quantificata come il prezzo equo p che un soggetto scommettitore accetterebbe di pagare per ricevere un guadagno unitario (1 euro) se l'evento E si verifica, e 0 se non si verifica. Il criterio di coerenza logica impone che non sia possibile per alcuno scommettitore costruire un *Dutch Book* (un sistema di scommesse a vincita garantita contro il banco).

Per svincolare la matematica dalle dispute filosofiche sul significato reale della probabilità, il grande matematico sovietico ****Andrei Nikolaevich Kolmogorov**** propose nel 1933 nel suo trattato *Grundbegriffe der Wahrscheinlichkeitsrechnung* un approccio puramente assiomatico, fondato sulla moderna teoria della misura.

2.2 L'Impianto Assiomatico di Kolmogorov

Nel modello di Kolmogorov, la probabilità non è definita da un processo empirico o soggettivo, ma è una **funzione matematica d'insieme** che soddisfa un sistema minimale di assiomi auto-consistenti.

Definizione 2.1: Spazio di Probabilità $(\Omega, \mathcal{F}, \mathbb{P})$

Uno **spazio di probabilità** è una struttura matematica descritta dalla terna $(\Omega, \mathcal{F}, \mathbb{P})$:

1. Ω (detto **spazio campionario** o *sample space*) è l'insieme di tutti i possibili esiti elementari ω dell'esperimento aleatorio.
2. $\mathcal{F}$ è una **σ -algebra** su Ω , ossia una famiglia di sottoinsiemi di Ω (detti **eventi**) che soddisfa le tre proprietà di chiusura:
 - $\Omega \in \mathcal{F}$ (l'evento certo appartiene alla collezione);
 - Se $E \in \mathcal{F}$, allora il complementare $E^c = \Omega \setminus E \in \mathcal{F}$ (chiusura rispetto alla negazione logica);
 - Se $\{E_n\}_{n=1}^{\infty} \subset \mathcal{F}$, allora $\bigcup_{n=1}^{\infty} E_n \in \mathcal{F}$ (chiusura rispetto a unioni numerabili).
3. $\mathbb{P} : \mathcal{F} \rightarrow [0, 1]$ è una misura a valori reali detta **misura di probabilità**.

Perché serve la σ -algebra $\mathcal{F}$ anziché l'intero insieme delle parti $\mathcal{P}(\Omega)$? Negli spazi finiti o discreti numerabili possiamo tranquillamente porre $\mathcal{F} = \mathcal{P}(\Omega)$. Tuttavia, quando Ω è un continuo (come la retta reale $\mathbb{R}$ o l'intervallo $[0, 1]$), la presenza di insiemi non misurabili

(come gli insiemi di Vitali o il paradosso di Banach-Tarski) impedisce di definire una misura σ -additiva coerente su *tutti* i possibili sottoinsiemi. La σ -algebra di Borel $\mathcal{B}(\mathbb{R})$ generata dagli intervalli aperti garantisce che ogni evento fisicamente significativo sia rigorosamente misurabile.




Figura 2.1: Rappresentazione insiemistica dello spazio campionario Ω e degli assiomi di Kolmogorov. L'evento certo Ω ha area totale unitaria ($\mathbb{P}(\Omega) = 1$). Gli eventi disgiunti E_1 ed E_2 occupano regioni prive di sovrapposizione ($E_1 \cap E_2 = \emptyset$), per cui l'area della loro unione è la somma diretta delle singole aree.

Teorema 2.2: Assiomi di Kolmogorov

La misura di probabilità $\mathbb{P} : \mathcal{F} \rightarrow [0, 1]$ deve soddisfare inderogabilmente i tre assiomi fondamentali:

1. **Assioma 1 (Positività e Limitatezza):** Per ogni evento $E \in \mathcal{F}$:

$$\mathbb{P}(E) \geq 0 \quad (2.3)$$

2. **Assioma 2 (Normalizzazione / Certezza):** La probabilità dell'intero spazio campionario è unitaria:

$$\mathbb{P}(\Omega) = 1 \quad (2.4)$$

3. **Assioma 3 (σ -additività / Additività Numerabile):** Se $\{E_i\}_{i=1}^{\infty}$ è una successione numerabile di eventi a due a due disgiunti (mutuamente incompatibili), ossia $E_i \cap E_j = \emptyset$ per ogni $i \neq j$, allora:

$$\mathbb{P}\left(\bigcup_{i=1}^{\infty} E_i\right) = \sum_{i=1}^{\infty} \mathbb{P}(E_i) \quad (2.5)$$

2.3 Teoremi Fondamentali e Proprietà Derivate

A partire dai tre soli assiomi di Kolmogorov, è possibile dedurre per via deduttiva l'intera struttura del calcolo delle probabilità.

Teorema 2.3: Proprietà Derivate Fondamentali

Sia $(\Omega, \mathcal{F}, \mathbb{P})$ uno spazio di probabilità. Per ogni $A, B \in \mathcal{F}$ valgono:

1. **Evento Impossibile:** $\mathbb{P}(\emptyset) = 0$.
2. **Evento Complementare:** $\mathbb{P}(A^c) = 1 - \mathbb{P}(A)$.

3. **Differenza di Eventi:** $\mathbb{P}(A \setminus B) = \mathbb{P}(A \cap B^c) = \mathbb{P}(A) - \mathbb{P}(A \cap B)$.

4. **Monotonia della Probabilità:** Se $A \subseteq B$, allora $\mathbb{P}(A) \leq \mathbb{P}(B)$ e di conseguenza $\mathbb{P}(B \setminus A) = \mathbb{P}(B) - \mathbb{P}(A)$.

5. **Formula di Inclusione-Esclusione (Principio di Poincaré per 2 Eventi):**

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B) \quad (2.6)$$

6. **Disuguaglianza di Boole (Sub-additività Numerabile):**

$$\mathbb{P}\left(\bigcup_{i=1}^n A_i\right) \leq \sum_{i=1}^n \mathbb{P}(A_i) \quad (2.7)$$

7. **Disuguaglianza di Bonferroni:**

$$\mathbb{P}(A \cap B) \geq \mathbb{P}(A) + \mathbb{P}(B) - 1 \quad (2.8)$$

Dimostrazioni Analitiche Complete Passo-Passo.

1. **Evento complementare:** Lo spazio campionario si scompone nell'unione disgiunta $\Omega = A \cup A^c$ con $A \cap A^c = \emptyset$. Per l'Assioma 3 e l'Assioma 2:

$$\mathbb{P}(\Omega) = \mathbb{P}(A) + \mathbb{P}(A^c) \implies 1 = \mathbb{P}(A) + \mathbb{P}(A^c) \implies \mathbb{P}(A^c) = 1 - \mathbb{P}(A) \quad (2.9)$$

Ponendo $A = \Omega$, si ha $\mathbb{P}(\emptyset) = \mathbb{P}(\Omega^c) = 1 - \mathbb{P}(\Omega) = 1 - 1 = 0$.

2. **Differenza di eventi:** L'evento A può essere partizionato in $A = (A \setminus B) \cup (A \cap B)$, dove $(A \setminus B) \cap (A \cap B) = \emptyset$. Applicando l'Assioma 3:

$$\mathbb{P}(A) = \mathbb{P}(A \setminus B) + \mathbb{P}(A \cap B) \implies \mathbb{P}(A \setminus B) = \mathbb{P}(A) - \mathbb{P}(A \cap B) \quad (2.10)$$

3. **Monotonia:** Se $A \subseteq B$, allora $A \cap B = A$. Sostituendo nella formula della differenza:

$$\mathbb{P}(B \setminus A) = \mathbb{P}(B) - \mathbb{P}(A \cap B) = \mathbb{P}(B) - \mathbb{P}(A) \quad (2.11)$$

Poiché per l'Assioma 1 $\mathbb{P}(B \setminus A) \geq 0$, ne segue immediatamente $\mathbb{P}(B) - \mathbb{P}(A) \geq 0 \implies \mathbb{P}(A) \leq \mathbb{P}(B)$.

4. **Inclusione-Esclusione a 2 eventi:** L'unione $A \cup B$ si scompone nell'unione disgiunta $A \cup B = A \cup (B \setminus A)$, con $A \cap (B \setminus A) = \emptyset$.

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B \setminus A) = \mathbb{P}(A) + [\mathbb{P}(B) - \mathbb{P}(A \cap B)] = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B) \quad (2.12)$$

5. **Disuguaglianza di Bonferroni:** Dalla limitatezza $\mathbb{P}(A \cup B) \leq 1$ e dal principio di inclusione-esclusione:

$$\mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B) \leq 1 \implies \mathbb{P}(A \cap B) \geq \mathbb{P}(A) + \mathbb{P}(B) - 1 \quad \blacksquare \quad (2.13)$$

■




Figura 2.2: Geometria del principio di Inclusion-Esclusione di Poincaré a tre insiemi (A , B , C). Sommando le singole aree $\mathbb{P}(A) + \mathbb{P}(B) + \mathbb{P}(C)$, le intersezioni a due a due vengono contate due volte e devono essere sottratte; l'intersezione a tre $A \cap B \cap C$, essendo stata aggiunta 3 volte e sottratta 3 volte, deve essere infine ri-aggiunta per bilanciare la misura totale.

Teorema 2.4: Formula Generale di Inclusion-Esclusione di Poincaré (n Eventi)

Dati n eventi $A_1, A_2, \dots, A_n \in \mathcal{F}$:

$$\mathbb{P}\left(\bigcup_{i=1}^n A_i\right) = \sum_{i=1}^n \mathbb{P}(A_i) - \sum_{1 \leq i < j \leq n} \mathbb{P}(A_i \cap A_j) + \sum_{1 \leq i < j < k \leq n} \mathbb{P}(A_i \cap A_j \cap A_k) - \dots + (-1)^{n-1} \mathbb{P}\left(\bigcap_{i=1}^n A_i\right) \quad (2.14)$$

In particolare, per $n = 3$ eventi:

$$\begin{aligned} \mathbb{P}(A \cup B \cup C) &= \mathbb{P}(A) + \mathbb{P}(B) + \mathbb{P}(C) \\ &\quad - [\mathbb{P}(A \cap B) + \mathbb{P}(A \cap C) + \mathbb{P}(B \cap C)] + \mathbb{P}(A \cap B \cap C) \end{aligned} \quad (2.15)$$

2.4 Calcolo Combinatorio e Tecniche di Conteggio

Negli spazi campionari finiti ed equiprobabili, la valutazione della probabilità classica richiede il conteggio accurato della cardinalità $|\Omega|$ e $|E|$. Il calcolo combinatorio fornisce gli strumenti sistematici per quantificare il numero di configurazioni possibili a seconda che:

- **L'ordine degli elementi conti oppure no** (sequenze ordinate vs sottoinsiemi non ordinati);
- **Sia ammessa o meno la ripetizione/reimmissione dello stesso elemento.**

Tabella 2.1: Quadro sinottico completo delle formule di Calcolo Combinatorio per l'estrazione di k elementi da un insieme di n elementi distinti.

Modalità di Conteggio	Senza Ripetizione (Semplici)	Con Ripetizione (Reimmis)
Disposizioni (L'ordine conta)	$D_{n,k} = \frac{n!}{(n-k)!}$	$D'_{n,k} = n^k$
Permutazioni ($k = n$, l'ordine conta)	$P_n = n!$	$P_n^{(n_1, \dots, n_m)} = \frac{n!}{n_1! n_2! \dots n_m!}$
Combinazioni (L'ordine non conta)	$C_{n,k} = \binom{n}{k} = \frac{n!}{k!(n-k)!}$	$C'_{n,k} = \binom{n+k-1}{k}$

Il Coefficiente Binomiale e le sue Proprietà Algebriche. Il coefficiente binomiale $\binom{n}{k}$ quantifica il numero di sottoinsiemi distinti di taglia k estraibili da un insieme di cardinalità n . Gode delle celebri proprietà:

1. **Simmetria complementare:** $\binom{n}{k} = \binom{n}{n-k}$.
2. **Formula ricorsiva di Stifel (Triangolo di Tartaglia-Pascal):** $\binom{n}{k} = \binom{n-1}{k-1} + \binom{n-1}{k}$.
3. **Teorema del Binomio di Newton:** $\sum_{k=0}^n \binom{n}{k} a^k b^{n-k} = (a+b)^n \implies \sum_{k=0}^n \binom{n}{k} = 2^n$.

2.5 Problemi Classici ed Esempi Notabili: Il Paradosso del Compleanno

Un esempio cardine che evidenzia come l'intuizione umana fallisca sistematicamente nella stima delle probabilità combinatorie è il ****Paradosso del Compleanno**** (*Birthday Paradox*).

Esercizio Guidato 2.1: Il Paradosso del Compleanno

In un'aula universitaria sono presenti n studenti. Assumendo l'anno composto da $N = 365$ giorni equiprobabili e trascurando gli anni bisestili e i parti gemellari:

- (a) Determinare la formula esatta per la probabilità $p(n)$ che almeno due persone condividano lo stesso giorno di compleanno.
- (b) Ricavare l'approssimazione esponenziale asintotica per grandi N .
- (c) Determinare il numero minimo di persone n^* affinché la probabilità superi il 50% ($p(n^*) \geq 0.5$).

Dimostrazione. (a) **Risoluzione tramite l'evento complementare:** Sia E l'evento "almeno due persone compiono gli anni lo stesso giorno". L'evento complementare E^c è "tutti gli n studenti compiono gli anni in n giorni rigorosamente distinti dell'anno".

- Il numero di esiti possibili totali nello spazio campionario è $|\Omega| = 365^n$ (disposizioni con ripetizione).
- Il numero di configurazioni favorevoli a E^c corrisponde alla scelta di n date distinte in sequenza ordinata:

$$|E^c| = D_{365,n} = 365 \cdot 364 \cdot 363 \dots (365 - n + 1) = \frac{365!}{(365 - n)!} \quad (2.16)$$

La probabilità esatta dell'evento complementare è quindi:

$$\mathbb{P}(E^c) = \frac{D_{365,n}}{365^n} = \prod_{i=1}^{n-1} \left(1 - \frac{i}{365}\right) = 1 \cdot \left(1 - \frac{1}{365}\right) \left(1 - \frac{2}{365}\right) \dots \left(1 - \frac{n-1}{365}\right) \quad (2.17)$$

La probabilità cercata è:

$$p(n) = \mathbb{P}(E) = 1 - \mathbb{P}(E^c) = 1 - \prod_{i=1}^{n-1} \left(1 - \frac{i}{365}\right) \quad (2.18)$$

(b) Derivazione dell'Approssimazione Esponenziale di Taylor: Sfruttando lo sviluppo in serie di Taylor $e^{-x} \approx 1 - x$ valido per $x \ll 1$, possiamo approssimare ogni singolo fattore $1 - \frac{i}{365} \approx e^{-i/365}$:

$$\mathbb{P}(E^c) \approx \prod_{i=1}^{n-1} e^{-i/365} = \exp\left(-\sum_{i=1}^{n-1} \frac{i}{365}\right) = \exp\left(-\frac{1}{365} \frac{(n-1)n}{2}\right) = \exp\left(-\frac{n(n-1)}{730}\right) \quad (2.19)$$

Pertanto, la curva di probabilità approssimata è data dalla funzione logistica:

$$p(n) \approx 1 - \exp\left(-\frac{n^2}{2 \cdot 365}\right) \quad (2.20)$$

(c) Calcolo della Soglia Critica n^* per $p(n) \geq 0.5$: Ponendo l'approssimazione esponenziale ≥ 0.5 :

$$1 - e^{-\frac{n^2}{730}} \geq 0.5 \iff e^{-\frac{n^2}{730}} \leq 0.5 \iff -\frac{n^2}{730} \leq \ln(0.5) = -\ln(2) \quad (2.21)$$

Moltiplicando per -730 e invertendo il verso:

$$n^2 \geq 730 \cdot \ln(2) \approx 730 \cdot 0.693147 = 505.997 \implies n \geq \sqrt{505.997} \approx 22.49 \quad (2.22)$$

Calcolando i valori esatti:

- Per $n = 22$: $p(22) = 0.4757$ (47.57%).
- Per $n = 23$: $p(23) = 0.5073$ (**50.73%**).

Bastano quindi appena **$n = 23$** persone affinché la probabilità superi il 50%. Il paradosso intuitivo svanisce se si considera che con $n = 23$ persone non stiamo confrontando i compleanni con una data fissa, ma stiamo generando $\binom{23}{2} = \frac{23 \cdot 22}{2} = \mathbf{253}$ coppie distinte di confronti simultanei. ■

CAPITOLO 3

Probabilità Condizionata, Formula di Bayes e Indipendenza

Sintesi del Capitolo. *Il presente capitolo esplora il cuore dinamico della teoria delle probabilità: l'aggiornamento razionale delle credenze e delle previsioni a fronte dell'acquisizione di nuova evidenza sperimentale o informativa. Viene formalizzata la probabilità condizionata come restrizione geometrica dello spazio campionario e si derivano la regola moltiplicativa e la formula a catena. Si dimostrano analiticamente il Teorema delle Probabilità Totali e il celebre Teorema di Bayes, pilastro dell'inferenza statistica moderna e del decision making razionale. Viene approfondito il paradosso dei falsi positivi nei test diagnostici e nei controlli di qualità industriale. Infine, si analizza la nozione di indipendenza stocastica, evidenziandone la netta cesura logica rispetto all'incompatibilità insiemistica e sviscerando la distinzione tra indipendenza a due a due e mutua indipendenza globale.*

3.1 Il Concetto di Informazione e la Probabilità Condizionata

Nel mondo reale e nei processi ingegneristici, lo stato di informazione dell'osservatore non è mai statico. Quando valutiamo l'affidabilità di un circuito elettronico, il verificarsi di un guasto a un primo componente ausiliario modifica radicalmente la probabilità che il sistema complessivo collassi. Analogamente, la conoscenza dell'esito di un sensore di allarme ricalibra la nostra stima sulla presenza di un'anomalia di funzionamento.

La **probabilità condizionata** formalizza esattamente questa dinamica: come varia la probabilità dell'evento E una volta acquisita la certezza empirica che un altro evento F si è già verificato.

Definizione 3.1: Probabilità Condizionata

Siano $E, F \in \mathcal{F}$ due eventi su uno spazio di probabilità $(\Omega, \mathcal{F}, \mathbb{P})$, con $\mathbb{P}(F) > 0$. Si definisce **probabilità condizionata** di E dato F , denotata con $\mathbb{P}(E | F)$, la quantità:

$$\mathbb{P}(E | F) = \frac{\mathbb{P}(E \cap F)}{\mathbb{P}(F)} \quad (3.1)$$

Interpretazione Geometrica e Insiemistica: La Restrizione dell'Universo. Il condizionamento ad un evento F corrisponde geometricamente ad una **traslazione e riscalatura** dello spazio campionario:

1. L'evento condizionante F diventa il *nuovo spazio campionario certo*. Tutti gli esiti $\omega \in \Omega \setminus F$ hanno ora probabilità rigorosamente nulla, poiché sappiamo con certezza che essi non si sono verificati.
2. Gli unici esiti elementari ancora compatibili con l'evento E sono quelli appartenenti all'intersezione $E \cap F$.
3. Poiché la misura di probabilità originaria di F era $\mathbb{P}(F) < 1$, per ripristinare il secondo assioma di Kolmogorov (la certezza che $\mathbb{P}(F | F) = 1$) è indispensabile dividere per il fattore di normalizzazione $\mathbb{P}(F)$.

Proprietà 3.2: Validità degli Assiomi di Kolmogorov per la Misura Condizionata

Fissato un evento $F \in \mathcal{F}$ con $\mathbb{P}(F) > 0$, la funzione $Q(E) := \mathbb{P}(E | F)$ definita su $\mathcal{F}$ costituisce a tutti gli effetti una genuina misura di probabilità su $(\Omega, \mathcal{F})$, e rispetta:

1. **Non negatività:** $0 \leq \mathbb{P}(E | F) \leq 1$ per ogni $E \in \mathcal{F}$.
2. **Certezza:** $\mathbb{P}(\Omega | F) = \frac{\mathbb{P}(\Omega \cap F)}{\mathbb{P}(F)} = \frac{\mathbb{P}(F)}{\mathbb{P}(F)} = 1$, ed in particolare $\mathbb{P}(F | F) = 1$.
3. **σ -additività:** Per ogni sequenza di eventi disgiunti a due a due $\{E_n\}_{n=1}^{\infty}$:

$$\mathbb{P}\left(\bigcup_{n=1}^{\infty} E_n \mid F\right) = \sum_{n=1}^{\infty} \mathbb{P}(E_n | F) \quad (3.2)$$

Ne consegue che tutti i teoremi dimostrati nel Capitolo 2 (probabilità del complementare, monotonia, inclusione-esclusione) continuano a valere immutati sotto il condizionamento a F , ad esempio:

$$\mathbb{P}(E^c | F) = 1 - \mathbb{P}(E | F), \quad \mathbb{P}(A \cup B | F) = \mathbb{P}(A | F) + \mathbb{P}(B | F) - \mathbb{P}(A \cap B | F) \quad (3.3)$$

3.1.1 Regola del Prodotto e Formula a Catena

Invertendo la definizione di probabilità condizionata, otteniamo lo strumento primario per calcolare la probabilità del verificarsi congiunto di una sequenza di eventi dipendenti nel tempo.

Proposizione 3.3: Regola Moltiplicativa (Regola del Prodotto)

Per qualsiasi coppia di eventi $E, F \in \mathcal{F}$:

$$\mathbb{P}(E \cap F) = \mathbb{P}(F) \cdot \mathbb{P}(E | F) = \mathbb{P}(E) \cdot \mathbb{P}(F | E) \quad (3.4)$$

Teorema 3.4: Formula a Catena (Chain Rule)

Dati n eventi $E_1, E_2, \dots, E_n \in \mathcal{F}$ con $\mathbb{P}(E_1 \cap E_2 \cap \dots \cap E_{n-1}) > 0$:

$$\mathbb{P}(E_1 \cap E_2 \cap \dots \cap E_n) = \mathbb{P}(E_1) \cdot \mathbb{P}(E_2 | E_1) \cdot \mathbb{P}(E_3 | E_1 \cap E_2) \dots \mathbb{P}(E_n | E_1 \cap \dots \cap E_{n-1}) \quad (3.5)$$

3.2 Il Teorema delle Probabilità Totali

Spesso la valutazione diretta della probabilità di un evento complesso E risulta impraticabile. Tuttavia, se il fenomeno può verificarsi sotto diverse condizioni o cause mutuamente esclusive $\{F_1, \dots, F_k\}$, possiamo decomporre il calcolo in contributi ponderati più semplici.

Definizione 3.5: Partizione dello Spazio Campionario

Una famiglia finita o numerabile di eventi $\{F_1, F_2, \dots, F_k\} \subset \mathcal{F}$ costituisce una **partizione** dello spazio campionario Ω se:

1. Gli eventi sono a due a due disgiunti (mutuamente incompatibili): $F_i \cap F_j = \emptyset, \forall i \neq j$;
2. Gli eventi sono esaustivi (ricoprono l'intero universo): $\bigcup_{i=1}^k F_i = \Omega$;
3. Ciascun evento ha probabilità non nulla: $\mathbb{P}(F_i) > 0, \forall i = 1, \dots, k$.




Figura 3.1: Decomposizione dell'evento E indotta da una partizione dello spazio campionario $\{F_1, F_2, F_3, F_4\}$. L'evento E viene sezionato nei frammenti disgiunti $E \cap F_i$. L'area complessiva di E è data dalla somma pesata delle probabilità condizionate $\mathbb{P}(E | F_i)$ moltiplicate per le probabilità delle cause $\mathbb{P}(F_i)$.

Teorema 3.6: Teorema delle Probabilità Totali (Legge delle Alternative)

Sia $\{F_1, F_2, \dots, F_k\}$ una partizione di Ω . Allora per ogni evento $E \in \mathcal{F}$:

$$\mathbb{P}(E) = \sum_{i=1}^k \mathbb{P}(E \cap F_i) = \sum_{i=1}^k \mathbb{P}(E | F_i) \cdot \mathbb{P}(F_i) \quad (3.6)$$

Dimostrazione. Poiché $\bigcup_{i=1}^k F_i = \Omega$, possiamo intersecare l'evento E con lo spazio campionario:

$$E = E \cap \Omega = E \cap \left(\bigcup_{i=1}^k F_i \right) = \bigcup_{i=1}^k (E \cap F_i) \quad (3.7)$$

Gli insiemi $\{E \cap F_i\}_{i=1}^k$ sono a due a due disgiunti poiché lo sono i sottoinsiemi F_i :

$$(E \cap F_i) \cap (E \cap F_j) = E \cap (F_i \cap F_j) = E \cap \emptyset = \emptyset \quad (\forall i \neq j) \quad (3.8)$$

Applicando il terzo assioma di Kolmogorov (σ -additività finita) e successivamente la regola moltiplicativa $\mathbb{P}(E \cap F_i) = \mathbb{P}(E | F_i) \mathbb{P}(F_i)$:

$$\mathbb{P}(E) = \mathbb{P} \left(\bigcup_{i=1}^k (E \cap F_i) \right) = \sum_{i=1}^k \mathbb{P}(E \cap F_i) = \sum_{i=1}^k \mathbb{P}(E | F_i) \cdot \mathbb{P}(F_i) \quad \blacksquare \quad (3.9)$$

■

3.3 Il Teorema di Bayes e l'Inversione delle Cause

Formulato originariamente dal reverendo Thomas Bayes e pubblicato postumo nel 1763, il ****Teorema di Bayes**** rappresenta il principio cardine dell'apprendimento e dell'inferenza statistica. Esso risponde a una domanda epistemologica inversa: **sapendo che si è verificato un certo effetto E , qual è la probabilità che tale effetto sia stato originato dalla specifica causa o ipotesi F_j ?*




Figura 3.2: Rappresentazione ad albero delle decisioni per il Teorema di Bayes. Al primo livello ramificano le cause a priori $F_1, \dots, F_k$ con probabilità $\mathbb{P}(F_i)$. Al secondo livello si sviluppano gli esiti condizionati E ed E^c . Il Teorema di Bayes calcola la probabilità di percorrere a ritroso uno specifico ramo dato l'effetto osservato E .

Teorema 3.7: Teorema di Bayes (Formula di Inversione delle Cause)

Sia $\{F_1, F_2, \dots, F_k\}$ una partizione di Ω , e sia $E \in \mathcal{F}$ un evento osservato con $\mathbb{P}(E) > 0$. Per ogni $j \in \{1, \dots, k\}$, la **probabilità a posteriori** della causa F_j dato l'effetto E è:

$$\mathbb{P}(F_j | E) = \frac{\mathbb{P}(E | F_j) \cdot \mathbb{P}(F_j)}{\mathbb{P}(E)} = \frac{\mathbb{P}(E | F_j) \cdot \mathbb{P}(F_j)}{\sum_{i=1}^k \mathbb{P}(E | F_i) \cdot \mathbb{P}(F_i)} \quad (3.10)$$

Dimostrazione. Dalla definizione di probabilità condizionata:

$$\mathbb{P}(F_j | E) = \frac{\mathbb{P}(F_j \cap E)}{\mathbb{P}(E)} \quad (3.11)$$

Applicando al numeratore la regola moltiplicativa $\mathbb{P}(F_j \cap E) = \mathbb{P}(E | F_j)\mathbb{P}(F_j)$ e al denominatore il Teorema delle Probabilità Totali $\mathbb{P}(E) = \sum_{i=1}^k \mathbb{P}(E | F_i)\mathbb{P}(F_i)$, si perviene direttamente alla tesi. ■

Nomenclatura e Struttura dell'Aggiornamento Bayesiano:

- $\mathbb{P}(F_j)$: **Probabilità a priori** (*prior probability*) della causa F_j , prima dell'osservazione dell'effetto E .
- $\mathbb{P}(E | F_j)$: **Verosimiglianza** (*likelihood*) dell'evidenza E data l'ipotesi F_j .
- $\mathbb{P}(E) = \sum \mathbb{P}(E | F_i)\mathbb{P}(F_i)$: **Fattore di scala o evidenza marginale** (*evidence*).
- $\mathbb{P}(F_j | E)$: **Probabilità a posteriori** (*posterior probability*), che combina informazione a priori ed evidenza empirica.

3.3.1 Applicazione Fondamentale: Il Paradosso dei Falsi Positivi

Un'applicazione classica che illustra la potenza del Teorema di Bayes e le trappole dell'intuizione comune riguarda i test diagnostici e il controllo di qualità industriale.

Esercizio Guidato 3.1: Test Diagnostico per Malattia Rara (Il Paradosso dei Falsi Positivi)

Si consideri una patologia rara che colpisce lo 0.1% della popolazione (prevalenza a priori $\mathbb{P}(M) = 0.001$). È disponibile un test clinico con le seguenti prestazioni:

- **Sensibilità** (probabilità che il test sia positivo se la persona è malata): $\mathbb{P}(T^+ | M) = 0.99$.
- **Specificità** (probabilità che il test sia negativo se la persona è sana): $\mathbb{P}(T^- | S) = 0.98 \implies \mathbb{P}(T^+ | S) = 0.02$ (tasso di falsi allarmi).

Un individuo estratto a caso dalla popolazione risulta positivo al test (T^+). Qual è la reale probabilità che sia effettivamente malato ($\mathbb{P}(M | T^+)$)?

Dimostrazione. La popolazione è partizionata in M (malati) ed $S = M^c$ (sani), con $\mathbb{P}(M) = 0.001$ e $\mathbb{P}(S) = 0.999$. Calcoliamo la probabilità totale che un test risulti positivo:

$$\begin{aligned}\mathbb{P}(T^+) &= \mathbb{P}(T^+ | M)\mathbb{P}(M) + \mathbb{P}(T^+ | S)\mathbb{P}(S) \\ &= (0.99 \times 0.001) + (0.02 \times 0.999) = 0.00099 + 0.01998 = \mathbf{0.02097} \quad (2.097\%)\end{aligned}$$

Applicando il Teorema di Bayes per ricavare la probabilità a posteriori:

$$\mathbb{P}(M | T^+) = \frac{\mathbb{P}(T^+ | M)\mathbb{P}(M)}{\mathbb{P}(T^+)} = \frac{0.00099}{0.02097} \approx \mathbf{0.0472} \quad (4.72\%)$$

Commento critico: Nonostante il test abbia un'accuratezza nominale altissima (99% e 98%), se un paziente riceve un esito positivo la probabilità reale di essere malato è appena del **4.72%**! Oltre il 95% dei positivi sono falsi allarmi. Ciò è dovuto al fatto che, essendo la malattia rarissima, la piccolissima percentuale di errore applicata alla stragrande maggioranza della popolazione sana ($0.02 \times 99.9\%$) produce un numero assoluto di falsi positivi nettamente superiore ai veri positivi ($0.99 \times 0.1\%$). ■

3.4 Indipendenza Stocastica

Definizione 3.8: Indipendenza Stocastica tra Due Eventi

Due eventi $E, F \in \mathcal{F}$ si dicono **stocasticamente indipendenti** (denotato con $E \perp\!\!\!\perp F$) se e solo se la probabilità della loro intersezione è uguale al prodotto delle loro probabilità marginali:

$$\mathbb{P}(E \cap F) = \mathbb{P}(E) \cdot \mathbb{P}(F) \quad (3.12)$$

Se $\mathbb{P}(F) > 0$, l'indipendenza equivale all'invarianza informativa del condizionamento:

$$\mathbb{P}(E | F) = \mathbb{P}(E) \quad (3.13)$$

Teorema 3.9: Indipendenza dei Complementari

Se E ed F sono stocasticamente indipendenti, allora sono indipendenti anche:

1. E ed F^c ;

2. E^c ed F ;
3. E^c ed F^c .

Dimostrazione per E ed F^c . Scomponiamo l'evento E nell'unione disgiunta $E = (E \cap F) \cup (E \cap F^c)$. Per la proprietà additiva:

$$\mathbb{P}(E) = \mathbb{P}(E \cap F) + \mathbb{P}(E \cap F^c) \quad (3.14)$$

Sfruttando l'indipendenza tra E ed F , sostituiamo $\mathbb{P}(E \cap F) = \mathbb{P}(E)\mathbb{P}(F)$:

$$\mathbb{P}(E \cap F^c) = \mathbb{P}(E) - \mathbb{P}(E)\mathbb{P}(F) = \mathbb{P}(E)(1 - \mathbb{P}(F)) = \mathbb{P}(E)\mathbb{P}(F^c) \quad \blacksquare \quad (3.15)$$

■

3.4.1 Indipendenza a Due a Due vs Mutua Indipendenza Globale

Quando si considerano tre o più eventi, la condizione di indipendenza a coppie **non è sufficiente** a garantire la mutua indipendenza globale.

Definizione 3.10: Mutua Indipendenza Globale di n Eventi

Una famiglia di n eventi $\{E_1, E_2, \dots, E_n\} \subset \mathcal{F}$ si dice **mutuamente indipendente** se per ogni sottoinsieme finito di indici $\{i_1, i_2, \dots, i_k\} \subseteq \{1, \dots, n\}$ con $2 \leq k \leq n$, si ha:

$$\mathbb{P}\left(\bigcap_{j=1}^k E_{i_j}\right) = \prod_{j=1}^k \mathbb{P}(E_{i_j}) \quad (3.16)$$

Per $n = 3$ eventi (A, B, C) , la mutua indipendenza richiede la validità simultanea di $2^3 - 3 - 1 = 4$ equazioni:

$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B) \quad (3.17)$$

$$\mathbb{P}(A \cap C) = \mathbb{P}(A)\mathbb{P}(C) \quad (3.18)$$

$$\mathbb{P}(B \cap C) = \mathbb{P}(B)\mathbb{P}(C) \quad (3.19)$$

$$\mathbb{P}(A \cap B \cap C) = \mathbb{P}(A)\mathbb{P}(B)\mathbb{P}(C) \quad (3.20)$$

Esempio 3.2: Controesempio di Bernstein: Indipendenza a Due a Due Senza Mutua Indipendenza

Si consideri un tetraedro regolare con quattro facce equiprobabili (probabilità $1/4$ ciascuna), colorate nel modo seguente:

- Faccia 1: Rossa (R)
- Faccia 2: Verde (V)
- Faccia 3: Bianca (B)
- Faccia 4: Contiene tutti e tre i colori (R, V, B)

Definiamo gli eventi: A = La faccia contiene il Rosso, B = La faccia contiene il Verde, C = La faccia contiene il Bianco.

- Ciascun colore è presente su 2 facce (la propria faccia monocromatica e la faccia 4),

quindi:

$$\mathbb{P}(A) = \frac{2}{4} = \frac{1}{2}, \quad \mathbb{P}(B) = \frac{1}{2}, \quad \mathbb{P}(C) = \frac{1}{2}$$

- La compresenza di due colori (es. $A \cap B$) si verifica esclusivamente se esce la faccia 4:

$$\mathbb{P}(A \cap B) = \frac{1}{4} = \frac{1}{2} \cdot \frac{1}{2} = \mathbb{P}(A)\mathbb{P}(B)$$

Analogamente $\mathbb{P}(A \cap C) = 1/4 = \mathbb{P}(A)\mathbb{P}(C)$ e $\mathbb{P}(B \cap C) = 1/4 = \mathbb{P}(B)\mathbb{P}(C)$. Gli eventi sono dunque **indipendenti a due a due**.

- Tuttavia, la compresenza simultanea di tutti e tre i colori $A \cap B \cap C$ avviene sempre e solo sulla faccia 4:

$$\mathbb{P}(A \cap B \cap C) = \frac{1}{4} \neq \mathbb{P}(A)\mathbb{P}(B)\mathbb{P}(C) = \frac{1}{2} \cdot \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{8}$$

Questo dimostra che la conoscenza congiunta di A e B determina con certezza l'evento C ($\mathbb{P}(C \mid A \cap B) = 1 \neq \mathbb{P}(C)$), distruggendo l'indipendenza globale.

3.5 Consigli per l'Esame e Trappole Ricorrenti

Trappola: Eventi Disgiunti (Incompatibili) vs Eventi Indipendenti

Questa è una delle trappole concettuali più insidiose nei test d'esame:

- Due eventi A e B sono ****disgiunti**** se non possono verificarsi insieme nel medesimo esperimento: $A \cap B = \emptyset \implies \mathbb{P}(A \cap B) = 0$. (È una proprietà insiemistica-geometrica).
- Due eventi sono ****indipendenti**** se $\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)$. (È una proprietà quantitativo-informativa).
- Se $\mathbb{P}(A) > 0$ e $\mathbb{P}(B) > 0$, due eventi disgiunti **NON POSSONO MAI ESSERE INDIPENDENTI!** Infatti:

$$\mathbb{P}(A \cap B) = 0 \neq \mathbb{P}(A)\mathbb{P}(B) > 0$$

Intuitivamente, sapere che A si è verificato ci dà l'informazione certissima che B non può assolutamente essersi verificato ($\mathbb{P}(B \mid A) = 0 \neq \mathbb{P}(B)$), massima forma possibile di dipendenza informativa!

CAPITOLO 4

Variabili Aleatorie Discrete, Continue e Vettori Aleatori

Sintesi del Capitolo. *Il presente capitolo opera la transizione concettuale fondamentale dalla teoria degli insiemi astratti alla modellazione quantitativa mediante funzioni a valori reali: le variabili aleatorie. Viene formalizzata la nozione di misurabilità e analizzata la Funzione di Ripartizione (CDF) come descrittore universale sia per leggi discrete che per leggi continue. Si approfondiscono le specificità delle variabili discrete (PMF) e delle variabili assolutamente continue (PDF), chiarendo la natura infinitesima della densità e il significato epistemologico della probabilità puntuale nulla. Nella seconda parte, la teoria viene estesa ai vettori aleatori bivariati: densità congiunte, distribuzioni marginali, leggi condizionate, indipendenza stocastica e la formula analitica del cambio di variabile con fattore Jacobiano di distorsione geometrica.*

4.1 Il Concetto di Variabile Aleatoria e la Funzione di Ripartizione (CDF)

Fino ad ora abbiamo trattato gli esiti sperimentali come elementi qualitativi o insiemistici di uno spazio campionario astratto Ω (ad esempio, sequenze di teste e croci, colori di biglie o campioni di guasto). Tuttavia, per applicare gli strumenti del calcolo differenziale e integrale, dell'algebra lineare e dell'analisi numerica, è indispensabile tradurre ciascun esito elementare $\omega \in \Omega$ in una grandezza numerica quantitativa reale $x \in \mathbb{R}$.

Definizione 4.1: Variabile Aleatoria Reale

Sia $(\Omega, \mathcal{F}, \mathbb{P})$ uno spazio di probabilità. Una **variabile aleatoria reale** (v.a.) X è una funzione misurabile che mappa lo spazio campionario nella retta reale:

$$X : \Omega \longrightarrow \mathbb{R}, \quad \omega \longmapsto X(\omega) \quad (4.1)$$

La condizione di **misurabilità** impone che per ogni intervallo di Borel $I \subseteq \mathbb{R}$, l'insieme degli esiti elementari la cui immagine ricade in I sia un evento appartenente alla σ -algebra $\mathcal{F}$:

$$\{\omega \in \Omega : X(\omega) \in I\} \equiv X^{-1}(I) \in \mathcal{F} \quad (4.2)$$

L'insieme dei valori effettivamente assunti dalla funzione è detto **supporto** o immagine della variabile aleatoria: $\text{Im}(X) = X(\Omega) \subseteq \mathbb{R}$.

Per caratterizzare probabilisticamente il comportamento di X senza dover fare continuamente riferimento allo spazio originario Ω , si introduce la ****Funzione di Ripartizione Cumulativa****.

Definizione 4.2: Funzione di Ripartizione Cumulativa (CDF)

La **funzione di ripartizione** (o Cumulative Distribution Function, CDF) di una variabile aleatoria X è la funzione a valori reali $F_X : \mathbb{R} \rightarrow [0, 1]$ definita da:

$$F_X(x) := \mathbb{P}(X \leq x) = \mathbb{P}(\{\omega \in \Omega : X(\omega) \leq x\}) \quad (4.3)$$

Teorema 4.3: Proprietà Caratteristiche Fondamentali della CDF

Qualsiasi funzione di ripartizione $F_X(x)$ soddisfa inderogabilmente le seguenti quattro proprietà matematiche:

1. **Monotonia non decrescente:** Se $x_1 < x_2$, allora $F_X(x_1) \leq F_X(x_2)$ (perché $\{X \leq x_1\} \subseteq \{X \leq x_2\}$).

2. **Limiti agli estremi:**

$$\lim_{x \rightarrow -\infty} F_X(x) = \mathbb{P}(\emptyset) = 0, \quad \lim_{x \rightarrow +\infty} F_X(x) = \mathbb{P}(\Omega) = 1 \quad (4.4)$$

3. **Continuità da destra:** Per ogni $x_0 \in \mathbb{R}$, $F_X(x_0^+) := \lim_{h \rightarrow 0^+} F_X(x_0 + h) = F_X(x_0)$.

4. **Probabilità degli intervalli e ampiezza dei salti:**

$$\mathbb{P}(a < X \leq b) = F_X(b) - F_X(a) \quad (4.5)$$

$$\mathbb{P}(X < x_0) = F_X(x_0^-) := \lim_{h \rightarrow 0^+} F_X(x_0 - h) \quad (4.6)$$

$$\mathbb{P}(X = x_0) = F_X(x_0) - F_X(x_0^-) = \text{ampiezza del salto di discontinuità in } x_0 \quad (4.7)$$




Figura 4.1: Confronto tipologico tra la CDF di una variabile discreta (a sinistra), caratterizzata da una struttura a scalini con salti finiti nei punti del supporto, e la CDF di una variabile assolutamente continua (a destra), priva di salti e ovunque continua e derivabile.

4.2 Variabili Aleatorie Discrete e Funzione di Massa (PMF)

Definizione 4.4: Variabile Aleatoria Discreta e PMF

Una variabile aleatoria X si dice **discreta** se il suo supporto $\text{Im}(X) = \{x_1, x_2, \dots\}$ è un insieme finito o al più numerabile (isomorfo a $\mathbb{N}$). La sua distribuzione è descritta dalla **funzione di massa di probabilità** (Probability Mass Function, PMF) $p_X(x)$:

$$p_X(x) := \mathbb{P}(X = x) \quad (4.8)$$

La PMF soddisfa i vincoli di positività e normalizzazione:

$$p_X(x) \geq 0 \quad \forall x \in \text{Im}(X), \quad \sum_{x \in \text{Im}(X)} p_X(x) = 1 \quad (4.9)$$

La CDF associata è una funzione a scalini monotona crescente:

$$F_X(x) = \sum_{x_k \leq x} p_X(x_k) \quad (4.10)$$

4.3 Variabili Aleatorie Continue e Funzione di Densità (PDF)

Nelle grandezze fisiche come tempo, massa, temperatura o pressione, il supporto della variabile aleatoria è un continuo (un intervallo o l'intera retta reale $\mathbb{R}$).

Definizione 4.5: Variabile Aleatoria Assolutamente Continua e PDF

Una variabile aleatoria X si dice **assolutamente continua** se esiste una funzione integrabile e non negativa $f_X : \mathbb{R} \rightarrow [0, \infty)$, detta **funzione di densità di probabilità** (Probability Density Function, PDF), tale che:

$$F_X(x) = \mathbb{P}(X \leq x) = \int_{-\infty}^x f_X(t) dt \quad (\forall x \in \mathbb{R}) \quad (4.11)$$

Una PDF ammissibile deve soddisfare le due condizioni:

$$f_X(x) \geq 0 \quad \forall x \in \mathbb{R}, \quad \int_{-\infty}^{+\infty} f_X(x) dx = 1 \quad (4.12)$$

Nei punti in cui f_X è continua, per il Teorema Fondamentale del Calcolo Integrale si ha:

$$f_X(x) = \frac{d}{dx} F_X(x) = F'_X(x) \quad (4.13)$$

Il Paradosso della Probabilità Puntuale Nulla nel Continuo: $\mathbb{P}(X = x_0) = 0$. Un aspetto che genera frequente smarrimento è che, per una variabile continua, la probabilità che X assuma un qualsiasi valore puntuale prefissato $x_0 \in \mathbb{R}$ è ****rigorosamente pari a zero****:

$$\mathbb{P}(X = x_0) = \int_{x_0}^{x_0} f_X(t) dt = 0 \quad (4.14)$$

Come può un evento avere probabilità zero senza essere impossibile? L'analogia fisica chiarificatrice è quella della densità di massa di un corpo continuo. Un'asta metallica di massa totale pari a 1 kg possiede una densità lineare $\rho(x)$ kg/m. Un singolo punto geometrico x_0




Figura 4.2: Significato geometrico della funzione di densità $f_X(x)$. La probabilità che X assuma valori nell'intervallo infinitesimo $[x, x + dx]$ è l'area del rettangolo elementare $f_X(x)dx$. La probabilità dell'intervallo $[a, b]$ corrisponde all'area totale sottesa dalla curva tra a e b .

ha volume nullo e dunque possiede massa rigorosamente zero ($dm = 0$). Tuttavia, l'asta è formata dall'unione di infiniti punti.

Nel continuo, il valore $f_X(x_0)$ non è una probabilità, ma una ****densità di probabilità locale per unità di lunghezza**** (misurata in $[\text{unità}]^{-1}$). La probabilità fisica non risiede mai nei singoli punti isolati, bensì nelle aree integrate su intervalli:

$$\mathbb{P}(a \leq X \leq b) = \mathbb{P}(a < X \leq b) = \mathbb{P}(a \leq X < b) = \mathbb{P}(a < X < b) = \int_a^b f_X(x) dx \quad (4.15)$$

4.4 Vettori Aleatori Bivariati, Distribuzioni Congiunte e Marginali

Definizione 4.6: Vettore Aleatorio Continuo e PDF Congiunta

Una coppia di variabili aleatorie (X, Y) definite sul medesimo spazio di probabilità forma un **vettore aleatorio bivariato in $\mathbb{R}^2$** . Se ammette una funzione di densità congiunta $f_{X,Y}(x, y) \geq 0$, la probabilità che il punto casuale (X, Y) cada in una regione bidimensionale $A \subseteq \mathbb{R}^2$ è data dall'integrale doppio:

$$\mathbb{P}((X, Y) \in A) = \iint_A f_{X,Y}(x, y) dx dy \quad (4.16)$$

con la condizione di normalizzazione sul piano $\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f_{X,Y}(x, y) dx dy = 1$.

4.4.1 Densità Marginali e Densità Condizionate

Definizione 4.7: Densità Marginali

Integrando la densità congiunta rispetto ad una delle due variabili su tutto il suo supporto, si ottiene la **densità marginale** della variabile residua (principio di saturazione dello spazio):

$$f_X(x) = \int_{-\infty}^{+\infty} f_{X,Y}(x, y) dy, \quad f_Y(y) = \int_{-\infty}^{+\infty} f_{X,Y}(x, y) dx \quad (4.17)$$

Definizione 4.8: Densità Condizionata

Fissato un valore x tale che $f_X(x) > 0$, la **funzione di densità condizionata** di Y dato $X = x$ è definita da:

$$f_{Y|X}(y | x) = \frac{f_{X,Y}(x, y)}{f_X(x)} \quad (4.18)$$

Essa rappresenta il profilo di sezione geometrica della superficie $f_{X,Y}(x, y)$ lungo la retta $X = x$, rinormalizzato affinché l'area sottesa lungo y sia esattamente unitaria: $\int_{-\infty}^{+\infty} f_{Y|X}(y | x) dy = 1$.

4.4.2 Indipendenza tra Variabili Aleatorie**Definizione 4.9: Indipendenza di Variabili Aleatorie**

Due variabili aleatorie X e Y si dicono **stocasticamente indipendenti** ($X \perp\!\!\!\perp Y$) se e solo se la funzione di ripartizione congiunta fattorizza nel prodotto delle CDF marginali per ogni coppia $(x, y) \in \mathbb{R}^2$:

$$F_{X,Y}(x, y) = F_X(x) \cdot F_Y(y) \quad (4.19)$$

Nel caso assolutamente continuo, ciò equivale alla fattorizzazione quasi ovunque della densità congiunta:

$$f_{X,Y}(x, y) = f_X(x) \cdot f_Y(y) \iff f_{Y|X}(y | x) = f_Y(y) \quad (4.20)$$

4.5 Trasformazioni di Variabili Aleatorie e Metodo dello Jacobiano

In molte applicazioni ingegneristiche si conosce la densità di una variabile di ingresso X e si desidera calcolare la densità della grandezza di uscita $Y = g(X)$ (ad esempio, tensione ai capi di un diodo non lineare $V = RI^2$).

Teorema 4.10: Trasformazione Monotona 1D

Sia X una v.a. continua con densità $f_X(x)$ e supporto (a, b) . Sia $Y = g(X)$ una trasformazione differenziabile e **strettamente monotona** (quindi invertibile con inversa $x = g^{-1}(y)$). Allora la densità di Y è data da:

$$f_Y(y) = f_X(g^{-1}(y)) \cdot \left| \frac{d}{dy} g^{-1}(y) \right| = \frac{f_X(x)}{|g'(x)|} \Big|_{x=g^{-1}(y)} \quad (4.21)$$

Dimostrazione per il caso strettamente crescente $g'(x) > 0$. Se g è strettamente crescente, l'evento $\{Y \leq y\}$ equivale a $\{g(X) \leq y\} = \{X \leq g^{-1}(y)\}$. Pertanto la CDF di Y è:

$$F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}(X \leq g^{-1}(y)) = F_X(g^{-1}(y)) \quad (4.22)$$

Derivando rispetto a y mediante la regola della catena (Teorema di derivazione delle funzioni composte):

$$f_Y(y) = \frac{d}{dy} F_Y(y) = F'_X(g^{-1}(y)) \cdot \frac{d}{dy} g^{-1}(y) = f_X(g^{-1}(y)) \cdot \frac{d}{dy} g^{-1}(y) \quad (4.23)$$

Nel caso decrescente compare un segno meno che viene assorbito dal valore assoluto $|\frac{d}{dy}g^{-1}(y)|$. ■ ■

CAPITOLO 5

Valore Atteso, Varianza, Covarianza e Disuguaglianze

Sintesi del Capitolo. Il presente capitolo sviluppa la teoria dei momenti e dei parametri sintetici che governano il comportamento probabilistico delle variabili aleatorie. Viene definito rigorosamente l'operatore lineare di speranza matematica $\mathbb{E}[\cdot]$, fornendo la giustificazione analitica della formula del trasferimento (LOTUS) e dimostrando la proprietà fondamentale dell'additività universale. Si analizzano la varianza teorica (con dimostrazione del Teorema di König-Huygens), la deviazione standard, la covarianza e la correlazione teorica ρ intesa come coseno geometrico nello spazio L^2 . Il capitolo culmina con le dimostrazioni analitiche complete delle disuguaglianze di concentrazione di Markov e di Chebyshev, pietre miliari per la convergenza stocastica e la Legge dei Grandi Numeri.

5.1 Valore Atteso (Speranza Matematica) e Principio del Baricentro

Se la funzione di probabilità (PMF o PDF) racchiude l'intera descrizione analitica di una variabile aleatoria, per scopi ingegneristici e decisionali è primario sintetizzare tale distribuzione attraverso parametri numerici scalari detti **momenti**.

Il momento del primo ordine più importante è il **valore atteso** (o speranza matematica / media teorica), che rappresenta la media probabilistica a lungo termine dei valori assunti dalla variabile.

Definizione 5.1: Valore Atteso (Speranza Matematica)

Sia $(\Omega, \mathcal{F}, \mathbb{P})$ uno spazio di probabilità e sia X una variabile aleatoria. Il **valore atteso** di X , denotato con $\mathbb{E}[X]$ o μ_X , è definito come:

- **Nel caso Discreto:**

$$\mathbb{E}[X] := \sum_{x \in \text{Im}(X)} x \cdot p_X(x) = \sum_x x \cdot \mathbb{P}(X = x) \quad (5.1)$$

a condizione che la serie converga assolutamente: $\sum_x |x| p_X(x) < +\infty$.

- **Nel caso Continuo:**

$$\mathbb{E}[X] := \int_{-\infty}^{+\infty} x \cdot f_X(x) dx \quad (5.2)$$

a condizione che l'integrale improprio converga assolutamente: $\int_{-\infty}^{+\infty} |x| f_X(x) dx < +\infty$.




Figura 5.1: Interpretazione fisica e meccanica del valore atteso come baricentro (centro di massa) della distribuzione di probabilità. Il punto $\mu = \mathbb{E}[X]$ rappresenta il fulcro su cui l'asse delle ascisse è in perfetto equilibrio statico rotazionale: $\sum (x_i - \mu)p(x_i) = 0$ oppure $\int (x - \mu)f(x)dx = 0$.

5.1.1 La Formula del Trasferimento (LOTUS)

Spesso non siamo interessati al valore atteso di X , bensì a quello di una sua trasformazione non lineare $Y = g(X)$ (ad esempio, il costo di gestione $C = aX^2 + b$). In linea di principio, occorrerebbe prima determinare la complessa densità $f_Y(y)$ e poi calcolare $\int y f_Y(y) dy$.

Il celebre Teorema del Trasferimento dimostra che questo passaggio intermedio è superfluo.

Teorema 5.2: Formula del Trasferimento (LOTUS - Law of the Unconscious Statistician)

Sia X una v.a. e sia $g : \mathbb{R} \rightarrow \mathbb{R}$ una funzione misurabile. Allora $\mathbb{E}[g(X)]$ può essere calcolato direttamente integrando $g(x)$ rispetto alla misura originaria di X :

$$\text{Nel discreto: } \mathbb{E}[g(X)] = \sum_{x \in \text{Im}(X)} g(x) \cdot p_X(x) \quad (5.3)$$

$$\text{Nel continuo: } \mathbb{E}[g(X)] = \int_{-\infty}^{+\infty} g(x) \cdot f_X(x) dx \quad (5.4)$$

Nel caso bivariato per una funzione $h(X, Y)$:

$$\mathbb{E}[h(X, Y)] = \iint_{\mathbb{R}^2} h(x, y) f_{X,Y}(x, y) dx dy \quad (5.5)$$

5.1.2 Linearità Universale del Valore Atteso

Teorema 5.3: Linearità dell'Operatore Valore Atteso

Siano X e Y due variabili aleatorie con valore atteso finito e siano $a, b \in \mathbb{R}$. Allora:

1. **Omogeneità e Traslazione:** $\mathbb{E}[aX + b] = a\mathbb{E}[X] + b$.
2. **Additività Universale:**

$$\mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y] \quad (5.6)$$

Attenzione fondamentale: L'additività del valore atteso è una proprietà algebrica universale dell'integrale e vale sempre, sia che X e Y siano indipendenti sia che siano fortemente dipendenti!

Proposizione 5.4: Valore Atteso del Prodotto di Variabili Indipendenti

Se X e Y sono variabili aleatorie **stocasticamente indipendenti**, allora:

$$\mathbb{E}[X \cdot Y] = \mathbb{E}[X] \cdot \mathbb{E}[Y] \quad (5.7)$$

5.2 Varianza Teorica e Deviazione Standard

La varianza misura l'entità media della dispersione quadratica della variabile aleatoria attorno al suo valore atteso μ .

Definizione 5.5: Varianza e Deviazione Standard

Sia X una variabile aleatoria con media $\mu = \mathbb{E}[X]$. Si definisce **varianza** di X :

$$\text{Var}(X) = \sigma^2 := \mathbb{E}[(X - \mu)^2] = \mathbb{E}[(X - \mathbb{E}[X])^2] \quad (5.8)$$

La **deviazione standard** (o scarto quadratico medio) è $\text{SD}(X) = \sigma = \sqrt{\text{Var}(X)}$.

Teorema 5.6: Formula di Calcolo di König-Huygens per la Varianza

La varianza ammette la forma computazionale fondamentale:

$$\text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 = \mathbb{E}[X^2] - \mu^2 \quad (5.9)$$

Dimostrazione. Sviluppando il quadrato all'interno del valore atteso e applicando la linearità:

$$\text{Var}(X) = \mathbb{E}[X^2 - 2\mu X + \mu^2] \quad (5.10)$$

$$= \mathbb{E}[X^2] - 2\mu\mathbb{E}[X] + \mathbb{E}[\mu^2] \quad (5.11)$$

$$= \mathbb{E}[X^2] - 2\mu(\mu) + \mu^2 = \mathbb{E}[X^2] - 2\mu^2 + \mu^2 = \mathbb{E}[X^2] - \mu^2 \quad \blacksquare \quad (5.12)$$

Proprietà 5.7: Proprietà della Varianza

Per ogni costante $a, b \in \mathbb{R}$:

1. $\text{Var}(X) \geq 0$, con $\text{Var}(X) = 0 \iff X = c$ quasi certamente (costante deterministica).
2. $\text{Var}(aX + b) = a^2 \text{Var}(X)$ (la varianza è insensibile a traslazioni costanti).
3. $\text{SD}(aX + b) = |a| \text{SD}(X)$.

5.3 Covarianza, Correlazione e Varianza della Somma**Definizione 5.8: Covarianza e Correlazione Teorica**

Dati due v.a. X e Y con medie μ_X, μ_Y :

1. La **covarianza teorica** è definita da:

$$\text{Cov}(X, Y) := \mathbb{E}[(X - \mu_X)(Y - \mu_Y)] = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] \quad (5.13)$$

2. Il coefficiente di correlazione di Pearson è:

$$\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X) \text{Var}(Y)}} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y} \in [-1, 1] \quad (5.14)$$

Teorema 5.9: Varianza della Somma e Identità di Bienaymé

Per qualsiasi coppia di variabili aleatorie X, Y :

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2 \text{Cov}(X, Y) \quad (5.15)$$

Più in generale, per una combinazione lineare di n variabili:

$$\text{Var}\left(\sum_{i=1}^n a_i X_i\right) = \sum_{i=1}^n a_i^2 \text{Var}(X_i) + 2 \sum_{1 \leq i < j \leq n} a_i a_j \text{Cov}(X_i, X_j) \quad (5.16)$$

Identità di Bienaymé: Se le variabili $\{X_i\}_{i=1}^n$ sono a due a due incorrelate (ed in particolare se sono stocasticamente indipendenti, per cui $\text{Cov}(X_i, X_j) = 0$), allora la varianza della somma è esattamente la somma delle varianze:

$$\text{Var}\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n \text{Var}(X_i) \quad (5.17)$$

5.4 Disuguaglianze Fondamentali di Concentrazione: Markov e Chebyshev

In ingegneria è frequente dover stimare una probabilità di guasto o di deviazione estrema conoscendo unicamente la media μ e la deviazione standard σ del sistema, senza conoscerne la densità esatta. Le disuguaglianze di concentrazione forniscono limiti superiori universali rigorosi validi per qualunque distribuzione.




Figura 5.2: Visualizzazione geometrica della Disuguaglianza di Chebyshev. La probabilità che la variabile X si discosti dalla media μ per più di k deviazioni standard ($|X - \mu| \geq k\sigma$) è limitata superiormente dall'area delle code esterne pari a $1/k^2$, a prescindere dalla forma specifica della distribuzione.

Teorema 5.10: Disuguaglianza di Markov

Sia Y una variabile aleatoria **non negativa** ($Y \geq 0$ q.c.) con valore atteso finito $\mathbb{E}[Y]$. Allora per ogni costante $a > 0$:

$$\mathbb{P}(Y \geq a) \leq \frac{\mathbb{E}[Y]}{a} \quad (5.18)$$

Dimostrazione. Consideriamo la funzione indicatrice $\mathbf{1}_{\{Y \geq a\}}$ (pari a 1 se $Y \geq a$, 0 se $Y < a$). Poiché $Y \geq 0$, vale la disuguaglianza puntuale:

$$a \cdot \mathbf{1}_{\{Y \geq a\}} \leq Y \quad (\forall \omega \in \Omega) \quad (5.19)$$

Infatti:

- Se $Y(\omega) < a$, il membro sinistro vale $a \cdot 0 = 0 \leq Y(\omega)$;
- Se $Y(\omega) \geq a$, il membro sinistro vale $a \cdot 1 = a \leq Y(\omega)$.

Applicando la monotonia del valore atteso ad ambo i membri:

$$\mathbb{E}[a \cdot \mathbf{1}_{\{Y \geq a\}}] \leq \mathbb{E}[Y] \iff a \cdot \mathbb{E}[\mathbf{1}_{\{Y \geq a\}}] \leq \mathbb{E}[Y] \quad (5.20)$$

Poiché per definizione $\mathbb{E}[\mathbf{1}_{\{Y \geq a\}}] = 1 \cdot \mathbb{P}(Y \geq a) + 0 \cdot \mathbb{P}(Y < a) = \mathbb{P}(Y \geq a)$, dividendo per $a > 0$ otteniamo:

$$\mathbb{P}(Y \geq a) \leq \frac{\mathbb{E}[Y]}{a} \quad \blacksquare \quad (5.21)$$

Teorema 5.11: Disuguaglianza di Chebyshev (Bienaymé-Chebyshev)

Sia X una variabile aleatoria con media $\mu = \mathbb{E}[X]$ e varianza $\sigma^2 = \text{Var}(X) < +\infty$. Allora per ogni soglia $\varepsilon > 0$:

$$\mathbb{P}(|X - \mu| \geq \varepsilon) \leq \frac{\text{Var}(X)}{\varepsilon^2} = \frac{\sigma^2}{\varepsilon^2} \quad (5.22)$$

Esprimendo la soglia come multiplo $k > 0$ della deviazione standard ($\varepsilon = k\sigma$):

$$\mathbb{P}(|X - \mu| \geq k\sigma) \leq \frac{1}{k^2}, \quad \text{o equivalentemente} \quad \mathbb{P}(|X - \mu| < k\sigma) \geq 1 - \frac{1}{k^2} \quad (5.23)$$

Dimostrazione. Definiamo la variabile non negativa $Y = (X - \mu)^2 \geq 0$. Notiamo che la condizione $|X - \mu| \geq \varepsilon$ equivale a $(X - \mu)^2 \geq \varepsilon^2$. Applicando la Disuguaglianza di Markov a Y con soglia $a = \varepsilon^2$:

$$\mathbb{P}(|X - \mu| \geq \varepsilon) = \mathbb{P}((X - \mu)^2 \geq \varepsilon^2) \leq \frac{\mathbb{E}[(X - \mu)^2]}{\varepsilon^2} = \frac{\text{Var}(X)}{\varepsilon^2} = \frac{\sigma^2}{\varepsilon^2} \quad \blacksquare \quad (5.24)$$

Esempio di Utilizzo Ingegnistico: Senza conoscere nulla sulla legge di probabilità di un macchinario:

- Per $k = 2$: la probabilità di trovarsi fuori dall'intervallo $[\mu - 2\sigma, \mu + 2\sigma]$ non può superare $\frac{1}{2^2} = 25\%$;
- Per $k = 3$: la probabilità di deviazione oltre 3σ non può superare $\frac{1}{3^2} = 11.11\%$.

CAPITOLO 6

Somma di Variabili Aleatorie, Convoluzione e Teoremi Limite

Sintesi del Capitolo. *Il presente capitolo costituisce il ponte analitico fondamentale che connette la teoria della probabilità alla statistica inferenziale. Si analizza la distribuzione della somma di variabili aleatorie indipendenti attraverso l'operatore matematico di convoluzione continua e discreta, esaminando le proprietà di stabilità e riproduttività delle famiglie parametriche notevoli. Vengono enunciati e dimostrati i grandi teoremi asintotici del calcolo delle probabilità: la Legge Debole dei Grandi Numeri (WLLN di Khinchin) mediante la disuguaglianza di Chebyshev, la Legge Forte (SLLN di Kolmogorov) e il monumentale Teorema del Limite Centrale (CLT di Lindeberg-Lévy). Infine, si approfondisce l'approssimazione normale della Binomiale di De Moivre-Laplace, illustrando la correzione geometrica di continuità di Yates.*

6.1 Distribuzione della Somma e Integrale di Convoluzione

In innumerevoli problemi fisici e ingegneristici, la grandezza osservata è il risultato dell'aggregazione o della sovrapposizione lineare di molteplici contributi aleatori indipendenti: il carico totale che grava su un pilastro portante, il rumore termico su un canale di trasmissione dati o il tempo totale di completamento di una sequenza di attività in un progetto industriale.

Siano X e Y due variabili aleatorie indipendenti. Vogliamo determinare la distribuzione della loro somma $Z = X + Y$.

Teorema 6.1: Convoluzione Discreta e Continua

Siano X e Y due variabili aleatorie stocasticamente indipendenti e sia $Z = X + Y$:

1. **Caso Discreto:** Se X e Y hanno PMF p_X e p_Y , la funzione di massa di Z è data dalla **convoluzione discreta**:

$$p_Z(z) = \mathbb{P}(X + Y = z) = \sum_{x \in \text{Im}(X)} p_X(x) \cdot p_Y(z - x) = (p_X * p_Y)(z) \quad (6.1)$$

2. **Caso Continuo:** Se X e Y hanno PDF f_X e f_Y , la funzione di densità di Z è data dall'**integrale di convoluzione**:

$$f_Z(z) = \int_{-\infty}^{+\infty} f_X(x) \cdot f_Y(z - x) dx = (f_X * f_Y)(z) \quad (6.2)$$

Dimostrazione nel caso assolutamente continuo. Calcoliamo dapprima la Funzione di Ripartizione (CDF) di $Z = X + Y$:

$$F_Z(z) = \mathbb{P}(X + Y \leq z) = \iint_{\{(x,y) \in \mathbb{R}^2: x+y \leq z\}} f_{X,Y}(x,y) dx dy \quad (6.3)$$

Sfruttando l'indipendenza stocastica, la densità congiunta fattorizza in $f_{X,Y}(x,y) = f_X(x)f_Y(y)$. Integrando rispetto a y sulla semiretta $(-\infty, z-x]$:

$$F_Z(z) = \int_{-\infty}^{+\infty} f_X(x) \left[\int_{-\infty}^{z-x} f_Y(y) dy \right] dx = \int_{-\infty}^{+\infty} f_X(x) F_Y(z-x) dx \quad (6.4)$$

Derivando $F_Z(z)$ rispetto a z sotto il segno di integrale (Teorema di Leibniz per integrali dipendenti da parametro):

$$f_Z(z) = \frac{d}{dz} F_Z(z) = \int_{-\infty}^{+\infty} f_X(x) \left[\frac{d}{dz} F_Y(z-x) \right] dx = \int_{-\infty}^{+\infty} f_X(x) f_Y(z-x) dx \quad \blacksquare \quad (6.5)$$

■




Figura 6.1: Effetto smussante della convoluzione: la somma di due variabili aleatorie uniformi indipendenti $X, Y \stackrel{\text{i.i.d.}}{\sim} \text{Unif}(0,1)$ genera una distribuzione continua triangolare simmetrica su $[0,2]$. Convoluzioni successive di uniformi generano distribuzioni a campana progressivamente sempre più lisce ed indistinguibili da una Gaussiana.

6.1.1 Famiglie di Distribuzioni Riproduttive (Chiusura per Convoluzione)

Proprietà 6.2: Proprietà di Riproduzione di Famiglie Notevoli

Siano X_1 e X_2 variabili indipendenti:

1. **Binomiali (con uguale probabilità di successo p):**

$$X_1 \sim \text{Bin}(n_1, p), X_2 \sim \text{Bin}(n_2, p) \implies X_1 + X_2 \sim \text{Bin}(n_1 + n_2, p) \quad (6.6)$$

2. **Poissoniane:**

$$X_1 \sim \text{Pois}(\lambda_1), X_2 \sim \text{Pois}(\lambda_2) \implies X_1 + X_2 \sim \text{Pois}(\lambda_1 + \lambda_2) \quad (6.7)$$

3. **Gaussiane (Normali):**

$$X_1 \sim \mathcal{N}(\mu_1, \sigma_1^2), X_2 \sim \mathcal{N}(\mu_2, \sigma_2^2) \implies X_1 + X_2 \sim \mathcal{N}(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2) \quad (6.8)$$

4. **Chi-quadro:**

$$X_1 \sim \chi^2(k_1), X_2 \sim \chi^2(k_2) \implies X_1 + X_2 \sim \chi^2(k_1 + k_2) \quad (6.9)$$

6.2 La Legge dei Grandi Numeri (LLN)

La Legge dei Grandi Numeri stabilisce formalmente che la media aritmetica di n osservazioni campionarie indipendenti converge al valore atteso teorico μ della popolazione.

Sia $\{X_n\}_{n \geq 1}$ una successione di v.a. indipendenti e identicamente distribuite (*i.i.d.*) con $\mathbb{E}[X_i] = \mu$ e $\text{Var}(X_i) = \sigma^2 < +\infty$. La media campionaria è $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$. Per linearità e identità di Bienaymé:

$$\mathbb{E}[\bar{X}_n] = \mu, \quad \text{Var}(\bar{X}_n) = \frac{\sigma^2}{n} \quad (6.10)$$

Teorema 6.3: Legge Debole dei Grandi Numeri (WLLN di Khinchin)

Per ogni soglia prefissata $\varepsilon > 0$, la probabilità che la media campionaria disti dal valore atteso teorico per più di ε decade a zero al divergere della numerosità campionaria:

$$\lim_{n \rightarrow \infty} \mathbb{P}(|\bar{X}_n - \mu| \geq \varepsilon) = 0 \iff \bar{X}_n \xrightarrow{\mathbb{P}} \mu \quad (\text{Convergenza in Probabilità}) \quad (6.11)$$

Dimostrazione mediante la Disuguaglianza di Chebyshev. Applichiamo la Disuguaglianza di Chebyshev alla variabile aleatoria $\bar{X}_n$:

$$\mathbb{P}(|\bar{X}_n - \mu| \geq \varepsilon) \leq \frac{\text{Var}(\bar{X}_n)}{\varepsilon^2} = \frac{\sigma^2}{n\varepsilon^2} \quad (6.12)$$

Passando al limite per $n \rightarrow \infty$ con $\varepsilon > 0$ costante:

$$0 \leq \lim_{n \rightarrow \infty} \mathbb{P}(|\bar{X}_n - \mu| \geq \varepsilon) \leq \lim_{n \rightarrow \infty} \frac{\sigma^2}{n\varepsilon^2} = 0 \quad \blacksquare \quad (6.13)$$

■

Teorema 6.4: Legge Forte dei Grandi Numeri (SLLN di Kolmogorov)

Nelle medesime ipotesi, la media campionaria converge a μ con probabilità 1 (convergenza quasi certa):

$$\mathbb{P}\left(\lim_{n \rightarrow \infty} \bar{X}_n = \mu\right) = 1 \iff \bar{X}_n \xrightarrow{q.c.} \mu \quad (6.14)$$


6.3 Il Teorema del Limite Centrale (CLT)

Se la Legge dei Grandi Numeri ci assicura che $\bar{X}_n$ collassa puntualmente su μ , il ****Teorema del Limite Centrale**** descrive la geometria della fluttuazione statistica residua attorno a μ , opportunamente riscalata per il fattore di amplificazione $\sqrt{n}$.

Teorema 6.5: Teorema del Limite Centrale (Lindeberg-Lévy)

Sia $\{X_i\}_{i=1}^n$ una successione di v.a. indipendenti e identicamente distribuite con valore atteso μ e varianza finita $\sigma^2 > 0$. Definita la variabile standardizzata della somma $S_n = \sum_{i=1}^n X_i$ o della media $\bar{X}_n$:

$$Z_n = \frac{S_n - n\mu}{\sigma\sqrt{n}} = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \quad (6.15)$$



All'aumentare di n , la distribuzione di $\bar{X}_n$ converge a $\mathcal{N}(\mu, \sigma^2/n)$.

Figura 6.2: Convergenza universale del Teorema del Limite Centrale: all'aumentare di n ($n = 1, 2, 5, 30$), la distribuzione della media campionaria standardizzata $Z_n = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}}$ perde memoria della forma originaria (anche se fortemente asimmetrica o discreta) e converge asintoticamente alla densità Gaussiana standard $\mathcal{N}(0, 1)$.

Per ogni $z \in \mathbb{R}$, la CDF di Z_n converge puntualmente alla CDF della Normale Standard:

$$\lim_{n \rightarrow \infty} \mathbb{P}(Z_n \leq z) = \Phi(z) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^z e^{-t^2/2} dt \iff Z_n \xrightarrow{d} \mathcal{N}(0, 1) \quad (6.16)$$

6.3.1 Teorema di De Moivre-Laplace e Correzione di Continuità di Yates

Quando si approssima una variabile discreta a supporto intero (come $X \sim \text{Bin}(n, p)$ con $np \geq 5$ e $n(1-p) \geq 5$) con una variabile continua $Y \sim \mathcal{N}(np, np(1-p))$, ciascun intero k corrisponde geometricamente all'intervallo continuo $[k - 0.5, k + 0.5]$.

Correzione di Continuità di Yates

Per calcolare probabilità su variabili discrete a valori interi tramite la normale:

$$\mathbb{P}(X = k) \approx \mathbb{P}(k - 0.5 \leq Y \leq k + 0.5) \quad (6.17)$$

$$\mathbb{P}(X \leq k) \approx \mathbb{P}(Y \leq k + 0.5) \quad (6.18)$$

$$\mathbb{P}(X < k) = \mathbb{P}(X \leq k - 1) \approx \mathbb{P}(Y \leq k - 0.5) \quad (6.19)$$

$$\mathbb{P}(X \geq k) \approx \mathbb{P}(Y \geq k - 0.5) \quad (6.20)$$

$$\mathbb{P}(X > k) = \mathbb{P}(X \geq k + 1) \approx \mathbb{P}(Y \geq k + 0.5) \quad (6.21)$$

CAPITOLO 7

Classi di Leggi di Probabilità Discrete

Sintesi del Capitolo. Il presente capitolo presenta una rassegna sistematica ed enciclopedica delle principali famiglie di variabili aleatorie discrete impiegate nella modellazione ingegneristica, gestionale e fisica. Per ciascuna distribuzione viene illustrato il processo generativo microscopico sottostante, la funzione di massa di probabilità (PMF), la funzione di ripartizione (CDF) e la derivazione analitica dei momenti teorici (valore atteso e varianza). Si approfondiscono la proprietà fondamentale di assenza di memoria della legge Geometrica, il Teorema di Poisson per eventi rari (con dimostrazione rigorosa del passaggio al limite dalla Binomiale), il campionamento ipergeometrico da popolazioni finite senza reinserimento con fattore di correzione FPCF e la Binomiale Negativa. Il capitolo si conclude con una tabella comparativa sinottica ad alta consultabilità.

7.1 Distribuzione di Bernoulli e Distribuzione Binomiale

L'atomo elementare della probabilità discreta è l'esperimento dicotomico, formalizzato dalla variabile di Bernoulli.

Definizione 7.1: Variabile Aleatoria di Bernoulli $\text{Bern}(p)$

Modella un singolo esperimento aleatorio che ammette due soli esiti mutuamente esclusivi ed esaustivi: **Successo** ($X = 1$) con probabilità $p \in [0, 1]$, e **Fallimento** ($X = 0$) con probabilità $q = 1 - p$.

- **Supporto:** $\text{Im}(X) = \{0, 1\}$.

- **PMF:**

$$p_X(k) = \mathbb{P}(X = k) = p^k(1 - p)^{1-k}, \quad k \in \{0, 1\} \quad (7.1)$$

- **Momenti Teorici:**

$$\mathbb{E}[X] = 1 \cdot p + 0 \cdot (1 - p) = p, \quad \text{Var}(X) = \mathbb{E}[X^2] - p^2 = p - p^2 = p(1 - p) \quad (7.2)$$

Ripetendo n prove di Bernoulli indipendenti nelle medesime condizioni, il numero complessivo di successi segue la legge Binomiale.

Definizione 7.2: Distribuzione Binomiale $\text{Bin}(n, p)$

Modella il numero complessivo X di successi ottenuti in una sequenza di $n \in \mathbb{N}_{\geq 1}$ prove di Bernoulli indipendenti con probabilità costante di successo $p \in [0, 1]$.

- **Supporto:** $\text{Im}(X) = \{0, 1, 2, \dots, n\}$.
- **PMF:**

$$p_X(k) = \mathbb{P}(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, 1, \dots, n \quad (7.3)$$

Teorema 7.3: Rappresentazione come Somma e Momenti della Binomiale

Ogni variabile $X \sim \text{Bin}(n, p)$ ammette la scomposizione canonica in somma di n indicatori bernoulliani indipendenti:

$$X = \sum_{i=1}^n I_i, \quad \text{con } I_1, \dots, I_n \stackrel{i.i.d.}{\sim} \text{Bern}(p) \quad (7.4)$$

Per la linearità del valore atteso e l'identità di Bienaymé per la varianza:

$$\mathbb{E}[X] = \sum_{i=1}^n \mathbb{E}[I_i] = \sum_{i=1}^n p = np \quad (7.5)$$

$$\text{Var}(X) = \sum_{i=1}^n \text{Var}(I_i) = \sum_{i=1}^n p(1-p) = np(1-p), \quad \text{SD}(X) = \sqrt{np(1-p)} \quad (7.6)$$




Figura 7.1: Confronto delle funzioni di massa di probabilità (PMF) per le distribuzioni discrete notevoli: (a) Binomiale $\text{Bin}(10, 0.5)$ a profilo campanulare simmetrico; (b) Poisson $\text{Pois}(3)$ per eventi rari con asimmetria positiva; (c) Geometrica $\text{Geom}(0.3)$ caratterizzata da un decadimento esponenziale strettamente monotono decrescente.

7.2 Distribuzione Geometrica e la Proprietà di Assenza di Memoria

Mentre la Binomiale fissa il numero di prove n e conta i successi k , la ****legge Geometrica**** risponde alla domanda duale di affidabilità: ***quante prove indipendenti occorre eseguire prima di osservare il primo successo?***

Definizione 7.4: Distribuzione Geometrica $\text{Geom}(p)$

Sia $p \in (0, 1]$ la probabilità di successo. La variabile aleatoria X che conta il numero della prova in cui si verifica il primo successo ha:

- **Supporto:** $\text{Im}(X) = \{1, 2, 3, \dots\} = \mathbb{N}_{\geq 1}$.
- **PMF:** Affinché il primo successo avvenga esattamente alla prova k , le prime $k - 1$ prove devono essere fallimenti seguite dal successo:

$$p_X(k) = \mathbb{P}(X = k) = (1 - p)^{k-1}p, \quad k = 1, 2, \dots \quad (7.7)$$

- **Funzione di Sopravvivenza e CDF:**

$$\mathbb{P}(X > k) = (1 - p)^k \implies F_X(k) = \mathbb{P}(X \leq k) = 1 - (1 - p)^k \quad (7.8)$$

- **Momenti Teorici:**

$$\mathbb{E}[X] = \frac{1}{p}, \quad \text{Var}(X) = \frac{1 - p}{p^2} \quad (7.9)$$

Teorema 7.5: Proprietà di Assenza di Memoria (Memorylessness)

La distribuzione Geometrica è l'**unica distribuzione discreta** che gode della proprietà di assenza di memoria:

$$\mathbb{P}(X > m + k \mid X > m) = \mathbb{P}(X > k) \quad (\forall m, k \in \mathbb{N}_{\geq 1}) \quad (7.10)$$

Dimostrazione. Dalla definizione di probabilità condizionata:

$$\mathbb{P}(X > m + k \mid X > m) = \frac{\mathbb{P}(\{X > m + k\} \cap \{X > m\})}{\mathbb{P}(X > m)} = \frac{\mathbb{P}(X > m + k)}{\mathbb{P}(X > m)} \quad (7.11)$$

$$= \frac{(1 - p)^{m+k}}{(1 - p)^m} = (1 - p)^k = \mathbb{P}(X > k) \quad \blacksquare \quad (7.12)$$

■

Significato Fisico: Se un componente si guasta secondo una legge geometrica, il fatto di aver funzionato per m cicli senza guastarsi non ne aumenta né ne diminuisce la probabilità di guastarsi nei successivi k cicli: il componente “non invecchia”.

7.3 Distribuzione di Poisson e la Legge degli Eventi Rari

La distribuzione di Poisson modella il numero di occorrenze di un evento casuale in un intervallo continuo di tempo o di spazio (chiamate a un centralino per ora, accessi a un web server per secondo, difetti per metro quadro di tessuto).

Definizione 7.6: Distribuzione di Poisson $\text{Pois}(\lambda)$

Sia $\lambda > 0$ il tasso medio di arrivo (numero atteso di eventi nell'intervallo considerato).

- **Supporto:** $\text{Im}(X) = \{0, 1, 2, \dots\} = \mathbb{N}_0$.

- **PMF:**

$$p_X(k) = \mathbb{P}(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}, \quad k = 0, 1, 2, \dots \quad (7.13)$$

- **Momenti Teorici (Eguaglianza Media-Varianza):**

$$\mathbb{E}[X] = \lambda, \quad \text{Var}(X) = \lambda \implies \text{SD}(X) = \sqrt{\lambda} \quad (7.14)$$

Teorema 7.7: Teorema del Limite di Poisson per Eventi Rari

Sia $X_n \sim \text{Bin}(n, p_n)$ una successione di variabili binomiali in cui il numero di prove tende all'infinito ($n \rightarrow \infty$) e la probabilità di successo decade a zero ($p_n \rightarrow 0$) in modo tale che il valore atteso rimanga costante: $np_n = \lambda > 0$. Allora per ogni $k \in \mathbb{N}_0$ fissato:

$$\lim_{n \rightarrow \infty} \mathbb{P}(X_n = k) = \frac{\lambda^k}{k!} e^{-\lambda} \quad (7.15)$$

Dimostrazione Analitica Rigorosa del Passaggio al Limite. Sostituendo $p_n = \frac{\lambda}{n}$ nella formula della Binomiale:

$$\mathbb{P}(X_n = k) = \binom{n}{k} \left(\frac{\lambda}{n}\right)^k \left(1 - \frac{\lambda}{n}\right)^{n-k} \quad (7.16)$$

$$= \frac{n(n-1)(n-2)\dots(n-k+1)}{k!} \frac{\lambda^k}{n^k} \left(1 - \frac{\lambda}{n}\right)^n \left(1 - \frac{\lambda}{n}\right)^{-k} \quad (7.17)$$

$$= \frac{\lambda^k}{k!} \cdot \underbrace{\left[\frac{n}{n} \cdot \frac{n-1}{n} \dots \frac{n-k+1}{n}\right]}_{\rightarrow 1 \text{ per } n \rightarrow \infty} \cdot \underbrace{\left(1 - \frac{\lambda}{n}\right)^n}_{\rightarrow e^{-\lambda}} \cdot \underbrace{\left(1 - \frac{\lambda}{n}\right)^{-k}}_{\rightarrow 1} \quad (7.18)$$

Passando al limite per $n \rightarrow \infty$:

$$\lim_{n \rightarrow \infty} \mathbb{P}(X_n = k) = \frac{\lambda^k}{k!} \cdot 1 \cdot e^{-\lambda} \cdot 1 = \frac{\lambda^k}{k!} e^{-\lambda} \quad \blacksquare \quad (7.19)$$

■

7.4 Distribuzione Ipergeometrica e Binomiale Negativa

Definizione 7.8: Distribuzione Ipergeometrica $\text{Hyp}(N, K, n)$

Modella il numero X di elementi conformi (successi) estratti in un campione di dimensione n pescato **senza reinserimento** da un lotto finito di N elementi totali contenente K elementi conformi.

- **PMF:**

$$p_X(k) = \mathbb{P}(X = k) = \frac{\binom{K}{k} \binom{N-K}{n-k}}{\binom{N}{n}} \quad (7.20)$$

- **Momenti Teorici e Fattore FPCF:** Posto $p = K/N$:

$$\mathbb{E}[X] = np, \quad \text{Var}(X) = np(1-p) \cdot \underbrace{\left(\frac{N-n}{N-1} \right)}_{\text{Fattore di Correzione Popolazione Finita (FPCF)}} \quad (7.21)$$

Osservazione (Confronto Ipergeometrica vs Binomiale)

Se $N \rightarrow \infty$ con $p = K/N$ costante, il fattore FPCF $\frac{N-n}{N-1} \rightarrow 1$. L'estrazione senza reinserimento diventa asintoticamente indistinguibile dall'estrazione con reinserimento ($\text{Bin}(n, p)$).

Definizione 7.9: Distribuzione Binomiale Negativa (o di Pascal) $\text{NB}(r, p)$

Modella il numero totale X di prove indipendenti di Bernoulli per ottenere $r \geq 1$ successi:

- **PMF:**

$$p_X(k) = \mathbb{P}(X = k) = \binom{k-1}{r-1} p^r (1-p)^{k-r}, \quad k = r, r+1, \dots \quad (7.22)$$

- **Momenti:** $\mathbb{E}[X] = \frac{r}{p}, \quad \text{Var}(X) = \frac{r(1-p)}{p^2}.$

7.5 Tabella Sinottica delle Classi di Leggi Discrete

Tabella 7.1: Quadro comparativo completo delle principali famiglie di variabili aleatorie discrete.

Distribuzione	Supporto	PMF $p_X(k)$	$\mathbb{E}[X]$	$\text{Var}(X)$	Chiusura Somma
Bern(p)	$\{0, 1\}$	$p^k (1-p)^{1-k}$	p	$p(1-p)$	Somma $\rightarrow \text{Bin}(n, p)$
Bin(n, p)	$\{0, \dots, n\}$	$\binom{n}{k} p^k (1-p)^{n-k}$	np	$np(1-p)$	Bin($n_1 + n_2, p$)
Geom(p)	$\{1, 2, \dots\}$	$(1-p)^{k-1} p$	$\frac{1}{p}$	$\frac{1-p}{p^2}$	Somma $\rightarrow \text{NB}(r, p)$
Pois(λ)	$\{0, 1, 2, \dots\}$	$\frac{\lambda^k}{k!} e^{-\lambda}$	λ	λ	Pois($\lambda_1 + \lambda_2$)
Hyp(N, K, n)	$\{\max(0, n - (N - K)), \dots\}$	$\frac{\binom{K}{k} \binom{N-K}{n-k}}{\binom{N}{n}}$	$n \frac{K}{N}$	$n \frac{K}{N} (1 - \frac{K}{N}) \frac{N-n}{N-1}$	No
NB(r, p)	$\{r, r+1, \dots\}$	$\binom{k-1}{r-1} p^r (1-p)^{k-r}$	$\frac{r}{p}$	$\frac{r(1-p)}{p^2}$	NB($r_1 + r_2, p$)

CAPITOLO 8

Classi di Leggi di Probabilità Continue

Sintesi del Capitolo. Il presente capitolo espone in modo rigoroso ed esaustivo le principali famiglie di variabili aleatorie continue. Partendo dalla legge Uniforme continua (con applicazioni al calcolo delle probabilità geometriche), si analizza l'Esponenziale e la sua proprietà di assenza di memoria nel continuo, nonché la legge del minimo di esponenziali indipendenti per sistemi affidabilistici in serie. Si approfondisce la distribuzione Normale Gaussiana, regina della statistica, esplicitando i metodi operativi di standardizzazione, le proprietà di simmetria e la celebre Regola Empirica. Infine, si deducono e si contestualizzano le tre distribuzioni pivotali cardine dell'inferenza statistica: la Chi-quadro (χ^2), la t di Student e la F di Fisher-Snedecor.

8.1 Distribuzione Uniforme Continua e Probabilità Geometrica

La legge Uniforme rappresenta la formalizzazione del principio di massima ignoranza o equidistribuzione spaziale nel continuo: ogni intervallo di ampiezza prefissata ha la medesima densità di probabilità.

Definizione 8.1: Distribuzione Uniforme Continua $\text{Unif}(a, b)$

Siano $a < b$ due numeri reali. Una v.a. X segue una legge uniforme sull'intervallo $[a, b]$ se la sua densità è costante sul supporto:

- **PDF:**

$$f_X(x) = \begin{cases} \frac{1}{b-a}, & \text{se } x \in [a, b] \\ 0, & \text{altrove} \end{cases} \quad (8.1)$$

- **CDF:**

$$F_X(x) = \begin{cases} 0, & x < a \\ \frac{x-a}{b-a}, & a \leq x \leq b \\ 1, & x > b \end{cases} \quad (8.2)$$

- **Momenti Teorici:**

$$\mathbb{E}[X] = \frac{a+b}{2}, \quad \text{Var}(X) = \frac{(b-a)^2}{12}, \quad \text{SD}(X) = \frac{b-a}{\sqrt{12}} \quad (8.3)$$

Proposizione 8.2: Probabilità Geometrica su Domini Bidimensionali

Se un punto aleatorio (X, Y) è distribuito uniformemente su un dominio piano misurabile $A \subset \mathbb{R}^2$ con densità congiunta costante $f_{X,Y}(x, y) = \frac{1}{\text{Area}(A)}$, per qualsiasi sottoinsieme misurabile $B \subseteq A$ la probabilità coincide con il rapporto geometrico delle aree:

$$\mathbb{P}((X, Y) \in B) = \frac{\text{Area}(B)}{\text{Area}(A)} \quad (8.4)$$

8.2 Distribuzione Esponenziale e Affidabilità nel Continuo

La distribuzione Esponenziale è il modello universale per i tempi di vita di componenti non soggetti a invecchiamento e per gli intertempi di arrivo in processi di Poisson.

Definizione 8.3: Distribuzione Esponenziale $\text{Exp}(\lambda)$

Sia $\lambda > 0$ il parametro di intensità (o tasso di guasto costante). Una v.a. continua X ha distribuzione esponenziale se:

- **Supporto:** $[0, +\infty)$.
- **PDF e CDF:**

$$f_X(x) = \lambda e^{-\lambda x}, \quad F_X(x) = 1 - e^{-\lambda x} \quad (x \geq 0) \quad (8.5)$$

- **Funzione di Sopravvivenza (Affidabilità $R(t)$):**

$$R(t) = \mathbb{P}(X > t) = 1 - F_X(t) = e^{-\lambda t} \quad (8.6)$$

- **Momenti Teorici:**

$$\mathbb{E}[X] = \frac{1}{\lambda}, \quad \text{Var}(X) = \frac{1}{\lambda^2}, \quad \text{SD}(X) = \frac{1}{\lambda} \quad (8.7)$$




Figura 8.1: Proprietà di assenza di memoria della legge Esponenziale. Sapendo che il componente è sopravvissuto fino al tempo s , la distribuzione del tempo residuo di funzionamento $X - s$ condizionata a $X > s$ ha esattamente la medesima forma esponenziale $e^{-\lambda t}$ di un componente nuovo di fabbrica.

Teorema 8.4: Assenza di Memoria nel Continuo

La distribuzione Esponenziale è l'**unica distribuzione continua** a supporto $[0, \infty)$ che soddisfa:

$$\mathbb{P}(X > s + t \mid X > s) = \mathbb{P}(X > t) \quad (\forall s, t \geq 0) \quad (8.8)$$

Teorema 8.5: Minimo di Esponenziali Indipendenti (Sistemi in Serie)

Siano $X_1, \dots, X_n$ variabili aleatorie esponenziali stocasticamente indipendenti con parametri $\lambda_1, \dots, \lambda_n$. Allora il tempo di primo guasto del sistema $T_{\min} = \min(X_1, \dots, X_n)$ è ancora una variabile esponenziale con parametro pari alla somma dei singoli tassi:

$$T_{\min} \sim \text{Exp} \left(\sum_{i=1}^n \lambda_i \right) \implies \mathbb{E}[T_{\min}] = \frac{1}{\sum_{i=1}^n \lambda_i} \quad (8.9)$$

8.3 Distribuzione Normale Gaussiana**Definizione 8.6: Distribuzione Normale Gaussiana $\mathcal{N}(\mu, \sigma^2)$**

Una variabile aleatoria continua X ha distribuzione normale con media $\mu \in \mathbb{R}$ e varianza $\sigma^2 > 0$ se la sua PDF è la celebre campana di Gauss:

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left(-\frac{(x - \mu)^2}{2\sigma^2} \right), \quad x \in \mathbb{R} \quad (8.10)$$

Se $\mu = 0$ e $\sigma^2 = 1$, si ottiene la **Normale Standard** $Z \sim \mathcal{N}(0, 1)$ con densità $\phi(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}$ e CDF $\Phi(z) = \int_{-\infty}^z \phi(t) dt$.




Figura 8.2: La curva a campana di Gauss $\mathcal{N}(\mu, \sigma^2)$ e la fondamentale **Regola Empirica (68–95–99.7%)**: l'intervallo $\mu \pm \sigma$ racchiude il 68.27% dell'area; $\mu \pm 2\sigma$ racchiude il 95.45%; $\mu \pm 3\sigma$ racchiude il 99.73% della popolazione.

Standardizzazione e Proprietà di Simmetria per il Calcolo delle Probabilità

Per qualsiasi variabile gaussiana $X \sim \mathcal{N}(\mu, \sigma^2)$:

1. **Standardizzazione:** Ponendo $Z = \frac{X-\mu}{\sigma} \sim \mathcal{N}(0, 1)$, si ha:

$$F_X(x) = \mathbb{P}(X \leq x) = \Phi\left(\frac{x-\mu}{\sigma}\right) \quad (8.11)$$

2. **Simmetria per valori negativi:** Poiché $\phi(z)$ è pari rispetto all'origine:

$$\Phi(-z) = 1 - \Phi(z) \quad (\forall z \in \mathbb{R}) \quad (8.12)$$

3. **Probabilità d'intervallo simmetrico attorno a μ :**

$$\mathbb{P}(\mu - k\sigma \leq X \leq \mu + k\sigma) = \Phi(k) - \Phi(-k) = 2\Phi(k) - 1 \quad (8.13)$$

8.4 Distribuzioni Campionarie Pivotali: χ^2 , t di Student e F

Queste tre distribuzioni costituiscono il fondamento matematico di tutti i test d'ipotesi e degli intervalli di confidenza dell'inferenza parametrica.

Definizione 8.7: Distribuzione Chi-quadro $\chi^2(k)$

Siano $Z_1, Z_2, \dots, Z_k \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, 1)$ variabili normali standard indipendenti. La somma dei loro quadrati definisce una variabile **Chi-quadro a k gradi di libertà**:

$$W = \sum_{i=1}^k Z_i^2 \sim \chi^2(k), \quad \mathbb{E}[W] = k, \quad \text{Var}(W) = 2k \quad (8.14)$$

Definizione 8.8: Distribuzione t di Student $t(k)$

Sia $Z \sim \mathcal{N}(0, 1)$ e $W \sim \chi^2(k)$ stocasticamente indipendenti. Il loro rapporto:

$$T = \frac{Z}{\sqrt{W/k}} \sim t(k) \quad (8.15)$$


definisce la distribuzione t di Student a k gradi di libertà.

- È simmetrica a campana centrata in 0 con media $\mathbb{E}[T] = 0$ (per $k > 1$) e varianza $\text{Var}(T) = \frac{k}{k-2}$ (per $k > 2$).
- Presenta **code più pesanti** rispetto alla Normale, per compensare l'incertezza dovuta alla stima della deviazione standard S .
- Per $k \rightarrow \infty$, $t(k) \xrightarrow{d} \mathcal{N}(0, 1)$.

Definizione 8.9: Distribuzione F di Fisher-Snedecor $F(d_1, d_2)$

Siano $W_1 \sim \chi^2(d_1)$ e $W_2 \sim \chi^2(d_2)$ due variabili chi-quadro indipendenti. Il rapporto tra le due varianze campionarie normalizzate:

$$F = \frac{W_1/d_1}{W_2/d_2} \sim F(d_1, d_2) \quad (8.16)$$



La t di Student presenta code più pesanti (heavy tails) per modellare l'incertezza su σ .

Figura 8.3: Confronto qualitativo tra la Normale Standard $\mathcal{N}(0, 1)$ e le distribuzioni t di Student a diversi gradi di libertà ($k = 1, 5$). Si noti come la densità di Student abbia un picco più basso e code nettamente più alte e spesse, convergendo alla Gaussiana all'aumentare di k .

definisce la distribuzione F con d_1 gradi di libertà al numeratore e d_2 al denominatore, impiegata nel test di uguaglianza delle varianze e nell'analisi della varianza (ANOVA).

CAPITOLO 9

Campione Statistico, Teoria della Stima Puntuale e Massima Verosimiglianza

Sintesi del Capitolo. *Il presente capitolo segna il passaggio concettuale dall'analisi probabilistica diretta (deduttiva: dal modello teorico ai dati attesi) all'inferenza statistica (induttiva: dai dati empirici osservati alla stima dei parametri incogniti del modello). Viene formalizzata la nozione di campione casuale i.i.d. e stabilita la netta distinzione tra statistica, stimatore (variabile aleatoria) e stima (valore numerico realizzato). Si definiscono e si dimostrano i criteri di ottimalità degli stimatori: non distorsione (correttezza), scomposizione dell'Errore Quadratico Medio (MSE) nel trade-off tra distorsione e varianza, consistenza asintotica ed efficienza UMVUE mediante il Limite di Cramér-Rao (CRLB) e l'Informazione di Fisher. Si sviluppa in dettaglio il Metodo della Massima Verosimiglianza (MLE), dimostrandone le proprietà di invarianza e normalità asintotica. Infine, si espone il metodo Monte Carlo per l'integrazione stocastica con relativo codice R.*

9.1 Il Paradigma dell'Inferenza: Campione Casuale e Stimatori

In tutte le scienze sperimentali e nell'ingegneria, il processo generativo che governa un fenomeno reale (il tempo di vita di una turbina, il tasso di difettosità di una linea di montaggio, il rendimento energetico di un impianto) è descrivibile mediante una legge di probabilità $f(x; \theta)$ la cui forma funzionale è nota a meno di uno o più parametri incogniti $\theta \in \Theta \subseteq \mathbb{R}^k$.

Definizione 9.1: Campione Casuale I.I.D.

Sia X una variabile aleatoria con densità o massa $f(x; \theta)$ dipendente dal parametro $\theta \in \Theta$. Un **campione casuale di dimensione** n è una n -upla di variabili aleatorie indipendenti e identicamente distribuite:

$$(X_1, X_2, \dots, X_n) \stackrel{\text{i.i.d.}}{\sim} f(x; \theta) \quad (9.1)$$

La realizzazione numerica osservata a posteriori sui dati empirici è denotata con $(x_1, x_2, \dots, x_n) \in \mathbb{R}^n$.

Definizione 9.2: Statistica, Stimatore e Stima

- Una **statistica** $T = g(X_1, \dots, X_n)$ è una qualsiasi funzione a valori reali del campione che non contiene parametri incogniti.

- Uno **stimatore puntuale** $\hat{\theta} = T(X_1, \dots, X_n)$ è una statistica concepita per approssimare il vero valore del parametro θ . Prima dell'estrazione del campione, $\hat{\theta}$ è una **variabile aleatoria** dotata di una propria distribuzione campionaria (detta *sampling distribution*).
- Una **stima puntuale** $\hat{\theta}_{\text{oss}} = T(x_1, \dots, x_n)$ è il singolo numero reale ottenuto sostituendo i dati numerici realizzati nello stimatore.

9.2 Criteri di Ottimalità: Correttezza, MSE e Consistenza

Dato che per uno stesso parametro θ è possibile costruire molteplici stimatori concorrenti, è fondamentale stabilire criteri oggettivi di qualità.

9.2.1 Correttezza (Non Distorsione / Unbiasedness)

Definizione 9.3: Distorsione e Stimatore Corretto

La **distorsione** (*Bias*) di uno stimatore $\hat{\theta}$ è la deviazione sistematica del suo valore atteso dal valore vero del parametro:

$$\text{Bias}(\hat{\theta}) := \mathbb{E}[\hat{\theta}] - \theta \quad (9.2)$$

Uno stimatore si dice **corretto (non distorto)** se il suo valore atteso coincide esattamente con il parametro cercato per ogni possibile $\theta \in \Theta$:

$$\mathbb{E}[\hat{\theta}] = \theta \iff \text{Bias}(\hat{\theta}) = 0 \quad (9.3)$$

Si dice **asintoticamente corretto** se $\lim_{n \rightarrow \infty} \mathbb{E}[\hat{\theta}_n] = \theta$.

9.2.2 Errore Quadratico Medio e Scomposizione Bias-Varianza

Non sempre uno stimatore non distorto è preferibile: se esso possiede una varianza enorme, le sue singole stime oscilleranno violentemente lontano dal bersaglio. La misura globale di accuratezza è l'**Errore Quadratico Medio**.




Figura 9.1: Analogia del tiro al bersaglio per il trade-off Distorsione-Varianza (Bias-Variance Tradeoff): (a) Basso Bias e Bassa Varianza (ottimo); (b) Alto Bias e Bassa Varianza (errore sistematico preciso); (c) Basso Bias e Alta Varianza (centrato in media ma disperso); (d) Alto Bias e Alta Varianza (pessimo).

Teorema 9.4: Decomposizione dell'Errore Quadratico Medio (MSE)

L'Errore Quadratico Medio (Mean Squared Error, MSE) di uno stimatore $\hat{\theta}$ misura la deviazione quadratica totale attesa dal parametro vero θ :

$$\text{MSE}(\hat{\theta}) := \mathbb{E} [(\hat{\theta} - \theta)^2] = \text{Var}(\hat{\theta}) + [\text{Bias}(\hat{\theta})]^2 \quad (9.4)$$

Se lo stimatore è corretto (Bias = 0), l'MSE coincide con la varianza: $\text{MSE}(\hat{\theta}) = \text{Var}(\hat{\theta})$.

Dimostrazione. Aggiungendo e sottraendo il valore atteso $\mathbb{E}[\hat{\theta}]$ all'interno dell'operatore:

$$\text{MSE}(\hat{\theta}) = \mathbb{E} \left[\left((\hat{\theta} - \mathbb{E}[\hat{\theta}]) + (\mathbb{E}[\hat{\theta}] - \theta) \right)^2 \right] \quad (9.5)$$

$$= \mathbb{E} \left[(\hat{\theta} - \mathbb{E}[\hat{\theta}])^2 \right] + 2(\mathbb{E}[\hat{\theta}] - \theta) \underbrace{\mathbb{E} [\hat{\theta} - \mathbb{E}[\hat{\theta}]]}_{=0} + (\mathbb{E}[\hat{\theta}] - \theta)^2 \quad (9.6)$$

$$= \text{Var}(\hat{\theta}) + [\text{Bias}(\hat{\theta})]^2 \quad \blacksquare \quad (9.7)$$

■

9.2.3 Consistenza Asintotica**Definizione 9.5: Stimatore Consistente**

Una successione di stimatori $\{\hat{\theta}_n\}_{n \geq 1}$ si dice **consistente in probabilità** (o debolmente consistente) per θ se all'aumentare della numerosità campionaria $n \rightarrow \infty$ converge in probabilità al parametro vero:

$$\forall \varepsilon > 0, \quad \lim_{n \rightarrow \infty} \mathbb{P} (|\hat{\theta}_n - \theta| \geq \varepsilon) = 0 \iff \hat{\theta}_n \xrightarrow{\mathbb{P}} \theta \quad (9.8)$$

Condizione Sufficiente di Consistenza (tramite Chebyshev): Se lo stimatore è asintoticamente non distorto e la sua varianza tende a zero per $n \rightarrow \infty$, allora è consistente:

$$\lim_{n \rightarrow \infty} \text{Bias}(\hat{\theta}_n) = 0 \quad \text{e} \quad \lim_{n \rightarrow \infty} \text{Var}(\hat{\theta}_n) = 0 \implies \lim_{n \rightarrow \infty} \text{MSE}(\hat{\theta}_n) = 0 \implies \hat{\theta}_n \xrightarrow{\mathbb{P}} \theta \quad (9.9)$$

9.3 Informazione di Fisher e Limite di Cramér-Rao (CRLB)

Esiste un limite fisico insormontabile alla precisione con cui è possibile stimare un parametro da un campione di taglia n ? La risposta è fornita dalla teoria dell'Informazione di Fisher.

Definizione 9.6: Informazione di Fisher

Sia $f(x; \theta)$ la densità della popolazione. Sotto condizioni di regolarità analitica, l'**Informazione di Fisher** contenuta in una singola osservazione è definita da:

$$I(\theta) := \mathbb{E} \left[\left(\frac{\partial}{\partial \theta} \ln f(X; \theta) \right)^2 \right] = -\mathbb{E} \left[\frac{\partial^2}{\partial \theta^2} \ln f(X; \theta) \right] \quad (9.10)$$

Per un campione i.i.d. di dimensione n , l'informazione totale è additiva: $I_n(\theta) = nI(\theta)$.

Significato Geometrico dell'Informazione di Fisher: La derivata seconda $-\frac{\partial^2}{\partial \theta^2} \ln f(x; \theta)$ misura la **curvatura (o concavità)** della log-verosimiglianza. Se la curva è molto piccata e incurvata verso il basso attorno al massimo ($I(\theta)$ grande), piccole variazioni di θ alterano drasticamente la densità, consentendo una stima estremamente precisa; se la curva è piatta ($I(\theta)$ piccolo), vi è alta incertezza.

Teorema 9.7: Disuguaglianza e Limite Inferiore di Cramér-Rao (CRLB)

Sia $\hat{\theta}$ uno stimatore corretto ($\mathbb{E}[\hat{\theta}] = \theta$) per il parametro scalare θ . Sotto condizioni di regolarità, la varianza dello stimatore è limitata inferiormente dal reciproco dell'informazione di Fisher totale:

$$\text{Var}(\hat{\theta}) \geq \frac{1}{I_n(\theta)} = \frac{1}{nI(\theta)} = \text{CRLB} \quad (9.11)$$

Uno stimatore corretto che raggiunge esattamente l'uguaglianza $\text{Var}(\hat{\theta}) = \text{CRLB}$ si dice **efficiente** o a varianza minima uniformemente (UMVUE).

9.4 Il Metodo della Massima Verosimiglianza (MLE)

Il Metodo della Massima Verosimiglianza (*Maximum Likelihood Estimation* - MLE), introdotto da Ronald Fisher nel 1922, è la tecnica di stima parametrica più autorevole ed elegante dell'inferenza statistica.




Figura 9.2: Curva della log-verosimiglianza $\ell(\theta)$ in funzione del parametro θ . Lo stimatore MLE $\hat{\theta}_{\text{MLE}}$ individua il punto stazionario di massimo assoluto in cui la funzione score si annulla: $S(\theta) = \ell'(\theta) = 0$, con derivata seconda strettamente negativa $\ell''(\theta) < 0$.

Definizione 9.8: Funzione di Verosimiglianza e Log-Verosimiglianza

Dato il campione osservato $\mathbf{x} = (x_1, \dots, x_n)$, la **funzione di verosimiglianza** $L(\theta)$ è la densità congiunta interpretata come funzione del parametro θ :

$$L(\theta) := f(x_1, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta) \quad (9.12)$$

Poiché il logaritmo naturale è una trasformazione strettamente monotona crescente, la massimizzazione di $L(\theta)$ è matematicamente equivalente alla massimizzazione della **log-verosimiglianza**:

$$\ell(\theta) := \ln L(\theta) = \sum_{i=1}^n \ln f(x_i; \theta) \quad (9.13)$$

Procedura Operativa in 4 Fasi per il Calcolo dello Stimatore MLE

1. **Scrittura della Verosimiglianza:** $L(\theta) = \prod_{i=1}^n f(x_i; \theta)$.
2. **Passaggio al Logaritmo:** $\ell(\theta) = \sum_{i=1}^n \ln f(x_i; \theta)$.
3. **Calcolo della Score Function ed Uguaglianza a Zero:**

$$S(\theta) = \frac{d\ell(\theta)}{d\theta} = 0 \implies \text{si risolve l'equazione per ricavare } \hat{\theta} \quad (9.14)$$

4. **Verifica della Concavità (Test dell'Hessiano):**

$$\left. \frac{d^2\ell(\theta)}{d\theta^2} \right|_{\theta=\hat{\theta}} < 0 \implies \text{garantisce che il punto stazionario sia un massimo relativo e globale.} \quad (9.15)$$

Teorema 9.9: Proprietà Notevoli dello Stimatore MLE

1. **Proprietà di Invarianza Funzionale (Teorema di Zehna):** Se $\hat{\theta}_{MLE}$ è lo stimatore di massima verosimiglianza per θ , allora per qualsiasi funzione $g(\theta)$, lo stimatore MLE di $g(\theta)$ è semplicemente $g(\hat{\theta}_{MLE})$.
2. **Normalità Asintotica ed Efficienza:** All'aumentare di $n \rightarrow \infty$, lo stimatore MLE converge in legge ad una normale con varianza pari al limite di Cramér-Rao:

$$\sqrt{n}(\hat{\theta}_{MLE} - \theta) \xrightarrow{d} \mathcal{N}\left(0, \frac{1}{I(\theta)}\right) \quad (9.16)$$

9.5 Il Metodo Monte Carlo per la Stima e l'Integrazione Numerica

Quando un integrale multivariato o il valore atteso di una grandezza complessa $I = \mathbb{E}[g(X)] = \int g(x)f(x)dx$ non ammette una primitiva in forma chiusa, il metodo Monte Carlo sfrutta la Legge dei Grandi Numeri per stimare I mediante campionamento pseudo-casuale al calcolatore.




Figura 9.3: Principio del metodo Monte Carlo: stima geometrica di π tramite campionamento uniforme di punti $(X_i, Y_i) \sim \text{Unif}([-1, 1]^2)$. La frazione di punti che cade all'interno del cerchio unitario $X^2 + Y^2 \leq 1$ converge a $\frac{\text{Area Cerchio}}{\text{Area Quadrato}} = \frac{\pi}{4}$.

Integrazione Monte Carlo in R

Per approssimare l'integrale $I = \int_a^b h(x)dx$:

1. Si riscrive l'integrale come $I = (b - a) \int_a^b h(x) \frac{1}{b-a} dx = (b - a) \mathbb{E}[h(X)]$ con $X \sim \text{Unif}(a, b)$.
2. Si generano N numeri pseudo-casuali $x_1, \dots, x_N \sim \text{Unif}(a, b)$ e si calcola la media:

$$\hat{I}_N = (b - a) \cdot \frac{1}{N} \sum_{i=1}^N h(x_i) \quad (9.17)$$

L'errore standard della stima decade come $\mathcal{O}(1/\sqrt{N})$, indipendentemente dalla dimensione dello spazio di integrazione.

CAPITOLO 10

Intervalli di Confidenza e Inferenza Intervallare

Sintesi del Capitolo. Il presente capitolo sviluppa la teoria della stima intervallare, lo strumento d'elezione per quantificare esplicitamente il grado di incertezza campionaria associato a una misura statistica. Si chiarisce l'autentico significato epistemologico frequentista del livello di confidenza $1 - \alpha$, demistificando i comuni errori interpretativi. Viene formalizzato il metodo universale della quantità pivotale in 4 fasi e presentata la tassonomia esaustiva degli intervalli di confidenza: per la media di popolazioni gaussiane (con varianza nota e incognita), per proporzioni campionarie bernoulliane (con dimensionamento conservativo del campione), per il confronto tra due medie indipendenti (modelli a varianze note, omoschedastiche con pooled variance e modello di Welch) e per la varianza mediante pivot Chi-quadro.

10.1 Il Concetto di Intervallo e l'Interpretazione Frequentista

Una stima puntuale come $\bar{x} = 10.2$ mm fornisce un unico valore numerico, ma non comunica al decisore l'affidabilità o l'errore potenziale della misura: un conto è aver calcolato $\bar{x} = 10.2$ su $n = 5$ pezzi ad alta variabilità, un altro è averlo ricavato da $n = 10000$ provini di precisione. L'**inferenza intervallare** risolve questa lacuna associando alla stima una regione di valori plausibili accoppiata a un livello di affidabilità probabilistica prefissato $1 - \alpha$ (tipicamente 95% o 99%).

Definizione 10.1: Intervallo di Confidenza


Sia $\mathbf{X} = (X_1, \dots, X_n)$ un campione casuale da una popolazione con parametro incognito θ . Fissato un livello di significatività $\alpha \in (0, 1)$ (con coefficiente di confidenza $1 - \alpha$), un **intervallo di confidenza** al $(1 - \alpha) \cdot 100\%$ per θ è una coppia di statistiche campionarie $L(\mathbf{X})$ e $U(\mathbf{X})$, con $L(\mathbf{X}) \leq U(\mathbf{X})$, tali che:

$$\mathbb{P}(L(\mathbf{X}) \leq \theta \leq U(\mathbf{X})) = 1 - \alpha \quad (10.1)$$

Trappola Epistemologica: Cosa Significa Realmente "Confidenza al 95%"?

Una volta che il campione è stato estratto e l'intervallo numerico realizzato è stato calcolato (ad esempio, $[12.4, 15.8]$):

- **ERRORE GRAVE:** Affermare che "la probabilità che θ sia compreso tra 12.4 e 15.8 è del 95%". Nel paradigma frequentista, θ non è una variabile aleatoria, ma



Nel 95% dei campioni estratti, l'intervallo casuale $[\bar{X}_n - d, \bar{X}_n + d]$ conterrà il parametro fisso μ .

Figura 10.1: Significato frequentista di un intervallo di confidenza al 95%. La linea verticale rossa rappresenta il parametro vero μ , fisso ed immutabile. Ciascun segmento orizzontale rappresenta l'intervallo casuale realizzato su un diverso campione estratto. Su un gran numero di repliche, esattamente il 95% degli intervalli (in blu) cattura μ , mentre il restante 5% (in rosso) lo manca.

una costante fisica fissa. Di conseguenza, θ o appartiene a $[12.4, 15.8]$ (probabilità 1) o non vi appartiene (probabilità 0).

- **INTERPRETAZIONE CORRETTA:** Il valore 95% misura l'**affidabilità a lungo termine della procedura statistica di stima**. Significa che se ripetessimo l'esperimento infinite volte estraendo nuovi campioni della medesima taglia, il 95% degli intervalli casuali così costruiti conterrebbe il parametro vero θ .

10.2 Il Metodo Generale della Quantità Pivotale

La tecnica universale per costruire intervalli di confidenza esatti e asintotici si basa sulla nozione di quantità pivotale.

Definizione 10.2: Quantità Pivotal

Una funzione $Q(\mathbf{X}, \theta)$ del campione e del parametro θ si dice **quantità pivotale** se:

1. Dipende esplicitamente dai dati $\mathbf{X}$ e dal parametro target θ ;
2. La sua legge di probabilità è **completamente nota** e non dipende da θ né da altri parametri ignoti di disturbo.




Figura 10.2: Costruzione dell'intervallo di confidenza sulla densità della quantità pivotale standardizzata $\mathcal{N}(0, 1)$. L'area centrale racchiude la probabilità $1 - \alpha$, delimitata dai quantili simmetrici $-z_{\alpha/2}$ e $+z_{\alpha/2}$, lasciando una massa $\alpha/2$ su ciascuna delle due code estreme.

Procedura Operativa in 4 Fasi per Costruire un Intervallo di Confidenza

1. **Scelta del Pivot:** Individuare la statistica $Q(\mathbf{X}, \theta)$ a distribuzione nota (es. Gaussiana Z , Student T , Chi-quadro W).
2. **Definizione della Probabilità Centrale:** Dalla tavola della distribuzione, individuare i quantili critici q_1, q_2 tali che:

$$\mathbb{P}(q_1 \leq Q(\mathbf{X}, \theta) \leq q_2) = 1 - \alpha \quad (10.2)$$

3. **Inversione Algebrica della Doppia Disuguaglianza:** Isolare il parametro θ al centro:

$$q_1 \leq Q(\mathbf{X}, \theta) \leq q_2 \iff L(\mathbf{X}) \leq \theta \leq U(\mathbf{X}) \quad (10.3)$$

4. **Valutazione Numerica:** Sostituire le realizzazioni campionarie $(\bar{x}, s, n)$ ottenendo $[L(\mathbf{x}), U(\mathbf{x})]$.

10.3 Tassonomia Completa degli Intervalli di Confidenza

10.3.1 1. Media di Popolazione con Varianza σ^2 Nota (Intervallo Z)

Se la popolazione è normale (o $n \geq 30$ per il CLT) con σ noto, il pivot è $Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1)$.

$$\text{IC}_{1-\alpha}(\mu) = \left[\bar{x} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}, \quad \bar{x} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \right] \quad (10.4)$$

Dimensionamento Campionario Ottimale: Per garantire un margine di errore massimo $E = z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$, la numerosità minima richiesta è:

$$n \geq \left(\frac{z_{\alpha/2} \cdot \sigma}{E} \right)^2 \quad (10.5)$$

10.3.2 2. Media di Popolazione con Varianza σ^2 Incognita (Intervallo t di Student)

Se la popolazione è normale con σ incognito, sostituendo la deviazione standard campionaria s , il pivot è $T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1)$:

$$\text{IC}_{1-\alpha}(\mu) = \left[\bar{x} - t_{\alpha/2, n-1} \frac{s}{\sqrt{n}}, \quad \bar{x} + t_{\alpha/2, n-1} \frac{s}{\sqrt{n}} \right] \quad (10.6)$$

10.3.3 3. Proporzione Bernoulliana (Intervallo Asintotico di Wald)

Per una proporzione $p \in (0, 1)$ con stimatore $\hat{p} = \frac{X}{n}$ su n prove ($n\hat{p} \geq 5, n(1-\hat{p}) \geq 5$):

$$\text{IC}_{1-\alpha}(p) = \left[\hat{p} - z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}, \quad \hat{p} + z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \right] \quad (10.7)$$

Dimensionamento Conservativo: Poiché $\max_p p(1-p) = 0.25$ in $p = 0.5$, il dimensionamento prudenziale che garantisce l'errore E per qualsiasi p è:

$$n \geq \frac{z_{\alpha/2}^2}{4E^2} \quad (10.8)$$

10.3.4 4. Differenza tra Due Medie Indipendenti $\mu_1 - \mu_2$

- **Varianze note σ_1^2, σ_2^2 :**

$$\text{IC}_{1-\alpha}(\mu_1 - \mu_2) = (\bar{x}_1 - \bar{x}_2) \pm z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \quad (10.9)$$

- **Varianze incognite ma uguali ($\sigma_1^2 = \sigma_2^2 = \sigma^2$ - Varianza Congiunta Pooled):**

$$s_p^2 = \frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2} \implies \text{IC}_{1-\alpha}(\mu_1 - \mu_2) = (\bar{x}_1 - \bar{x}_2) \pm t_{\alpha/2, n_1 + n_2 - 2} s_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}} \quad (10.10)$$

10.3.5 5. Varianza di Popolazione Gaussiana σ^2

Il pivot è $W = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$:

$$\text{IC}_{1-\alpha}(\sigma^2) = \left[\frac{(n-1)s^2}{\chi_{\alpha/2, n-1}^2}, \quad \frac{(n-1)s^2}{\chi_{1-\alpha/2, n-1}^2} \right] \quad (10.11)$$

CAPITOLO 11

Verifica delle Ipotesi Statistiche (Test di Significatività)

Sintesi del Capitolo. *Il presente capitolo espone la teoria formale delle decisioni statistiche di Jerzy Neyman ed Egon Pearson. Si formalizza la dialettica tra ipotesi nulla (H_0) e ipotesi alternativa (H_1), chiarendo l'asimmetria ontologica tra le due posizioni mediante la celebre metafora giuridica del processo penale. Si analizza la matrice di contingenza degli errori decisionali (Errore di I tipo α ed Errore di II tipo β), definendo la funzione di potenza del test. Viene approfondito il concetto unificante di p-value e dimostrato il teorema di dualità strutturale che lega i test bilaterali agli intervalli di confidenza. Infine, si presenta la tassonomia operativa dei test parametrici Z e t per medie, proporzioni e confronti tra campioni indipendenti.*

11.1 La Struttura Logica del Test d'Ipotesi e la Metafora Giuridica

Nel metodo scientifico e nell'ingegneria gestionale, il decisore deve costantemente vagliare affermazioni quantitative su parametri ignoti: un nuovo trattamento riduce i consumi? Il tasso di difettosità supera la soglia di tolleranza contrattuale?

La teoria della verifica delle ipotesi di Neyman-Pearson non cerca di “dimostrare la verità assoluta”, bensì stabilisce una procedura oggettiva per decidere se l'evidenza campionaria è sufficientemente forte da respingere una teoria di riferimento.

Definizione 11.1: Ipotesi Nulla (H_0) e Ipotesi Alternativa (H_1)

- **Ipotesi Nulla (H_0):** Rappresenta lo *status quo*, l'ipotesi di neutralità, assenza di effetto o conformità nominale (ad esempio $H_0 : \mu = \mu_0$). Viene assunta provvisoriamente vera fino a prova contraria (principio di conservazione).
- **Ipotesi Alternativa (H_1 o H_a):** Rappresenta la congettura del ricercatore o l'effetto innovativo che si intende sostenere mediante evidenza empirica schiacciante:
 - **Bilaterale (a due code):** $H_1 : \mu \neq \mu_0$;
 - **Unilaterale destra (a una coda):** $H_1 : \mu > \mu_0$;
 - **Unilaterale sinistra (a una coda):** $H_1 : \mu < \mu_0$.

La Metafora Giuridica del Processo Penale: Per comprendere la profonda asimmetria tra H_0 e H_1 :

- H_0 equivale alla ****presunzione di innocenza dell'imputato**** (innocente fino a prova contraria oltre ogni ragionevole dubbio).
- H_1 equivale alla ****colpevolezza****.
- Il verdetto del tribunale non è mai “dimostrazione di innocenza”, bensì:
 - **Rifiuto di H_0 (Condanna):** Le prove empiriche a carico sono talmente schiaccianti che l'ipotesi di innocenza è incompatibile con i fatti.
 - **Non rifiuto di H_0 (Assoluzione per insufficienza di prove):** Non significa aver provato che l'imputato è innocente, ma che i dati raccolti non sono sufficienti a condannarlo.

11.2 Matrice degli Errori Decisionali e Potenza del Test

Poiché la decisione è assunta sulla base di un campione casuale limitato, il test è esposto a due tipologie di errore probabilistico:

Tabella 11.1: Matrice di contingenza e probabilità degli esiti decisionali nel test d'ipotesi.

Decisione Assunta	H_0 Vera nella Realtà	H_0 Falsa nella Realtà (H_1 vera)
Non Rifiutare H_0	Decisione Corretta ($1 - \alpha$)	Errore di II Tipo (β) (<i>Falso Negativo</i>)
Rifiutare H_0	Errore di I Tipo (α) (<i>Falso Positivo</i>)	Decisione Corretta / Potenza ($1 - \beta$)

Definizione 11.2: Livello di Significatività ed Errore di I Tipo

L’**Errore di I Tipo** consiste nel condannare un innocente (rifiutare H_0 quando H_0 è vera). La massima probabilità tollerata per questo errore è fissata a priori dal ricercatore come **livello di significatività** α :

$$\alpha := \mathbb{P}(\text{Rifiutare } H_0 \mid H_0 \text{ è vera}) \qquad (\text{tipicamente } 0.05 \text{ o } 0.01) \qquad (11.1)$$

Definizione 11.3: Errore di II Tipo e Potenza del Test ($1 - \beta$)

L’**Errore di II Tipo** consiste nell’assolvere un colpevole (non rifiutare H_0 quando nella realtà H_0 è falsa). La sua probabilità è $\beta = \mathbb{P}(\text{Non Rifiutare } H_0 \mid H_1 \text{ vera})$. La **Potenza del Test** (Power) è la probabilità di rifiutare correttamente H_0 quando l’effetto reale esiste:

$$\text{Potenza}(\theta) := 1 - \beta(\theta) = \mathbb{P}(\text{Rifiutare } H_0 \mid \theta \in H_1) \qquad (11.2)$$




Figura 11.1: Sovrapposizione delle distribuzioni campionarie della statistica test sotto H_0 (distribuzione blu a sinistra) e sotto H_1 per un valore alternativo $\theta_1 > \theta_0$ (distribuzione rossa a destra). Fissata la soglia critica c_α , l'area rossa a destra di c_α sotto la curva H_0 è α ; l'area verde tratteggiata sotto la curva H_1 a sinistra di c_α è β ; l'area a destra sotto la curva H_1 rappresenta la Potenza $1 - \beta$.




Figura 11.2: Suddivisione dello spazio della statistica test gaussiana sotto H_0 per un test bilaterale al livello $\alpha = 5\%$. La regione centrale di Non Rifiuto ha probabilità $1 - \alpha = 95\%$, delimitata dai valori critici $\pm z_{0.025} = \pm 1.96$. Le due code estreme rosse costituiscono la Regione Critica di Rifiuto $\mathcal{R}$.

11.3 Regioni di Accettazione, Regioni Critiche di Rifiuto e Algoritmo Operativo

Procedura Operativa in 4 Fasi per l'Esecuzione di un Test d'Ipotesi

1. **Formulazione del Sistema di Ipotesi:** Definire esplicitamente H_0 e l'alternativa H_1 (bilaterale o unilaterale).
2. **Scelta della Statistica Test e Livello α :** Individuare la statistica pivotale (es. Z_{test} o T_{test}) e calcolarne la distribuzione esatta sotto l'assunzione che H_0 sia vera.
3. **Individuazione della Soglia Critica e Calcolo del Valore Osservato:**

$$Z_{\text{oss}} = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}} \quad \text{oppure} \quad T_{\text{oss}} = \frac{\bar{x} - \mu_0}{s/\sqrt{n}} \quad (11.3)$$

4. **Regola di Decisione e Conclusione Statistica:**

$$\begin{cases} T_{\text{oss}} \in \mathcal{R} \implies \textbf{Rifiuto } H_0 \text{ al livello } \alpha \text{ a favore di } H_1 \text{ (evidenza significativa);} \\ T_{\text{oss}} \notin \mathcal{R} \implies \textbf{Non Rifiuto } H_0 \text{ (dati compatibili con } H_0 \text{ a livello } \alpha). \end{cases} \quad (11.4)$$

11.4 Il Concetto di p -value (Livello di Significatività Osservato)

Il confronto rigido tra statistica test e soglia critica prefissata α comunica una decisione binaria (rifiuto / non rifiuto), ma non esprime quanto la decisione sia schiacciante o marginale. Per questa ragione l'analisi statistica contemporanea privilegia il **p -value**.

Definizione 11.4: p -value (Livello di Significatività Osservato)

Il **p -value** è la probabilità, calcolata assumendo rigorosamente vera l'ipotesi nulla H_0 , di osservare un valore della statistica test uguale o ancor più sfavorevole ad H_0 di quello effettivamente calcolato sui dati campionari:

$$p\text{-value} = \begin{cases} 2 \cdot (1 - \Phi(|z_{\text{oss}}|)), & \text{per test bilaterale } (H_1 : \mu \neq \mu_0) \\ 1 - \Phi(z_{\text{oss}}), & \text{per test unilaterale destro } (H_1 : \mu > \mu_0) \\ \Phi(z_{\text{oss}}), & \text{per test unilaterale sinistro } (H_1 : \mu < \mu_0) \end{cases} \quad (11.5)$$

Teorema 11.5: Regola di Decisione Universale basata sul p -value

La regola decisionale universale stabilisce:

$$\begin{cases} p\text{-value} \leq \alpha \implies \textbf{Rifiuto } H_0 \text{ (il dato è statisticamente significativo a livello } \alpha); \\ p\text{-value} > \alpha \implies \textbf{Non Rifiuto } H_0 \text{ (evidenza non sufficiente a respingere } H_0). \end{cases} \quad (11.6)$$




Figura 11.3: Significato geometrico del p -value in un test bilaterale. Il p -value corrisponde all'area cumulata delle code estreme esterne a $\pm|z_{oss}|$. Se l'area è inferiore ad α , il risultato è talmente anomalo sotto H_0 da imporne il rifiuto.

11.5 Teorema di Dualità tra Test Bilaterali e Intervalli di Confidenza

Esiste un profondo legame strutturale e algebrico tra l'inferenza per intervalli e la verifica delle ipotesi.

Teorema 11.6: Dualità Test-Intervalli di Confidenza

Sia $IC_{1-\alpha}(\theta) = [L(\mathbf{X}), U(\mathbf{X})]$ l'intervallo di confidenza bilaterale al livello $(1 - \alpha) \cdot 100\%$ per il parametro θ . Allora il test d'ipotesi bilaterale $H_0 : \theta = \theta_0$ contro $H_1 : \theta \neq \theta_0$ al livello di significatività α produce la medesima decisione:

$$\text{Non Rifiuto di } H_0 \text{ al livello } \alpha \iff \theta_0 \in IC_{1-\alpha}(\theta) \quad (11.7)$$

Equivalentemente, si rifiuta H_0 se e solo se il valore ipotizzato θ_0 cade al di fuori dell'intervallo di confidenza: $\theta_0 \notin [L(\mathbf{x}), U(\mathbf{x})]$.

CAPITOLO 12

Raccolta Temi d'Esame Risolti con Guida Metodologica

Sintesi del Capitolo. Questo capitolo finale raccoglie una selezione ragionata e completa di problemi tipici delle prove scritte d'esame di Statistica e Calcolo delle Probabilità. Ciascun esercizio è accompagnato da un'analisi preliminare della strategia risolutiva, dallo svolgimento passo-passo matematicamente rigoroso, da box di attenzione per le trappole più ricorrenti e dal confronto con approcci alternativi.

12.1 Tema d'Esame 1: Probabilità Condizionata e Formula di Bayes

Esercizio Guidato 12.1: Screening Diagnostico su Tre Macchine di Produzione

Un'azienda manifatturiera produce componenti elettronici utilizzando tre linee automatizzate (M_1, M_2, M_3):

- La linea M_1 produce il 40% dei pezzi totali con una percentuale di difettosità del 2%;
 - La linea M_2 produce il 35% dei pezzi totali con una percentuale di difettosità del 3%;
 - La linea M_3 produce il restante 25% dei pezzi totali con una percentuale di difettosità del 6%.
1. Calcolare la probabilità che un pezzo scelto a caso dalla produzione complessiva risulti **difettoso** (D).
 2. Sapendo che un pezzo estratto a caso è risultato **difettoso**, determinare la probabilità che sia stato prodotto dalla linea M_3 .
 3. Sapendo che un pezzo estratto a caso è risultato **conforme (non difettoso)**, determinare la probabilità che provenga dalla linea M_1 .

Dimostrazione. 1. **Definizione della Partizione e delle Probabilità:** La terna $\{M_1, M_2, M_3\}$

costituisce una partizione esaustiva dello spazio campionario S :

$$\begin{aligned}\mathbb{P}(M_1) &= 0.40, & \mathbb{P}(D | M_1) &= 0.02 \\ \mathbb{P}(M_2) &= 0.35, & \mathbb{P}(D | M_2) &= 0.03 \\ \mathbb{P}(M_3) &= 0.25, & \mathbb{P}(D | M_3) &= 0.06\end{aligned}$$

2. Risoluzione Quesito 1 (Formula delle Probabilità Totali):

$$\begin{aligned}\mathbb{P}(D) &= \sum_{i=1}^3 \mathbb{P}(D | M_i) \mathbb{P}(M_i) \\ &= (0.02)(0.40) + (0.03)(0.35) + (0.06)(0.25) \\ &= 0.0080 + 0.0105 + 0.0150 = \mathbf{0.0335} \quad (\mathbf{3.35\%})\end{aligned}$$

3. Risoluzione Quesito 2 (Teorema di Bayes per M_3):

$$\mathbb{P}(M_3 | D) = \frac{\mathbb{P}(D | M_3) \mathbb{P}(M_3)}{\mathbb{P}(D)} = \frac{0.06 \cdot 0.25}{0.0335} = \frac{0.0150}{0.0335} = \frac{30}{67} \approx \mathbf{0.4478} \quad (\mathbf{44.78\%})$$

Osservazione: Nonostante M_3 produca solo il 25% del volume, a causa del suo alto tasso di difettosità genera quasi il 45% di tutti i pezzi difettosi dell'impianto.

4. Risoluzione Quesito 3 (Probabilità condizionata su pezzi conformi D^c): La probabilità totale di conformità è $\mathbb{P}(D^c) = 1 - \mathbb{P}(D) = 1 - 0.0335 = 0.9665$. La probabilità che un pezzo di M_1 sia conforme è $\mathbb{P}(D^c | M_1) = 1 - 0.02 = 0.98$.

$$\mathbb{P}(M_1 | D^c) = \frac{\mathbb{P}(D^c | M_1) \mathbb{P}(M_1)}{\mathbb{P}(D^c)} = \frac{0.98 \cdot 0.40}{0.9665} = \frac{0.3920}{0.9665} \approx \mathbf{0.4056} \quad (\mathbf{40.56\%}) \quad \blacksquare$$

12.2 Tema d'Esame 2: Vettore Aleatorio Continuo Bivariato

Esercizio Guidato 12.2: Densità Congiunta su Dominio Triangolare

Sia (X, Y) un vettore aleatorio continuo con funzione di densità di probabilità congiunta:

$$f_{X,Y}(x, y) = \begin{cases} c \cdot xy, & \text{se } 0 \leq y \leq x \leq 2 \\ 0, & \text{altrove} \end{cases}$$

1. Determinare il valore della costante di normalizzazione $c \in \mathbb{R}$.
2. Calcolare le funzioni di densità marginali $f_X(x)$ e $f_Y(y)$ e specificarne i rispettivi supporti.
3. Stabilire se X e Y sono stocasticamente indipendenti.
4. Calcolare il valore atteso congiunto $\mathbb{E}[XY]$ e la covarianza $\text{Cov}(X, Y)$.
5. Determinare la densità condizionata $f_{Y|X}(y | x)$ e il valore atteso condizionato $\mathbb{E}[Y | X = x]$.

Dimostrazione. 1. Calcolo della costante c (Normalizzazione): L'integrale doppio sul triangolo $D = \{(x, y) : 0 \leq x \leq 2, 0 \leq y \leq x\}$ deve valere 1:

$$\begin{aligned} 1 &= \iint_D cxy \, dx \, dy = c \int_0^2 x \left[\int_0^x y \, dy \right] dx = c \int_0^2 x \left[\frac{y^2}{2} \right]_0^x dx = \frac{c}{2} \int_0^2 x^3 \, dx \\ &= \frac{c}{2} \left[\frac{x^4}{4} \right]_0^2 = \frac{c}{2} \cdot \frac{16}{4} = 2c \implies c = \frac{1}{2} \end{aligned}$$

Quindi la PDF congiunta è $f_{X,Y}(x, y) = \frac{1}{2}xy$ su $0 \leq y \leq x \leq 2$.

2. Calcolo delle PDF marginali:

- Per $x \in [0, 2]$:

$$f_X(x) = \int_0^x \frac{1}{2}xy \, dy = \frac{1}{2}x \left[\frac{y^2}{2} \right]_0^x = \frac{x^3}{4}, \quad x \in [0, 2]$$

(Verifica: $\int_0^2 \frac{x^3}{4} dx = \frac{1}{4} \left[\frac{x^4}{4} \right]_0^2 = 1$, corretto).

- Per $y \in [0, 2]$:

$$f_Y(y) = \int_y^2 \frac{1}{2}xy \, dx = \frac{1}{2}y \left[\frac{x^2}{2} \right]_y^2 = \frac{y}{4}(4 - y^2) = y - \frac{y^3}{4}, \quad y \in [0, 2]$$

3. Verifica dell'Indipendenza: Il supporto $D = \{(x, y) : 0 \leq y \leq x \leq 2\}$ è un triangolo, ossia **non è un dominio rettangolare a variabili separate**. Inoltre, $f_X(x)f_Y(y) = \frac{x^3}{4}(y - \frac{y^3}{4}) \neq \frac{1}{2}xy = f_{X,Y}(x, y)$. Pertanto, X e Y **NON** sono stocasticamente indipendenti.

4. Calcolo di $\mathbb{E}[XY]$, $\mathbb{E}[X]$, $\mathbb{E}[Y]$ e $\text{Cov}(X, Y)$:

$$\mathbb{E}[XY] = \int_0^2 \int_0^x (xy) \left(\frac{1}{2}xy \right) dy \, dx = \frac{1}{2} \int_0^2 x^2 \left[\frac{y^3}{3} \right]_0^x dx = \frac{1}{6} \int_0^2 x^5 \, dx = \frac{1}{6} \left[\frac{x^6}{6} \right]_0^2 = \frac{64}{36} = \frac{16}{9}$$

$$\mathbb{E}[X] = \int_0^2 x \left(\frac{x^3}{4} \right) dx = \frac{1}{4} \left[\frac{x^5}{5} \right]_0^2 = \frac{32}{20} = \frac{8}{5} = 1.6$$

$$\mathbb{E}[Y] = \int_0^2 y \left(y - \frac{y^3}{4} \right) dy = \left[\frac{y^3}{3} - \frac{y^5}{20} \right]_0^2 = \frac{8}{3} - \frac{32}{20} = \frac{8}{3} - \frac{8}{5} = \frac{16}{15} \approx 1.067$$

La covarianza è:

$$\text{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] = \frac{16}{9} - \left(\frac{8}{5} \right) \left(\frac{16}{15} \right) = \frac{16}{9} - \frac{128}{75} = \frac{400 - 384}{225} = \frac{16}{225} \approx 0.0711 > 0$$

5. PDF condizionata e Valore Atteso Condizionato: Per $x \in (0, 2]$:

$$f_{Y|X}(y | x) = \frac{f_{X,Y}(x, y)}{f_X(x)} = \frac{\frac{1}{2}xy}{\frac{1}{4}x^3} = \frac{2y}{x^2}, \quad 0 \leq y \leq x$$

Il valore atteso condizionato (regressione teorica) è:

$$\mathbb{E}[Y | X = x] = \int_0^x y \cdot \left(\frac{2y}{x^2} \right) dy = \frac{2}{x^2} \left[\frac{y^3}{3} \right]_0^x = \frac{2}{3}x \quad \blacksquare$$

■

12.3 Tema d'Esame 3: Teorema del Limite Centrale e Dimensionamento

Esercizio Guidato 12.3: Carico su Ascensore e CLT

Il peso degli utenti di una torre aziendale è modellato come una variabile aleatoria X con valore atteso $\mu = 75$ kg e deviazione standard $\sigma = 12$ kg. Un ascensore di servizio ha una portata nominale di sicurezza pari a 2000 kg.

1. Se salgono $n = 25$ persone indipendenti, qual è la probabilità che il carico complessivo $S_{25} = \sum_{i=1}^{25} X_i$ superi la soglia di sicurezza di 2000 kg?
2. Determinare il numero massimo di persone $n_{\max}$ che possono salire contemporaneamente affinché la probabilità di sovraccarico ($S_n > 2000$) rimanga inferiore allo 0.5% ($\alpha = 0.005$).

Dimostrazione. 1. **Calcolo della Probabilità con $n = 25$ tramite CLT:** Per la somma di $n = 25$ variabili indipendenti:

$$\begin{aligned}\mathbb{E}[S_{25}] &= n\mu = 25 \cdot 75 = 1875 \text{ kg} \\ \sigma_{S_{25}} &= \sqrt{n}\sigma = \sqrt{25} \cdot 12 = 5 \cdot 12 = 60 \text{ kg}\end{aligned}$$

Per il Teorema del Limite Centrale, $S_{25} \sim \mathcal{N}(1875, 60^2)$. Standardizzando la soglia critica 2000 kg:

$$Z_{\text{oss}} = \frac{2000 - 1875}{60} = \frac{125}{60} \approx 2.083$$

La probabilità di superare la portata è:

$$\mathbb{P}(S_{25} > 2000) = 1 - \Phi(2.083) \approx 1 - 0.9814 = \mathbf{0.0186} \quad (\mathbf{1.86\%})$$

2. **Calcolo del numero massimo n affinché $\mathbb{P}(S_n > 2000) \leq 0.005$:** La condizione $\mathbb{P}\left(Z > \frac{2000-75n}{12\sqrt{n}}\right) \leq 0.005$ equivale a richiedere:

$$\frac{2000 - 75n}{12\sqrt{n}} \geq z_{0.005} = 2.576$$

Riorganizzando come disequazione di secondo grado nella variabile ausiliaria $u = \sqrt{n} > 0$:

$$75u^2 + 12(2.576)u - 2000 \leq 0 \implies 75u^2 + 30.912u - 2000 \leq 0$$

Risolviendo l'equazione associata:

$$u = \frac{-30.912 + \sqrt{30.912^2 - 4(75)(-2000)}}{2 \cdot 75} = \frac{-30.912 + \sqrt{955.55 + 600000}}{150} = \frac{-30.912 + 775.21}{150} \approx 4.962$$

Poiché $u = \sqrt{n} \leq 4.962$, elevando al quadrato:

$$n \leq (4.962)^2 \approx 24.62 \implies \mathbf{n_{\max} = 24 \text{ persone}} \quad \blacksquare$$

■

12.4 Tema d'Esame 4: Stima di Massima Verosimiglianza e Informazione di Fisher

Esercizio Guidato 12.4: Stima del Parametro di una Distribuzione di Rayleigh

Sia $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Rayleigh}(\theta)$ con PDF:

$$f(x; \theta) = \frac{x}{\theta} \exp\left(-\frac{x^2}{2\theta}\right), \quad x > 0, \quad \theta > 0$$

1. Determinare lo stimatore di massima verosimiglianza $\hat{\theta}_{\text{MLE}}$ per il parametro θ .
2. Verificare se lo stimatore trovato è corretto (non distorto).
3. Calcolare l'Informazione di Fisher attesa $I_1(\theta)$ e verificare se $\hat{\theta}_{\text{MLE}}$ raggiunge il limite inferiore di Cramér-Rao (CRLB).

Dimostrazione. 1. Derivazione dello Stimatore MLE: La funzione di verosimiglianza è:

$$L(\theta) = \prod_{i=1}^n \left[\frac{x_i}{\theta} \exp\left(-\frac{x_i^2}{2\theta}\right) \right] = \left(\prod_{i=1}^n x_i \right) \theta^{-n} \exp\left(-\frac{1}{2\theta} \sum_{i=1}^n x_i^2\right)$$

La funzione di log-verosimiglianza è:

$$\ell(\theta) = \ln L(\theta) = \sum_{i=1}^n \ln(x_i) - n \ln(\theta) - \frac{1}{2\theta} \sum_{i=1}^n x_i^2$$

Derivando rispetto a θ e ponendo uguale a zero (Score function):

$$\frac{d\ell}{d\theta} = -\frac{n}{\theta} + \frac{1}{2\theta^2} \sum_{i=1}^n x_i^2 = 0 \implies \frac{n}{\theta} = \frac{1}{2\theta^2} \sum_{i=1}^n x_i^2 \implies \hat{\theta}_{\text{MLE}} = \frac{1}{2n} \sum_{i=1}^n X_i^2$$

Verifica della concavità: $\left. \frac{d^2\ell}{d\theta^2} \right|_{\hat{\theta}} = \frac{n}{\theta^2} - \frac{\sum x_i^2}{\theta^3} = \frac{n}{\theta^2} - \frac{2n\hat{\theta}}{\theta^3} = -\frac{n}{\theta^2} < 0$.

2. Verifica della Correttezza: Per una v.a. di Rayleigh, $\mathbb{E}[X^2] = 2\theta$. Calcoliamo il valore atteso di $\hat{\theta}_{\text{MLE}}$:

$$\mathbb{E}[\hat{\theta}_{\text{MLE}}] = \mathbb{E}\left[\frac{1}{2n} \sum_{i=1}^n X_i^2\right] = \frac{1}{2n} \sum_{i=1}^n \mathbb{E}[X_i^2] = \frac{1}{2n} (n \cdot 2\theta) = \theta$$

Pertanto, $\text{Bias}(\hat{\theta}_{\text{MLE}}) = 0$: **lo stimatore è esattamente corretto (non distorto)**.

3. Informazione di Fisher ed Efficienza di Cramér-Rao: Calcoliamo la derivata seconda del logaritmo della densità per una singola osservazione:

$$\ln f(X; \theta) = \ln(X) - \ln(\theta) - \frac{X^2}{2\theta} \implies \frac{\partial^2 \ln f}{\partial \theta^2} = \frac{1}{\theta^2} - \frac{X^2}{\theta^3}$$

L'informazione di Fisher per singola osservazione è:

$$I_1(\theta) = -\mathbb{E}\left[\frac{\partial^2 \ln f}{\partial \theta^2}\right] = -\left(\frac{1}{\theta^2} - \frac{\mathbb{E}[X^2]}{\theta^3}\right) = -\left(\frac{1}{\theta^2} - \frac{2\theta}{\theta^3}\right) = \frac{1}{\theta^2}$$

Il limite inferiore di Cramér-Rao su n osservazioni è $\text{CRLB} = \frac{1}{nI_1(\theta)} = \frac{\theta^2}{n}$. Calcolando la varianza dello stimatore $\hat{\theta}_{\text{MLE}}$ (essendo $X_i^2 \sim \text{Exp}(1/(2\theta))$ con $\text{Var}(X_i^2) = (2\theta)^2 = 4\theta^2$):

$$\text{Var}(\hat{\theta}_{\text{MLE}}) = \frac{1}{4n^2} \sum_{i=1}^n \text{Var}(X_i^2) = \frac{1}{4n^2} (n \cdot 4\theta^2) = \frac{\theta^2}{n}$$

La varianza coincide esattamente con il CRLB: **lo stimatore è UMVUE (Uniformemente a Varianza Minima / Efficiente)**. ■

CAPITOLO 13

Archivio Ufficiale Temi d'Esame Svolti (2024–2022 ed Eserciziari)

Sintesi del Capitolo. *Questo capitolo conclusivo raccoglie le prove d'esame ufficiali del corso di Statistica I (Ingegneria Gestionale, Università di Pisa), complete di testo originale, strategia d'attacco, svolgimento matematico analitico passo-passo a quattro cifre significative e codici di calcolo in linguaggio R. La raccolta è organizzata cronologicamente per anno accademico (con gli appelli completi del 2024, 2023 e 2022) e tematicamente con gli eserciziari storici.*

13.1 Sessione d'Esame 2024: Testi e Soluzioni Svolte Passo-Passo

In questa sezione vengono presentati e risolti integralmente gli appelli d'esame dell'anno accademico 2023/2024, fornendo per ogni quesito la strategia teorica, i calcoli analitici espliciti a 4 cifre significative e i relativi snippet di codice computazionale in linguaggio R.

13.1.1 Appello del 04 Giugno 2024

Esercizio Guidato 13.1: Appello 04.06.2024 – Esercizio 1: Call Center ed Esponenziale

La durata in minuti di una chiamata a un call center è una v.a. $X \sim \text{Exp}(\lambda = 1/3)$, avente densità:

$$f_X(x) = \begin{cases} \frac{1}{3}e^{-x/3}, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

- (a) Calcolare la probabilità che una chiamata scelta a caso abbia una durata minore o uguale a 3 minuti.
- (b) Calcolare la probabilità che scegliendo 5 telefonate a caso indipendenti, almeno 2 abbiano durata maggiore o uguale a 3 minuti.
- (c) Un operatore guadagna un bonus alla terza chiamata di durata superiore a 6 minuti. Calcolare il valore atteso del numero di chiamate necessarie per ottenere il bonus.

Dimostrazione. (a) Probabilità di durata ≤ 3 minuti: Utilizzando la funzione di ripartizione dell'Esponenziale $F_X(t) = 1 - e^{-\lambda t}$:

$$\mathbb{P}(X \leq 3) = F_X(3) = 1 - e^{-3 \cdot (1/3)} = 1 - e^{-1} \approx \mathbf{0.6321} \quad (\text{Opzione a})$$

(b) Binomiale su 5 telefonate: La probabilità che una singola chiamata duri almeno 3 minuti è $p = \mathbb{P}(X \geq 3) = e^{-1} \approx 0.36788$. Su un campione di $n = 5$ chiamate indipendenti, il numero di chiamate Y di durata ≥ 3 segue $Y \sim \text{Bin}(5, p)$.

$$\begin{aligned} \mathbb{P}(Y \geq 2) &= 1 - \mathbb{P}(Y = 0) - \mathbb{P}(Y = 1) = 1 - (1 - p)^5 - 5p(1 - p)^4 \\ &= 1 - (0.63212)^5 - 5(0.36788)(0.63212)^4 \\ &= 1 - 0.10098 - 0.29381 = \mathbf{0.6052} \approx \mathbf{0.604} \quad (\text{Opzione a}) \end{aligned}$$

(c) Valore atteso per il 3° successo (Binomiale Negativa): La probabilità di una chiamata con durata > 6 minuti è $p_6 = \mathbb{P}(X > 6) = e^{-6/3} = e^{-2} \approx 0.135335$. Il numero totale N di chiamate per ottenere $r = 3$ successi segue $N \sim \text{NB}(r = 3, p = e^{-2})$, con valore atteso:

$$\mathbb{E}[N] = \frac{r}{p_6} = \frac{3}{e^{-2}} = 3e^2 \approx 3 \cdot 7.389056 = \mathbf{22.1672} \text{ chiamate} \quad \blacksquare$$

Esercizio Guidato 13.2: Appello 04.06.2024 – Esercizio 2: Poisson e Binomiale con CLT

Il numero di ordini orari ricevuti da Svalvolati SA segue una legge di Poisson con parametro $\mu = 7/6$ indipendente per ogni ora.

- (a) Calcolare la probabilità di ricevere almeno 3 ordini nelle prime tre ore della giornata.
- (b) Le valvole funzionano con probabilità $p = 0.95$. In scatole da 400 unità, sia X il numero di valvole funzionanti. Calcolare $\mathbb{E}[X]$ e $\text{SD}(X)$.
- (c) Calcolare approssimativamente tramite CLT con correzione di continuità la probabilità $\mathbb{P}(X \geq 385)$.

Dimostrazione. (a) Somma di Poisson in 3 ore: Per la proprietà di additività, $S_3 = \sum_{i=1}^3 Y_i \sim \text{Pois}(3 \cdot 7/6 = 3.5)$.

$$\begin{aligned} \mathbb{P}(S_3 \geq 3) &= 1 - e^{-3.5} \left(1 + 3.5 + \frac{3.5^2}{2} \right) = 1 - e^{-3.5} (1 + 3.5 + 6.125) \\ &= 1 - 10.625 e^{-3.5} = 1 - 0.32085 = \mathbf{0.6791} \approx \mathbf{0.68} \quad (\text{Opzione b}) \end{aligned}$$

(b) Momenti della Binomiale $\text{Bin}(400, 0.95)$:

$$\mathbb{E}[X] = np = 400 \cdot 0.95 = \mathbf{380}$$

$$\text{Var}(X) = np(1 - p) = 400 \cdot 0.95 \cdot 0.05 = 19 \implies \text{SD}(X) = \sqrt{19} \approx \mathbf{4.3589}$$

(c) Approssimazione Normale con Correzione di Continuità: Applichiamo la correzione di Yates ponendo $X \geq 385 \implies Y \geq 384.5$:

$$\begin{aligned} \mathbb{P}(X \geq 385) &\approx 1 - \Phi \left(\frac{384.5 - 380}{\sqrt{19}} \right) = 1 - \Phi \left(\frac{4.5}{4.3589} \right) \\ &= 1 - \Phi(1.0324) \approx 1 - 0.8490 = \mathbf{0.1510} \quad (\mathbf{15.10\%}) \quad \blacksquare \end{aligned}$$

Esercizio Guidato 13.3: Appello 04.06.2024 – Esercizio 3: Inferenza su Scarti Chimici

Un impianto produceva in media $\mu_0 = 7.53$ kg di scarti al giorno. Su $n = 8$ misurazioni con un nuovo processo si ottengono: 7.2, 6.8, 7.5, 7.4, 7.1, 7.3, 7.6, 7.3. Si assume normalità.

- Calcolare la media campionaria $\bar{x}$ e la deviazione standard campionaria corretta s .
- Determinare l'intervallo di confidenza al 95% per la media μ .
- Formulare il test per dimostrare la riduzione degli scarti.
- Testare l'ipotesi a livello $\alpha = 0.01$ (1%) e trarre le conclusioni.

Dimostrazione. (a) **Statistiche Descrittive Campionarie:**

$$\sum_{i=1}^8 x_i = 58.2 \implies \bar{x} = \frac{58.2}{8} = 7.2750 \text{ kg}$$

$$\sum_{i=1}^8 x_i^2 = 423.84 \implies s^2 = \frac{1}{7} (423.84 - 8(7.275)^2) = \frac{0.435}{7} \approx 0.062143$$

$$s = \sqrt{0.062143} \approx 0.2493 \text{ kg}$$

(b) **Intervallo di Confidenza di Student al 95% ($n - 1 = 7$ g.d.l.):** Dalla tavola t -Student: $t_{0.025,7} = 2.365$.

$$d = 2.365 \cdot \frac{0.2493}{\sqrt{8}} = 0.2085 \implies \text{IC}_{0.95}(\mu) = [7.2750 \pm 0.2085] = [7.0665, 7.4835] \text{ kg}$$

(c) **Formulazione delle Ipotesi:** $H_0 : \mu = 7.53$ (il processo non riduce gli scarti) vs $H_1 : \mu < 7.53$ (il processo riduce gli scarti, unilaterale sinistro).

(d) **Esecuzione del Test t a livello $\alpha = 0.01$:**

$$T_{\text{oss}} = \frac{\bar{x} - \mu_0}{s/\sqrt{n}} = \frac{7.2750 - 7.53}{0.2493/\sqrt{8}} = \frac{-0.2550}{0.08814} = -2.8931$$

La soglia critica con 7 g.d.l. al livello $\alpha = 0.01$ unilaterale sinistro è $-t_{0.01,7} = -2.998$. Poiché $T_{\text{oss}} = -2.8931 > -2.998$, la statistica **non cade nella regione di rifiuto**. **Conclusione:** Non si rifiuta H_0 al livello dell'1% ($p\text{-value} \approx 0.0116 > 0.01$). L'evidenza campionaria non è sufficientemente forte all'1% per dichiarare una riduzione statisticamente significativa. ■ ■

Esercizio Guidato 13.4: Appello 04.06.2024 – Esercizio 4: Densità Parametrica e Stimatore

Sia $f_\theta(x) = \frac{x}{\theta^2} e^{-x/\theta} \mathbb{I}_{(0,\infty)}(x)$ con $\theta > 0$.

- Verificare che f_θ è una PDF e calcolare $\mathbb{E}[2X_1 + 3]$ in funzione di θ .
- Identificare lo stimatore di massima verosimiglianza $\hat{\theta}_{\text{MLE}}$.
- Discutere correttezza e consistenza di $\hat{\theta}_{\text{MLE}}$.

Dimostrazione. (a) **Verifica PDF e Momenti:** $f_\theta(x) \geq 0$. Usando la formula notevole $\int_0^\infty x^n e^{-\lambda x} dx = \frac{n!}{\lambda^{n+1}}$ con $n = 1, \lambda = 1/\theta$:

$$\int_0^\infty \frac{x}{\theta^2} e^{-x/\theta} dx = \frac{1}{\theta^2} (1!\theta^2) = 1$$

$$\mathbb{E}[X] = \int_0^\infty \frac{x^2}{\theta^2} e^{-x/\theta} dx = \frac{1}{\theta^2} (2!\theta^3) = 2\theta. \text{ Per linearità: } \mathbb{E}[2X_1 + 3] = 2(2\theta) + 3 = 4\theta + 3.$$

(b) Derivazione MLE:

$$L(\theta) = \prod_{i=1}^n \left(\frac{x_i}{\theta^2} e^{-x_i/\theta} \right) = \left(\prod x_i \right) \theta^{-2n} \exp \left(-\frac{1}{\theta} \sum x_i \right)$$

$$\ell(\theta) = \sum \ln x_i - 2n \ln \theta - \frac{1}{\theta} \sum x_i \implies \frac{d\ell}{d\theta} = -\frac{2n}{\theta} + \frac{1}{\theta^2} \sum x_i = 0$$

$$\implies 2n\theta = \sum_{i=1}^n x_i \implies \hat{\theta}_{\text{MLE}} = \frac{1}{2n} \sum_{i=1}^n X_i = \frac{\bar{X}_n}{2}$$

(c) Correttezza e Consistenza: $\mathbb{E}[\hat{\theta}_{\text{MLE}}] = \frac{1}{2}\mathbb{E}[\bar{X}_n] = \frac{1}{2}(2\theta) = \theta \implies$ **Corretto.** Per la WLLN, $\bar{X}_n \xrightarrow{\mathbb{P}} 2\theta \implies \hat{\theta} = \bar{X}_n/2 \xrightarrow{\mathbb{P}} \theta \implies$ **Consistente.** ■

Esercizio Guidato 13.5: Appello 04.06.2024 – Esercizio 5: Integrazione Monte Carlo con R

Si consideri l'integrale $I = \int_{-\infty}^{+\infty} \frac{\cos(7+\ln(x^2+1))}{2+x^4} e^{-(x-2)^2/8} dx$.

- Illustrare il principio teorico di Monte Carlo applicato a questo integrale.
- Scrivere il codice R completo per la stima numerica.

Dimostrazione. Riconosciamo il nucleo di una densità normale $X \sim \mathcal{N}(\mu=2, \sigma^2=4)$, la cui PDF è $f(x) = \frac{1}{\sqrt{2\pi \cdot 4}} e^{-(x-2)^2/8} = \frac{1}{2\sqrt{2\pi}} e^{-(x-2)^2/8}$. Possiamo riscrivere l'integrale come:

$$I = 2\sqrt{2\pi} \int_{-\infty}^{+\infty} \underbrace{\frac{\cos(7+\ln(x^2+1))}{2+x^4}}_{g(x)} f(x) dx = 2\sqrt{2\pi} \mathbb{E}[g(X)]$$

Codice R per la Stima Monte Carlo:

```
set.seed(42)
N <- 10^6
# Campionamento da Normale(mu=2, sigma=2)
x <- rnorm(N, mean = 2, sd = 2)
# Valutazione della funzione trasformata
g_x <- cos(7 + log(x^2 + 1)) / (2 + x^4)
# Calcolo della stima dell'integrale
I_hat <- 2 * sqrt(2 * pi) * mean(g_x)
print(I_hat)
```

13.1.2 Appello del 25 Giugno 2024**Esercizio Guidato 13.6: Appello 25.06.2024 – Esercizio 1: Estrazione Biglie e Somma CLT**

Una scatola contiene 30 biglie numerate da 1 a 10 in 3 colori (rosso, bianco, verde).

- Senza reinserimento, X_1 e X_2 sono indipendenti?
- Senza reinserimento, qual è la probabilità che la somma dei numeri sia esattamente 18?
- Con reinserimento, qual è la probabilità di pescare almeno 4 biglie rosse in 5

tentativi?

- (d) Con reinserimento su 100 estrazioni, calcolare $\mathbb{E}[X_1 + 3X_2]$ e $\text{Var}(2X_1 + 9)$.
 (e) Calcolare tramite CLT la probabilità che la somma $\sum_{i=1}^{100} X_i$ sia inferiore a 500.

Dimostrazione. (a) **Indipendenza:** Senza reinserimento l'estrazione altera lo spazio campionario $\Rightarrow$ **No (Opzione b).**

(b) **Somma = 18:** Le coppie numeriche ordinate sono (8, 10), (10, 8) (ciascuna $3 \times 3 = 9$ modi) e (9, 9) ($3 \times 2 = 6$ modi). Casi favorevoli = $9 + 9 + 6 = 24$. Casi possibili = $30 \times 29 = 870$.

$$\mathbb{P}(\text{Somma} = 18) = \frac{24}{870} = \frac{4}{145} \approx 0.0276 \approx 0.028 \quad (\text{Opzione d})$$

(c) **Almeno 4 rosse su 5 estrazioni con reinserimento** ($p = 10/30 = 1/3$):

$$\mathbb{P}(Y \geq 4) = \binom{5}{4} \left(\frac{1}{3}\right)^4 \left(\frac{2}{3}\right) + \left(\frac{1}{3}\right)^5 = \frac{10}{243} + \frac{1}{243} = \frac{11}{243} \approx 0.0453 \approx 0.045 \quad (\text{Opzione c})$$

(d) **Momenti per variabile uniforme discreta su $\{1, \dots, 10\}$:** $\mathbb{E}[X] = \frac{1+10}{2} = 5.5$,
 $\text{Var}(X) = \frac{10^2-1}{12} = \frac{99}{12} = 8.25$.

$$\mathbb{E}[X_1 + 3X_2] = 5.5 + 3(5.5) = 22$$

$$\text{Var}(2X_1 + 9) = 4 \text{Var}(X_1) = 4(8.25) = 33$$

(e) **Somma di 100 variabili con CLT:** $\mathbb{E}[S_{100}] = 550$, $\sigma_S = \sqrt{100 \cdot 8.25} = \sqrt{825} \approx 28.7228$.

$$\mathbb{P}(S_{100} < 500) \approx \Phi\left(\frac{499.5 - 550}{28.7228}\right) = \Phi(-1.758) = 1 - 0.9606 = 0.0394 \quad (3.94\%) \quad \blacksquare$$

■

Esercizio Guidato 13.7: Appello 25.06.2024 – Esercizio 2: Vendite Parigi vs Londra

Vendite su 6 giorni: Parigi (2659.5, 1882.5, 2165.0, 1949.0, 2453.5, 2050.0), Londra (2963.0, 2685.0, 3083.5, 2151.5, 2466.5, 2020.0).

- (a) Calcolare medie e deviazioni standard campionarie di entrambi i negozi.
 (b) Con σ_1 incognita, calcolare l'IC bilaterale al 90% per μ_1 (Parigi).
 (c) Formulare il test per dimostrare la superiorità del negozio di Londra.
 (d) Con $\sigma_1 = 300$, $\sigma_2 = 400$, testare a livello $\alpha = 0.05$ (5%) e concludere.

Dimostrazione. (a) **Statistiche Campionarie** ($n_1 = n_2 = 6$):

$$\text{Parigi: } \bar{x}_1 = 2193.25 \text{ €, } s_1^2 = 87834.375 \Rightarrow s_1 = 296.37 \text{ €}$$

$$\text{Londra: } \bar{x}_2 = 2561.58 \text{ €, } s_2^2 = 196884.375 \Rightarrow s_2 = 443.72 \text{ €}$$

(b) **Intervallo di Confidenza al 90% per Parigi** ($t_{0.05,5} = 2.015$):

$$d = 2.015 \cdot \frac{296.37}{\sqrt{6}} = 243.79 \Rightarrow \text{IC}_{0.90}(\mu_1) = [2193.25 \pm 243.79] = [1949.46, 2437.04] \text{ €}$$

(c) **Ipotesi del Test:** $H_0 : \mu_2 - \mu_1 \leq 0$ vs $H_1 : \mu_2 - \mu_1 > 0$ (unilaterale destro).

(d) **Test Z con varianze note** $\sigma_1 = 300, \sigma_2 = 400$ a livello $\alpha = 0.05$:

$$SE = \sqrt{\frac{400^2}{6} + \frac{300^2}{6}} = \sqrt{\frac{250000}{6}} \approx 204.124 \implies Z_{\text{oss}} = \frac{2561.58 - 2193.25}{204.124} = \frac{368.33}{204.124} = \mathbf{1.8045}$$

La soglia critica gaussiana è $z_{0.05} = 1.645$. Poiché $Z_{\text{oss}} = 1.8045 > 1.645$, **si rifiuta H_0 al livello del 5%** ($p\text{-value} \approx 0.0356 < 0.05$). **Conclusione:** *I dati forniscono evidenza statisticamente significativa che il negozio di Londra ha vendite medie superiori a quello di Parigi.* ■

Esercizio Guidato 13.8: Appello 25.06.2024 – Esercizi 3, 4 e 5: Bayes, MLE Bernoulli e Monte Carlo

- (3) Screening con 3 test indipendenti: prevalenza $\mathbb{P}(M) = 0.02$, $\mathbb{P}(T^+|M) = 0.99$, $\mathbb{P}(T^-|S) = 0.97 \implies \mathbb{P}(T^+|S) = 0.03$. Calcolare $\mathbb{P}(T_1^+)$, $\mathbb{P}(\geq 2+ | S)$ e $\mathbb{P}(M | \geq 2+)$.
- (4) Modello Bernoulli $p(k|\theta) = \theta^k(1-\theta)^{1-k}$. Ricavare lo stimatore MLE, verificarne correttezza e consistenza.
- (5) Monte Carlo per $I = \int_{-7}^{10} \frac{\sin(7+\ln(x^2+1))}{2+e^x} dx$ con codice R.

Dimostrazione. Esercizio 3 (Bayes su 3 test ripetuti):

- $\mathbb{P}(T_1^+) = 0.99(0.02) + 0.03(0.98) = 0.0198 + 0.0294 = \mathbf{0.0492}$ (4.92%).
- Per persona sana (S): $Y \sim \text{Bin}(3, 0.03)$. $\mathbb{P}(\geq 2+ | S) = 3(0.03)^2(0.97) + (0.03)^3 = \mathbf{0.002646}$ (0.2646%).
- Per persona malata (M): $Y \sim \text{Bin}(3, 0.99)$. $\mathbb{P}(\geq 2+ | M) = 3(0.99)^2(0.01) + (0.99)^3 = 0.029403 + 0.970299 = 0.999702$.
- Evidenza totale: $\mathbb{P}(\geq 2+) = 0.999702(0.02) + 0.002646(0.98) = 0.022587$.
- Probabilità a posteriori: $\mathbb{P}(M | \geq 2+) = \frac{0.019994}{0.022587} = \mathbf{0.8852}$ (88.52%).

Esercizio 4 (MLE Bernoulli): $L(\theta) = \theta^{\sum x_i} (1-\theta)^{n-\sum x_i} \implies \ell(\theta) = \sum x_i \ln \theta + (n - \sum x_i) \ln(1-\theta)$. Annullando la derivata prima: $\frac{\sum x_i}{\theta} - \frac{n-\sum x_i}{1-\theta} = 0 \implies \hat{\theta}_{\text{MLE}} = \bar{X}_n$. $\mathbb{E}[\hat{\theta}] = \theta \implies$ **Corretto**. Per la WLLN, $\bar{X}_n \xrightarrow{\mathbb{P}} \theta \implies$ **Consistente**.

Esercizio 5 (Monte Carlo su $[-7, 10]$): Poniamo $X \sim \text{Unif}(-7, 10)$ con densità $f(x) = 1/17$. L'integrale è $I = 17 \mathbb{E}[g(X)]$.

```
set.seed(123)
N <- 10^6
x <- runif(N, min = -7, max = 10)
g_x <- sin(7 + log(x^2 + 1)) / (2 + exp(x))
I_hat <- 17 * mean(g_x)
print(I_hat)
```

■

13.2 Sessione d'Esame 2023: Testi e Soluzioni Svolte

13.2.1 Appello del 06 Giugno 2023

Esercizio Guidato 13.9: Appello 06.06.2023 – Esercizio 1: Mazza di Carte Italiane

Un mazzo di 40 carte contiene 4 semi e valori da 1 a 7 più tre figure (F, C, R) ciascuna di valore 10.

- Due carte estratte senza reinserimento con valori X_1, X_2 . Sono indipendenti?
- Senza reinserimento, qual è la probabilità che la somma sia esattamente 4?
- Con reinserimento, qual è la probabilità di pescare almeno 3 carte di coppe in 4 estrazioni?
- Con reinserimento, sia X il numero di estrazioni per osservare il primo fante dopo il primo 4. Calcolare $\mathbb{E}[X]$ e $\text{Var}(X)$.

Dimostrazione. (a) **Indipendenza:** Senza reinserimento l'estrazione altera la composizione $\Rightarrow$ **No (Opzione b).**

(b) **Somma = 4:** I casi favorevoli per ottenere somma 4 sono:

- Due carte di valore 2: $4 \times 3 = 12$ modi;
- Un Asso (1) e un 3: $4 \times 4 = 16$ modi (Asso poi 3) + 16 modi (3 poi Asso) = 32 modi.

Casi favorevoli totali = $12 + 32 = 44$. Casi possibili = $40 \times 39 = 1560$.

$$\mathbb{P}(\text{Somma} = 4) = \frac{44}{1560} = \frac{11}{390} \approx 0.0282 \approx 0.028 \quad (\text{Opzione d})$$

(c) **Almeno 3 carte di coppe su 4 estrazioni** ($p = 1/4$):

$$\mathbb{P}(Y \geq 3) = \binom{4}{3} \left(\frac{1}{4}\right)^3 \left(\frac{3}{4}\right) + \left(\frac{1}{4}\right)^4 = 4 \cdot \frac{3}{256} + \frac{1}{256} = \frac{13}{256} \approx 0.0508 \approx 0.051 \quad (\text{Opzione b})$$

(d) **Primo Fante dopo il primo 4 (Somma di Geometriche indipendenti):** Sia T_1 il tempo d'attesa per il primo 4 ($p_1 = 4/40 = 1/10$) e T_2 il tempo d'attesa per il primo fante successivo ($p_2 = 4/40 = 1/10$). Per l'assenza di memoria, $X = T_1 + T_2$ con $T_1, T_2 \stackrel{\text{i.i.d.}}{\sim} \text{Geom}(1/10)$.

$$\mathbb{E}[X] = \mathbb{E}[T_1] + \mathbb{E}[T_2] = \frac{1}{1/10} + \frac{1}{1/10} = 10 + 10 = 20$$

$$\text{Var}(X) = \text{Var}(T_1) + \text{Var}(T_2) = \frac{1 - 1/10}{(1/10)^2} + \frac{1 - 1/10}{(1/10)^2} = 90 + 90 = 180 \quad \blacksquare$$

■

Esercizio Guidato 13.10: Appello 06.06.2023 – Esercizio 2: Durata Batterie e Test Z a Due C

Marca A ($n_A = 7$): 720, 730, 740, 710, 705, 715, 725. Varianza nota $\sigma_A^2 = 121$. Marca B ($n_B = 6$): 708, 703, 693, 718, 713, 698. Varianza nota $\sigma_B^2 = 81$.

- Calcolare l'IC bilaterale al 95% per μ_A .
- Definire le ipotesi per verificare una differenza significativa tra le due marche.
- Eseguire il test al livello $\alpha = 0.05$ e concludere.

Dimostrazione. (a) **Media campionaria Marca A e IC 95%** ($\sigma_A = 11$, $z_{0.025} = 1.96$):
 $\bar{x}_A = \frac{5045}{7} = 720.71$ h.

$$d = 1.96 \cdot \frac{11}{\sqrt{7}} = 1.96 \cdot 4.1576 = 8.1489 \implies \text{IC}_{0.95}(\mu_A) = [720.71 \pm 8.15] = [720.71 - 8.15, 720.71 + 8.15] = [712.56, 728.86]$$

(b) **Ipotesi del Test:** $H_0 : \mu_A - \mu_B = 0$ vs $H_1 : \mu_A - \mu_B \neq 0$ (bilaterale).

(c) **Test Z a Due Campioni a livello** $\alpha = 0.05$: $\bar{x}_B = \frac{4233}{6} = 705.50$ h.

$$\text{SE} = \sqrt{\frac{121}{7} + \frac{81}{6}} = \sqrt{17.2857 + 13.5000} = \sqrt{30.7857} \approx 5.5485$$

$$Z_{\text{oss}} = \frac{720.71 - 705.50}{5.5485} = \frac{15.21}{5.5485} \approx 2.741$$

Poiché $|Z_{\text{oss}}| = 2.741 > z_{0.025} = 1.96$, **si rifiuta H_0 al 5%** ($p\text{-value} = 2(1 - \Phi(2.741)) \approx 0.0061 < 0.05$). **Conclusione:** Esiste una differenza statisticamente significativa nella durata media delle batterie tra le due marche a favore della Marca A. ■

13.3 Sessione d'Esame 2022: Testi e Soluzioni Svolte

13.3.1 Appello 1 (2022)

Esercizio Guidato 13.11: Appello 2022 – Esercizio: Controllo Qualità e Test d'Ipotesi

Un produttore di resistori elettronici dichiara che la resistenza media nominale è $\mu_0 = 100 \Omega$. Su un campione di $n = 16$ componenti si misura una media $\bar{x} = 101.8 \Omega$ e una deviazione standard campionaria $s = 3.2 \Omega$.

- (a) Calcolare l'intervallo di confidenza al 95% per la resistenza media μ .
- (b) Testare l'ipotesi di conformità $H_0 : \mu = 100$ contro l'ipotesi bilaterale $H_1 : \mu \neq 100$ al livello $\alpha = 0.05$.
- (c) Qual è la decisione se il livello di significatività viene abbassato all'1% ($\alpha = 0.01$)?

Dimostrazione. (a) **Intervallo t -Student al 95%** ($n - 1 = 15$ g.d.l., $t_{0.025,15} = 2.131$):

$$d = 2.131 \cdot \frac{3.2}{\sqrt{16}} = 2.131 \cdot 0.8 = 1.7048 \implies \text{IC}_{0.95}(\mu) = [101.8 \pm 1.705] = [100.095, 103.505] \Omega$$

(b) **Test t a livello** $\alpha = 0.05$:

$$T_{\text{oss}} = \frac{\bar{x} - \mu_0}{s/\sqrt{n}} = \frac{101.8 - 100}{3.2/4} = \frac{1.8}{0.8} = 2.250$$

Poiché $|T_{\text{oss}}| = 2.250 > t_{0.025,15} = 2.131$, **si rifiuta H_0 al 5%**. Nota: per la dualità Test-IC, il valore nominale $100 \notin [100.095, 103.505]$, confermando il rifiuto.

(c) **Test t a livello** $\alpha = 0.01$: Dalla tavola di Student a 15 g.d.l.: $t_{0.005,15} = 2.947$. Poiché $|T_{\text{oss}}| = 2.250 < 2.947$, **non si rifiuta H_0 all'1%**. ■

13.4 Eserciziario Tematico Selezionato dalle Prove Scritte

In questa sezione vengono raccolti esercizi emblematici tratti dagli esempi d'esame storici, suddivisi per nuclei concettuali per facilitare il ripasso mirato.

Esercizio Guidato 13.12: Probabilità Bivariata e Regressione Lineare

Sia (X, Y) un vettore aleatorio continuo con densità congiunta $f_{X,Y}(x, y) = \frac{6}{5}(x + y^2)$ sul quadrato unitario $[0, 1]^2$.

- (a) Determinare le densità marginali $f_X(x)$ e $f_Y(y)$.
- (b) Calcolare la covarianza $\text{Cov}(X, Y)$ e verificare se X e Y sono incorrelate.

Dimostrazione. (a) **Densità Marginali su $[0, 1]$:**

$$f_X(x) = \int_0^1 \frac{6}{5}(x + y^2) dy = \frac{6}{5} \left[xy + \frac{y^3}{3} \right]_0^1 = \frac{6}{5} \left(x + \frac{1}{3} \right), \quad x \in [0, 1]$$

$$f_Y(y) = \int_0^1 \frac{6}{5}(x + y^2) dx = \frac{6}{5} \left[\frac{x^2}{2} + xy^2 \right]_0^1 = \frac{6}{5} \left(\frac{1}{2} + y^2 \right), \quad y \in [0, 1]$$

(b) **Momenti e Covarianza:**

$$\mathbb{E}[X] = \frac{6}{5} \int_0^1 x \left(x + \frac{1}{3} \right) dx = \frac{6}{5} \left[\frac{1}{3} + \frac{1}{6} \right] = \frac{6}{5} \cdot \frac{1}{2} = \frac{3}{5} = 0.6$$

$$\mathbb{E}[Y] = \frac{6}{5} \int_0^1 y \left(\frac{1}{2} + y^2 \right) dy = \frac{6}{5} \left[\frac{1}{4} + \frac{1}{4} \right] = \frac{6}{5} \cdot \frac{1}{2} = \frac{3}{5} = 0.6$$

$$\begin{aligned} \mathbb{E}[XY] &= \frac{6}{5} \int_0^1 \int_0^1 (xy)(x + y^2) dx dy = \frac{6}{5} \int_0^1 y \left[\frac{x^3}{3} + \frac{x^2 y^2}{2} \right]_0^1 dy = \frac{6}{5} \int_0^1 \left(\frac{y}{3} + \frac{y^3}{2} \right) dy \\ &= \frac{6}{5} \left[\frac{1}{6} + \frac{1}{8} \right] = \frac{6}{5} \cdot \frac{7}{24} = \frac{7}{20} = 0.35 \end{aligned}$$

La covarianza è:

$$\text{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] = 0.35 - (0.6)(0.6) = 0.35 - 0.36 = -0.01 \neq 0$$

Le variabili presentano una lieve covarianza negativa e dunque **non sono incorrelate** (e di conseguenza non sono indipendenti). ■